

分 类 号 TP391
学校代码 10388

密级 公开
学号 2231808002



福建理工大学
FUJIAN UNIVERSITY OF TECHNOLOGY

硕士专业学位研究生学位（毕业）论文

基于深度学习的楔形光学零部件表面瑕疵检测

关键技术研究

学 科 专 业 : 新一代电子信息技术（含量子技术）
研 究 方 向 : 智能检测
研 究 生 姓 名 : 吕非凡
指 导 教 师 、 职 称 : 郑积仕
所 在 学 院 : 人工智能与交通工程学院
答辩委员会主席签名 : _____

二〇二六 年 五 月

一 遵守学术行为规范承诺

本人已熟知并愿意自觉遵守《福建理工大学研究生培养与学位授予工作中学术规范实施办法》的所有内容，承诺所提交的毕业和学位论文是终稿，不存在学术造假或学术不端行为，且论文的纸质版与电子版内容完全一致。

二 独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得福建理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示谢意。

三 关于论文使用授权的说明

本学位论文作者完全了解 福建理工大学 有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权 福建理工大学 可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

本学位论文属于（必须在以下相应方框内打“√”，否则一律按“公开论文”处理）：

- 1、保密论文：☐ 本学位论文属于保密，在_____年解密后适用本授权书。
- 2、限制级论文：☐ 本学位论文属于延迟公开，在_____年公开后适用本授权书。
- 3、公开论文：☐ 本学位论文不属于保密和延迟公开范围，适用本授权书。

研究生本人签名：_____

签字日期：20____年____月____日

研究生导师签名：_____

签字日期：20____年____月____日

基于深度学习的楔形光学零部件表面瑕疵检测 关键技术研究

摘要

在激光束导向与高精度成像系统中，光学楔形片扮演着至关重要的角色，其表面质量的好坏直接决定了整个系统的损伤阈值及运行稳定性。然而，在实际的精密加工环节，微米级的麻点、划痕和崩边瑕疵往往难以完全避免。现有检测手段存在人工视检主观性强，传统图像处理泛化能力不足等问题。本文尝试回归光学本质，从楔形片的物理散射特性入手，将物理先验知识与深度学习网络深度融合，提出了一套全新的瑕疵检测方法。本文的核心研究工作涵盖以下四个方面：

(1) 设计开发了基于三波段暗场成像的图像获取装备。考虑到微米级瑕疵在单一光源照射下特征极其微弱，本文利用了它们在不同光谱波段下所表现出的散射差异。这种多波段协同不仅在物理层面上直接增强了瑕疵特征，还初步完成了目标与背景的解耦。更重要的是，该硬件方案完好保留了原始的光学能量梯度分布，为算法提供了高质量的物理数据源。

(2) 提出了融合物理信息的 PINN-Swin-Unet 瑕疵检测深度学习方案。选用品具备全局建模能力的 Swin-Unet 作为基准网络，并为其设计了一个并行的物理特征提取模块。该模块的核心作用，是将上述三个波段中捕捉到的物理散射规律转化为高维特征。通过改进的跳跃连接层注入主干网络，引导解码器精准重建瑕疵边缘，消融实验表明含有物理特征提取模块的模型检测瑕疵的平均交并比基准模型提升了 18.9%，达到 0.815。

(3) 构建了基于麦克斯韦方程组的物理约束损失函数。从电磁场边界条件出发，在图像的像素梯度与电磁能量密度之间建立了数学关联，构建了包含边界能量梯度约束、内部均匀性约束及背景抑制约束的复合损失函数。该机制强制要求网络的预测行为必须符合实际的物理散射现象。这种做法大幅增强了模型在面对复杂干扰背景时的抗噪能力与鲁棒性。实验结果表明，该损失函数将检测瑕疵的平均交并比进一步提升至 0.873 较基准模型提升 27.4%。

(4) 设计了针对光学楔形片的精密几何度量评价模型。针对楔形片 5.5° 楔角及厚度渐变引发的透视失真，结合 Zernike 矩与最小二乘法精准确立了物理基准坐标系。随后，为三类典型瑕疵分别建立几何评价模型，并引入倾斜补偿因子修正投影压缩，实现了微米级的真实尺寸还原。数据证实，补偿后的圆心定位误差被严格控制在 0.5 像素以内。

关键词：瑕疵检测，光学楔形片，PINN-Swin-Unet，物理约束损失函数

Research on Key Technologies for Surface Defect Detection of Wedge Optical Components Based on Deep Learning

Abstract

Optical wedges are indispensable components in laser beam steering and high-precision imaging systems, where their surface integrity strictly dictates the overall damage threshold and operational stability of the system. In actual precision manufacturing, however, micron-level defects — such as pits, scratches, and edge chips — remain frustratingly inevitable. Current detection schemes either rely heavily on subjective manual inspection or hit a bottleneck with purely data-driven models that lack adequate generalization capabilities. To overcome these limitations, this study returns to the fundamentals of optics. By exploring the physical scattering characteristics of the wedge, we propose a novel defect detection approach that deeply integrates physical prior knowledge with deep learning networks. The core contributions of this paper are detailed in the following four aspects:

(1) Development of a tri-band dark-field imaging system. Recognizing that micron-level defects exhibit extremely weak features under monochromatic illumination, we leveraged their distinct scattering behaviors across multiple spectral bands. This multi-band synergy not only physically enhances the defect signatures but also achieves a preliminary decoupling between the target and the background. Crucially, this hardware design perfectly preserves the original optical energy gradient distribution, thereby feeding the algorithm with high-quality, physically meaningful data.

(2) Construction of the physics-informed PINN-Swin-Unet architecture. We selected Swin-Unet as our baseline due to its excellent global modeling capabilities and custom-designed a parallel physical feature extraction module. The primary function of this module is to encode the physical scattering behaviors captured across the three optical bands into high-dimensional features. By incorporating an improved skip connection layer into the backbone network, the decoder is guided to precisely reconstruct defect edges; ablation experiments demonstrate that the model equipped with a physical feature extraction module achieves an average Intersection over Union (IoU) for defect detection that is 18.9% higher than that of the baseline model, reaching a value of 0.815.

(3) Design of a physical constraint loss function inspired by Maxwell's equations. Grounded in electromagnetic boundary conditions, we established a mathematical correlation between image pixel gradients and electromagnetic energy density. This enabled the formulation of a composite loss function that simultaneously enforces constraints on boundary energy gradients, internal uniformity, and background suppression. Essentially, this mechanism forces the network's predictions to strictly adhere to actual physical scattering phenomena, drastically improving noise resilience and robustness in complex, interfering environments. Experimental results demonstrate that this loss function further boosts the average IoU for defect detection to 0.873—a 27.4% improvement over the baseline model.

(4) Establishment of a precision geometric metrology framework tailored for optical wedges. To address the inevitable perspective distortion caused by the 5.5° wedge angle and inherent thickness gradients, we established a precise physical reference coordinate system using Zernike moment sub-pixel edge detection combined with the least squares method. Subsequently, tailored geometric evaluation models were developed for the three typical defect categories. By introducing a tilt compensation factor to correct for projection compression, the system successfully achieves micron-level dimensional restoration. Validation data confirms that the compensated center positioning error is strictly controlled to within 0.5 pixels.

Key words: Defect detection, Optical wedge, PINN-Swin-Unet, Physics-constrained loss function

目录

摘要	I
Abstract	II
第一章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于深度学习的瑕疵检测研究现状	3
1.2.2 基于物理信息神经网络的瑕疵检测研究现状	5
1.3 主要研究内容	7
1.4 章节安排	8
第二章 光学楔形片表面瑕疵图像获取方案设计	10
2.1 光学楔形片表面瑕疵检测的特点与需求	10
2.1.1 光学楔形片表面瑕疵分类	10
2.1.2 关键技术与难点	11
2.2 瑕疵图像获取总体方案设计	11
2.3 三波段获取瑕疵图像	14
2.3.1 工业相机和镜头的选择	14
2.3.2 光源和照明方式的选择	15
2.3.3 不同波段下瑕疵敏感度分析	17
2.4 本章小结	19
第三章 基于深度学习的瑕疵检测算法研究	20
3.1 数据集构建	20
3.1.1 数据集标注	20
3.1.2 数据增强	21
3.1.3 数据集划分	22
3.2 PINN-Swin-Unet 网络总体架构设计	23
3.2.1 Swin-Unet 基准算法简述	23
3.2.2 PINN-Swin-Unet 改进策略概述	24
3.3 物理信息特征提取模块	25
3.3.1 三波段瑕疵物理信息特征提取	25
3.3.2 补充物理信息的跳跃链接	26
3.4 物理约束损失函数构建	28
3.4.1 麦克斯韦方程组与散射机理简述	28
3.4.2 物理约束复合损失函数设计	29
3.5 本章小结	32

第四章 光学楔形片表面瑕疵精确定位算法研究	33
4.1 楔形片边缘轮廓亚像素拟合与基准校准	34
4.1.1 Zernike 矩亚像素边缘检测	34
4.1.2 基于最小二乘法的圆拟合	35
4.1.3 基于厚度梯度的坐标系建立	35
4.2 划痕定位与尺寸计算	36
4.2.1 基于骨架细化的长度提取	37
4.2.2 楔角 5.5° 倾斜补偿模型	37
4.2.3 划痕宽度与面积度量	37
4.3 崩边定位与尺寸计算	38
4.3.1 崩边深度计算	39
4.3.2 崩边周向宽度计算	40
4.4 麻点定位与尺寸计算	40
4.4.1 等效直径算法	41
4.4.2 麻点精确定位	42
4.5 算法验证与实验分析	42
4.6 本章小结	44
第五章 验证与分析	45
5.1 训练环境及参数设置	45
5.2 评价指标	45
5.3 实验结果及分析	46
5.3.1 瑕疵检测性能比较分析	46
5.3.2 消融实验	48
5.3.3 MSE 有效性验证	49
5.4 模型对比及分析	50
5.4.1 与深度学习模型的对比分析	50
5.4.2 与工业级软件及先进架构的对比分析	51
5.4.3 PINN-Swin-Unet 的性能优势论证	51
5.5 定性结果分析与可视化验证	53
5.6 本章小结	55
总结与展望	56
参考文献	58
致 谢	63
个人简历、在学期间的研究成果及发表的学术论文	64

第一章 绪论

1.1 研究背景及意义

作为光学元件的核心部件，楔形光学零部件在激光束导向、光谱分析、干涉测量及高精度成像系统中发挥着不可或缺的作用。其表面完整性与洁净度直接决定着光学系统的性能、稳定性和使用寿命^[1]。然而在制造、涂覆、运输和组装过程中，麻点、划痕、崩边等微小瑕疵极易产生。这些瑕疵主要源于加工工艺及后续不当操作^[2]，可能引发光散射、吸收和衍射现象。严重时会导致激光损伤阈值降低、成像质量下降，甚至发系统完全失效。

目前，传统的针对楔形光学零部件等精密光学元件的瑕疵检测方法主要依赖人工目视检查或特定算法的机器视觉技术^[3]。受限于元件尺寸微小及瑕疵尺度细微，检测人员需在暗室内且在高亮度照明条件下长时间进行高强度作业，极易产生视觉疲劳，从而导致误检率和漏检率居高不下，检测效率也难以满足工厂需要。人工检查存在效率低下、成本高昂及主观性强等问题。虽然传统的机器视觉方法如阈值分割、形态学滤波、边缘检测、阈值分割、纹理分析等，通过分析图像的特定特征来识别瑕疵实现了一定程度的自动化，但通常需要繁琐的参数调整，且对光照变化和瑕疵形态多样性具有较差的鲁棒性^[4]。相较于这些传统方法，深度学习算法以其卓越的数据处理能力和自动化特征识别能力，为光学元器件的瑕疵检测提供了一种新的解决方案^[5]。然而，在实现光学楔片表面瑕疵自动化检测的工程实践中，因各种瑕疵具有特殊的物理散射特性与多尺度的形貌带来了瑕疵检测的双重技术挑战。

首先是多光谱物理特征的有效感知与融合难题。不同于普通的工业成像任务，光学楔片表面的微小瑕疵（如麻点、划痕、崩边）在单一白光光源下特征稀疏且对比度极低，难以满足高精度检测的需求。研究表明，不同类别的瑕疵对特定波段具有差异化的散射响应，例如短波紫外光对微米级麻点更具敏感性，而蓝绿光波段则更利于揭示划痕的形貌特征。如何突破传统纯数据驱动模型的局限，将这种跨光谱的物理响应特征深度集成至深度学习架构中，是提升模型在复杂工况下泛化性能的关键。

其次是高精度特征提取难题。即使获取了多光谱图像，光学楔形片表面瑕疵仍面临着极端的多尺度特性：从仅占数十像素的微米级麻点到毫米级的复杂崩边瑕疵并存，这要求模型必须具备极强的多尺度特征捕捉能力。更为复杂的是，低对比度划痕极易湮灭在环境噪声或复杂的背景干扰中，导致模型检测性能不足以

满足工业厂线需求，虚警率居高不下。

综上所述，随着高精度光学系统向精密化与集成化方向演进，核心元器件光学楔片的表面完整性与洁净度已成为提升系统激光损伤阈值、保障成像质量的物理前提。当前还存在人工目检主观性强、工厂真实检测环境黑暗，检测员极易因为视疲劳导致检测错误，工厂具体环境如图 1-1 所示。此外传统机器视觉算法鲁棒性不足以及深度学习算法在面对微尺度瑕疵时在难以提取其特征，无法突破纯数据驱动模型等痛点问题。受限于瑕疵在不同光谱下复杂的散射响应特性，以及低对比度划痕与微小麻点在复杂背景下的识别困境，研发融合含有瑕疵物理信息的高精度自动化检测技术势在必行，这不仅是突破精密光学元件自动化质检瓶颈的关键所在，更是从底层算法层面保障光学系统运行稳定性、促进行业高标准良率产出的重要技术支撑。



图 1-1 人工视检厂线

1.2 国内外研究现状

工业瑕疵检测旨在识别各类工业制品在生产过程中产生的质量瑕疵，是保障产品性能、提升制造良率的核心技术之一。对于光学楔形片等精密光学元件而言，其表面完整性直接影响光路指向精度与系统损伤阈值。传统的瑕疵检测主要依赖人工目检，受主观因素影响大且效率低下，难以适应现代工业高精度、自动化的质检需求。近年来，随着光学成像技术的演进以及计算机视觉、深度学习领域的飞速发展，基于视觉的自动化瑕疵检测技术取得了显著进步，为解决精密光学元

件表面微小瑕疵的检测问题提供了高效的方案。

1.2.1 基于深度学习的瑕疵检测研究现状

工业瑕疵检测的痛点在于难以同时兼顾速度与准确率，而深度学习的介入恰好打破了这一僵局。由于网络模型天然擅长从海量图像中自主学习深层特征，它能够顺畅地将缺陷分割、类别判定以及精准定位等环节全部交由机器自动完成。这使得制造企业无需再依赖高昂的人工成本，就能获得更加敏锐、稳定的质检结果。

近年来，深度学习技术在工业瑕疵检测领域引发了范式变革，研究人员不断探索提升定位与分类性能的多样化策略。在有监督领域，Wang^[6]等人提出了一种基于卷积神经网络的轻量级深度学习模型 **Mobile-Unet**，用于实现端到端的瑕疵分割。该网络采用中值频率平衡损失函数来克服样本不平衡的挑战。**Mobile-Unet** 引入了深度可分离卷积，显著降低了网络的复杂度和模型大小。与其他模型不同的是，不需要人工标注样本进行训练。他们设计的网络只需要无疵点的图像，设计生成一个假样本生成器来模拟疵点图像，并用真实样本进行验证。此外 Tang 等^[7]人提出了一种针对铝材表面瑕疵的分割模型 **FDTransUnet**，利用全局自注意力机制来弥补卷积神经网络在长距离依赖建模上的不足。Sun^[8]针对铝型材表面的复杂瑕疵，设计了一种改进的 **MCH-YOLOv12** 检测算法。该研究通过对传统的通道门控线性单元进行增强，解决了瑕疵在特定方向和边缘特征上的识别难题。Wen^[9]针对带钢瑕疵特征分布稀疏的挑战，提出了一种监督聚焦特征网络，这种聚焦策略显著提高了对不规则瑕疵的特征学习效率，为稀疏分布瑕疵的精准定位提供了新思路；在弱监督学习领域，孙美军^[10]提出了一种基于弱监督的注意力网络，仅依赖图像级标签即可同步实现瑕疵的定位与分类。该方法首先对多尺度感受野模块提取的特征应用特征融合网络，以有效捕获边缘细节信息；继而利用多层次自编码器深入挖掘特征的深层语义信息。此外，引入三线性全局注意力模块进一步优化浅层特征的空间表征；最终通过融合增强浅层边缘特征与深层语义特征，生成高精度的瑕疵特征，实现了高效且准确的自动化表面瑕疵检测。同样，唐明^[11]提出将注意力机制与多尺度最大池化相结合的方法，采用 **ResNet50** 作为预训练网络，构建了一个两阶段检测模型作为基线网络，并在此基础上引入了注意力机制和 **MSMP** 模块。注意力机制能够增强 **ResNet50** 各阶段提取的特征图的特征，使网络集中于对最终检测结果有效的区域，而忽略无效甚至不利于检测的背景区域；针对瑕疵数据有限的场景，Minhas&Zelek^[12]开发了仅基于无瑕疵样本训练的半监督自编码器，提出了一种用于异常检测的卷积自编码器架构，该架

构仅使用无瑕疵（正常）实例进行训练。对于测试图像，通过从自编码器输出中减去原始图像而获得的残差掩模，通过阈值处理得到瑕疵分割掩模通过残差门限实现分割；而 Guo^[13]等人则提出了用于小样本瑕疵检测的新型无监督模型“ISU-GAN”，该模型基于 CycleGAN 架构，在生成器中添加了跳跃连接、SE 模块和内卷模块，从而显著提高了模型的特征提取能力。此外，还提出了一种基于 SSIM 的瑕疵分割方法，该方法适用于基于 GAN 的瑕疵检测，并且可以准确地提取瑕疵轮廓，而无需冗余的噪声抑制后处理。在 DAGM2007 数据集上的实验表明，与使用完整训练集的监督模型相比，无监督的 ISU-GAN 仅需不到三分之一的未标注训练数据即可实现更高的检测精度和更精细的瑕疵轮廓。在特定材料的架构优化方面，Xiong^[14]等人通过引入密集残差单元改进了光伏玻璃用 SqueezeNet 模型，该方法在经典 SqueezeNet 网络模型的两部分 Fire 模块中引入密集残差单元，以提取玻璃边缘图像的重要特征信息，有效避免水滴等干扰因素对瑕疵检测的影响。在通用架构选择方面，Konovalenko^[15]等人的研究表明，在高级编码器中，类 U-Net 模型表现最佳。在瑕疵分割领域，该模型展现出最高的准确率和泛化能力。虽然基于卷积神经网络的语义分割模型（如 U-Net）无需人工特征工程即可实现“端到端”的像素级定位，但标准 CNN 在捕捉全局依赖关系时存在固有局限。这种瑕疵常导致在检测划痕等大尺度或细长瑕疵时出现分割不连续或遗漏的情况。为解决这一问题，Swin-Unet^[16]通过整合 Transformer 架构来应对长距离依赖性挑战。该模型采用创新的滑动窗口自注意力机制，在高效捕捉局部精细特征的同时建立全局上下文关联。在医学影像和工业检测领域均展现出卓越性能，已成为复杂瑕疵检测任务中稳健的基准模型。这也是本文选取 Swin-Unet 作为主干网络的原因。

然而，原始的 Swin-Unet 在处理具有复杂表面纹理或极端低对比度的工业背景时，往往存在早期收敛缓慢和局部特征提取不充分的问题。为此，研究人员开始探索将特定的物理或频域先验特征与 VisionTransformer 进行深度融合。例如，在 IEEE 发表的 Swin-UNet^[17]研究中，学者们提出了一种协同架构，通过多尺度信息融合机制将 CNN 的局部高频特征提取优势与 Transformer 的全局建模能力相结合，显著提升了工业表面微小疵病的分割精度；此外，针对背景纹理复杂的表面，有研究提出了一种结合 Gabor 滤波器与改进 Swin-Unet 的瑕疵分割模型^[18]，该方法通过将传统的频域光谱特征作为先验知识嵌入神经网络，有效消除了复杂背景纹理对瑕疵分割的干扰。这些研究表明，在 Swin-Unet 的架构基础上引入多尺度物理或光谱特征分支，是突破低对比度微小瑕疵检测极限的重要发展趋势。

1.2.2 基于物理信息神经网络的瑕疵检测研究现状

为了让深度学习跳出单纯“数据拟合”的局限，物理信息神经网络(Physics-Informed Neural Networks, PINNs^[19])提供了一条将科学定律与算法相融合的新路径。简单来说，这种方法就是将偏微分方程等已知的控制规律，作为一种感向偏置引入损失函数，该方法使模型预测符合已知物理规律，从而增强了模型的泛化性与可解释性。有了这种物理法则作为底线约束，模型给出的预测不仅更加透彻合理，还能有效应对多物理场耦合带来的计算挑战。当本文将这种理念应用到工业瑕疵检测时，其优势显而易见——在以往因数据量不足或环境噪声过大而容易导致模型失效的极端场景下，PINNs 依靠物理机理与实验数据的双轮驱动，展现出了极强的检测鲁棒性。

在 PINNs 基础研究方面，Chen^[20]等人率先将 PINNs 应用于纳米光学与超材料的逆向设计问题，证明了将物理定律融入深度学习框架在处理光学物理场重建任务中的优越性。Lawal^[21]等人对 PINNs 的演进进行了系统性综述，强调了物理约束在提升神经网络训练稳定性和数据效率方面的关键作用。针对瑕疵识别难题，Cai 等人^[22]提出了一种融合物理模拟数据生成技术与物理信息深度自动编码器的故障检测新方法。该方法首先利用物理模拟手段生成数据，借此驱动 PIDAE 模型以精准重构系统在正常工况下的动态行为，随后引入序贯概率比检验算法对潜在异常进行判别。在新设计电液伺服执行器的实验验证中，该方案表现出了优异的检测精度。Bai^[23]等人，提出了一种整合数字孪生技术和逆物理信息神经网络(InversePINN)的故障诊断模型，用于设备故障诊断。该模型通过 GAN 生成对抗网络补充故障数据，并使用 InversePINN 进行参数估计和故障分类。实验验证显示，该模型在轴承故障诊断中的准确率达到 98.5%，显著优于传统方法。Lee^[24]等人，提出了一种基于 PINN 的无人机尾翼瑕疵检测模型，通过整合激光超声信号和波传播方程作为物理约束，预测裂纹处的等效波速度。实验结果表明，该方法在微裂纹检测中的准确率较高，具有实际应用潜力。此外 Zhang^[25]等人针对工业检测中极具挑战性的重叠瑕疵识别问题，提出了一种同步成像与光电多模态融合框架。研究通过将光学成像数据与电磁测量信号进行耦合，利用物理场理论解析了瑕疵在复合场下的非线性响应规律。实验表明，这种融合物理先验的方法能有效分离重叠的瑕疵特征，其检测性能显著优于传统单一传感方法。Rolih^[26]等人则探索了通用分割大模型在弱监督场景下的潜力，通过将 SAM (Segment Anything Model) 与弱标注数据集成，提出了一种自动化的掩码细化框架。该研究证明了利用预训练大模型的物理先验知识，可以将低成本的边界框标注转化为高精度的分割结果，极大地降低了光学元件等复杂工业制品的标注成本。

在多光谱与物理先验特征的融合应用方面,虽然基于纯空间域的深度学习模型取得了显著进展,但面对透明或高反光材质表面的微弱瑕疵,单纯依靠白光或单通道图像往往难以提取有效特征。因此,研究人员开始探索将特定波段的光谱响应作为先验知识引入神经网络。例如, Wu^[27]等人针对手机玻璃盖板的表面瑕疵,提出了一种基于多光谱成像的深度学习检测方法。该研究证明,利用不同波长光线的反射与吸收特性获取多光谱图像,能够揭示常规光照下难以察觉的微观瑕疵细节,从而显著提升 YOLO 等模型的检测精度。而在更早期的研究中, Chen^[28]等人构建了多光谱深度卷积神经网络用于太阳能电池表面瑕疵检测,证实了多光谱的高维物理输入能大幅增强模型区分复杂背景纹理与真实瑕疵的能力。这些研究充分表明,结合多波段的光学散射特性进行特征提取,是突破低对比度微小瑕疵检测极限的有效途径。

另一方面,在物理信息神经网络的特定应用场景中,尽管已有研究将 PINNs 成功应用于热传导或声波检测,但在光学成像与微观电磁散射领域的深度应用仍具有巨大探索空间。值得注意的是,部分前沿研究已开始将光学核心控制方程直接作为网络的损失函数。例如, Chen^[29]等人提出了一种基于全矢量麦克斯韦方程组的 PINN 框架,用于从近场数据中逆向检索纳米光子结构的复介电常数。该研究证明了将麦克斯韦方程嵌入损失函数,能使网络在处理复杂电磁散射问题时获得极高的物理一致性。同样,基于衍射层析成像的研究中, Gigli^[30]提出了 MaxwellNet,通过将亥姆霍兹方程作为物理约束,实现了对生物样本光散射场的精准预测;在光刻技术领域,最新研究也成功探索了利用 PINNs 求解掩膜的三维光散射问题^[31]。这些前沿成果为精密光学元件瑕疵检测提供了全新的理论视角:即放弃将神经网络视为纯粹的“黑盒”,转而将瑕疵区域的光学散射规律(如麦克斯韦边界条件)作为显式的物理约束注入模型。这一思路不仅能极大削减由于环境噪声引发的高虚警率,也为本文提出耦合三波段物理特征与麦克斯韦约束的 PINN-Swin-Unet 模型提供了坚实的理论支撑。

含有物理信息神经网络的瑕疵检测方法结合了数据驱动和物理知识的优势,能够在数据不足的情况下实现高精度检测。目前,国内外研究正逐步从纯数据驱动向“数据+物理”双驱动模式转型。同时,其对物理一致性的强调提高了模型的可解释性和泛化能力。但在精密光学元件检测领域,如何针对特定材质的散射特性设计高效的物理损失函数,仍是当前亟需解决的关键科学问题,这正构成了本文进一步研究的出发点。

1.3 主要研究内容

本研究针对光学楔片在精密制造过程中产生的表面微小瑕疵（麻点、划痕、崩边）检测难题，深入探讨了物理成像机理与深度学习算法的融合路径。提出了一种结合物理信息与深度学习的瑕疵检测算法，通过引入三波段物理特征提取模块与电磁边界条件约束，显著提升了模型对低对比度及微尺度瑕疵的检测精度与泛化能力。研究内容主要包括：

（1）构建了基于三波段散射特性的物理信息特征提取模块。本研究利用光学楔片表面瑕疵在不同波段（370–460nm、465–505nm 及 520–610nm）下的物理散射差异，设计了物理信息特征提取模块。该模块突破了传统单通道或灰度图检测的局限，通过全连接层，对三通道光谱信息进行深度融合与权重重分配，提取出能够表征瑕疵物理属性的判别性特征。这一方法增强微小噪声的区分度，为后续特征解析提供了丰富的物理先验信息。

（2）构筑了物理信息驱动的 PINN-Swin-Unet 瑕疵检测架构。本研究选用具备强大全局上下文建模能力的 Swin-Unet 作为基础网络，利用其分层 SwinTransformer 模块及滑动窗口自注意力机制，建立长距离像素间的依赖关系，以应对光学楔片表面细长划痕等瑕疵的非局部关联建模难题。通过在 Swin-Unet 架构中嵌入物理诱导偏置，将其由纯数据驱动模型升级为物理信息深度学习模型，使其在保留 SwinTransformer 捕捉复杂形貌特征优势的同时，能够利用物理规律对预测过程进行约束，显著增强了模型对低对比度及微尺度瑕疵分割的稳定性与鲁棒性。

（3）创新性地设计了基于麦克斯韦方程组的电磁边界约束损失函数 $L_{maxwell}$ 。本研究通过建立数字图像梯度与电磁能量密度 $|E|^2$ 之间的映射关系，将麦克斯韦方程组中的电磁边界条件转化为物理诱导偏置。引入 $L_{maxwell}$ 物理信息损失函数，约束模型预测结果在瑕疵边缘（介质界面）处严格遵循物理场强跳变规律。结合连续性损失 L_{cont} 和背景抑制损失 L_{bg} ，实现了在抑制复杂光学背景噪声的同时，大幅增强对低对比度边缘的提取精度。

（4）开展了系统的对比实验与统计验证。为了全面评估 PINN-Swin-Unet 的性能，本研究构建了包含多种复杂瑕疵的光学楔形片数据集。通过与 Swin-Unet、UNet++、VM-UNet 等类 Unet 家族，先进的工业检测模型 YOLOv13 以及传统 Halcon 算法进行对比分析，并引入 T-检验进行统计显著性验证。结果表明，本算法在 mIoU 和等关键指标上均取得显著提升，并能以 24.5FPS 的推理速度满足工业现场实时在线检测的需求。

（5）围绕光学楔形片的精密几何度量展开研究。针对其微小尺寸和非对称

结构（ 5.5° 楔角、 $0.2\text{mm}\sim 0.45\text{mm}$ 厚度梯度）导致的成像畸变，提出了一套包含基准校准、瑕疵定位与尺寸补偿的完整方法。通过亚像素边缘拟合确立物理坐标系，并利用灰度梯度识别厚度方向；在此基础上，分别构建划痕、崩边和麻点的几何模型，引入倾斜补偿因子修正投影失真，实现微米级尺寸还原与精确定位。实验验证了该方法的有效性，为工业质检中此类特殊元件的自动化检测提供了可靠的解决方案。

1.4 章节安排

本文共分为五章，各章节内容安排如下，本文技术路线图如图 1-2 所示：

第一章，绪论。详细阐述了本课题的研究背景及意义。深入分析了基于深度学习的瑕疵检测国内外研究现状，以及含有物理信息网络的瑕疵检测研究现状。已现有技术为基础，总结现今研究的空白以及本课题的主要研究内容。

第二章，光学楔形片表面瑕疵图像获取方案设计。首先，分析了楔形片表面瑕疵的产生机理并进行分类。其次，结合实际生产需求探讨了楔形结构带来的成像难点。最后，详细介绍了基于暗场照明的三波段图像获取系统硬件设计，通过对相机、镜头及不同波段光源的选型，实现了对微小瑕疵物理散射特征的有效增强。

第三章，基于深度学习的瑕疵检测算法研究。首先，对采集的三波段图像进行预处理并构建数据集，引入复合图像增强策略。其次，详述了 PINN-Swin-Unet 算法的架构设计，阐述了物理信息特征提取模块与跳跃连接的融合机理。最后，推导了基于麦克斯韦方程组的物理约束损失函数，为模型提供物理驱动的归纳偏置。

第四章，光学楔形片表面瑕疵精确定位算法研究。针对楔形片非对称几何结构导致的成像畸变，提出了精密几何度量体系。利用 Zernike 矩算子实现边缘亚像素提取，并通过最小二乘法拟合建立基准坐标系。针对三类典型瑕疵构建了几何评价模型，并引入 5.5° 楔角倾斜补偿因子修正投影失真，实现微米级的尺寸还原与定位。

第五章，实验与分析。本章搭建了实验测试环境，验证了物理约束权重的敏感性并进行了多维度的消融实验。通过与传统 CNN、先进架构及工业软件 Halcon 的对比，评估了 PINN-Swin-Unet 在精度与实时性方面的表现。最后，通过预测掩膜的可视化分析，直观验证了模型对微观瑕疵边缘的还原能力。

在五章内容结束之后总结了全文，随后针对现有不足提出展望，包括提升复杂干扰下的特征解耦能力、进一步优化实时性与轻量化、增强定位基准的鲁棒性，

以及探索重叠瑕疵的细粒度拆解方法。




图 1-2 技术路线图

第二章 光学楔形片表面瑕疵图像获取方案设计



2.1 光学楔形片表面瑕疵检测的特点与需求

2.1.1 光学楔形片表面瑕疵分类

在实际生产中，光学楔形片的瑕疵种类繁多，形状不一。在楔形片的加工过程中，通常需要对光学玻璃进行粗磨、精磨、抛光和镀膜四大基本工序，在这过程中，可能因为操作不当、环境污染或者保存不当等造成各种各样的表面瑕疵。表面瑕疵指抛光加工后的光学元件表面依然存在的麻点、划痕、崩边、开口、气泡、水印、腐蚀印等各种加工瑕疵。这些瑕疵的产生原因主要加工过程和后续的不当操作所导致的^[2]。对于上述瑕疵的检测标准大致有美国军用规范 MIL-PRF-13830B^[32-34]、以及国家标准 GB/T-1185^[35]，这些标准涵盖了产品的质量要求、性能指标、测试方法等各种检测指标。

综合国内外光学元件表面质量检测相关标准及行业标准，并对国内外的文献进行了广泛的审查。本文挑选了最具代表性，且生产过程中最易出现的三种表面疵病——麻点、划痕、崩边。针对此三类表面瑕疵的分类如表 2-1 所示。

表 2-1 麻点、划痕、崩边形成原因及图像

瑕疵类型	形成原因	瑕疵图片
麻点	(1) 在镀膜过程中，蒸发源受热不均导致熔融态材料产生微小喷溅并凝固在基片表面。清洗工序中残留的化学药剂干涸或空气中的微小液滴、颗粒附着在表面。	
划痕	(2) 在研磨和抛光工序中，磨料粒度不均或混入硬质异物，会在表面留下线状痕迹。	
崩边	(3) 在楔形片的切削、定心磨边等环节，由于光学材料具有较高的脆性，在机械应力冲击下容易在边缘产生局部微断裂。	

2.1.2 关键技术与难点

对于光学楔形片表面的麻点、划痕、崩边的图像获取在以下难点：

（1）楔形几何结构导致的光路偏移与重影干扰

与普通的平行平板玻璃不同，楔形片具有特定的楔角在采用透射或反射式照明时，光线经过两个非平行的表面会产生复杂的折射与多次反射，极易在成像CCD上形成“重影”或背景亮度的非均匀梯度分布。这种由几何结构引起的物理干扰会严重掩盖微小瑕疵（如麻点）的特征，增加了图像预处理的难度。

（2）微米级极小瑕疵与大视场检测的精度矛盾

本研究涉及的麻点等瑕疵尺寸通常在微米级。为了满足工业生产的效率要求，检测系统需具备较大的成像视场。然而，在高分辨率与大视场之间存在天然的物理平衡难题：若分辨率不足，微小瑕疵会在图像中坍缩为单个像素甚至消失；若单纯提升分辨率，则会导致景深变浅，由于楔形片表面存在高度差，边缘区域极易发生离焦模糊，导致成像质量下降。

（3）不同形态瑕疵对光场响应的非一致性

光学楔形片表面的瑕疵类型多样，其物理形貌决定了它们对光的散射与吸收规律截然不同。例如，划痕表现为方向性极强的线性散射，而崩边则呈现出复杂的漫反射特性。在单一波段或单一角度的光源照射下，往往会出现“顾此失彼”的情况——能看清划痕时，崩边的对比度极低。如何针对不同瑕疵的物理特性，设计多光谱、多角度的复合照明方案，是获取高质量特征图像的关键。

（4）透明光学材料表面的极低对比度挑战

光学玻璃具有高透射率和低反射率的物理特性。微小瑕疵与背景之间的光学特征差异极小。在成像过程中，环境杂散光、载物台表面的微小尘埃或震动都可能产生比瑕疵更强的噪声信号。如何在信噪比极低的条件下，通过物理成像手段（如特定波段滤光）人为增强瑕疵与背景的对比度，是本研究必须解决的底层技术痛点。

2.2 瑕疵图像获取总体方案设计

针对光学楔形片表面瑕疵检测中面临的低对比度、微米级瑕疵尺度以及楔形结构引起的光路偏移等成像难题，本研究设计了一套基于三波段光谱特征融合的自动化图像获取方案。该方案遵循“物理特性导向、多光谱特征互补”的核心原则，旨在通过硬件系统的优化组合，最大限度地提升微小瑕疵与背景之间的对比度。

为了获取光学楔形片表面微米级瑕疵的高对比度图像,并为后续深度学习算法提供无损的多光谱物理信息,本文设计了一套基于暗场照明的三波段图像获取系统。如图 2-1 所示,该系统主要由暗场色散模块与数据收集模块两部分协同构成,通过精密的光路编排实现了对瑕疵微弱散射光的捕获与多波段高保真分离。系统整体结构实物图如图 2-2 所示。

(1) 暗场色散模块^[36]。该模块的核心目的在于通过光学干预手段最大化低对比度瑕疵的特征显现。系统采用环形光源以特定倾斜角度对楔形片表面进行斜向照明。根据暗场成像原理,当楔形片表面平整无瑕疵时,入射光主要发生镜面反射,反射光束射向物镜外侧而不进入镜头,此时成像背景呈现极暗状态。而当光束照射到极微小的麻点、划痕或崩边等形态突变区域时,表面形貌的连续性被破坏,光线发生强烈的漫反射与散射。携带瑕疵几何形态与深度信息的散射光垂直向上,被物镜精准收集。物镜将这些微弱的散射光场初步放大后,传递至色散管镜。色散管镜利用光学色散效应,对不同波长光线的轴向折射率差异进行控制与补偿,确保多波段光束在后续光路传输中保持良好的准直性,为后端的高分辨率分光与多焦面成像奠定基础。

(2) 数据收集模块。该模块承担着将混合散射光按光谱波段精准剥离并分别成像的关键任务,其核心分光器件为二向色镜^[37]。二向色镜表面镀有特殊的干涉膜,能够实现对特定波长光线的“高反”与“高透”。携带着全频带疵病信息的混合光束进入收集模块后,分光流程如下:

1) 一级分离:从照明系统出射的复合光束首先入射到第一块二向色镜上。根据镀膜的光谱特性,这块二向色镜会将某一特定波段的光束反射到右侧光路,其余波段的光则继续向上透射。为了把整机尺寸控制得更为紧凑,我们在右侧光路中加装了一块全反射棱镜,将反射光束折转 90° 后再引向上方,从而使其顺利进入后续的右侧支路。

2) 二级分离:经过一级分光后向上传播的剩余光束,紧接着到达第二块二向色镜。在这里,第二种特定波段的光束被反射到左侧光路,而剩下的第三种波段的光束几乎不受干扰地直接穿过二向色镜,沿着正上方方向继续行进。至此,三个波段的相互独立的通道已完全分离。每一路光束随后分别经过各自对应的聚焦管镜,这些管镜的作用是把发散的平行光精确地会聚到三台高分辨率工业相机的感光靶面上。最终,三个相机(探测器 1、2、3)各自接收一个特定波段的图像信号,为后续的物理信息特征提取提供了稳定、可靠的光谱数据。




图 2-1 图像获取系统设计




图 2-2 系统整体结构实物图

通过上述暗场诱导与二向色镜物理分光机制，本系统能够通过单次曝光，同步获取同一物理视野下楔形片在三个独立波段（紫外、绿光、黄光）的高对比度暗场散射图像。这种硬件层面的纯物理分光架构，不仅从根源上避免了传统彩色相机 Bayer 滤光片插值算法带来的空间分辨率损失与色彩串扰度分布^[38]。这为第三章中物理信息特征，更完整保留了微观瑕疵在不同波长下最原始的光学能量梯提取模块进行跨光谱特征映射与物理规律解耦，提供了高质量的硬核物理数据源。

2.3 三波段获取瑕疵图像

2.3.1 工业相机和镜头的选择

在光学楔形片表面瑕疵检测系统中，硬件选型的核心目标是确保能够清晰捕捉微米级的微小瑕疵，同时兼顾一定的成像视场以提高检测效率。

(1)工业相机选型

考虑到楔形片表面瑕疵特征极其细微，本研究选用海康机器人（HIKROBOT）生产的 MV-CS040-A0UM 高速单色工业相机。该相机采用先进的 CMOS 感光芯片，具备 2048×2048 的正方形分辨率（400 万像素），非常适合配合光学物镜进行圆形或方片状光学元件的成像。其核心优势在于 5.5μm×5.5μm 的大像元设计。相比于小像元相机，较大的感光面积能够显著提升单位时间内的摄光量，从而在检测透明玻璃表面的微弱散射信号时，具备更高的信噪比和更宽的动态范围。此外，该相机在全分辨率下最大帧率可达 90.1fps，配 30μm~10sec 的宽泛曝光调节，能够灵活适应不同波段光源下的亮度差异。相机的具体性能指标如表 2-2 所示。

表 2-2 相机的具体性能指标

参数	规格及指标
相机型号	MV-CS040-A0UM
分辨率	2048×2048
像元尺寸	5.5μm×5.5μm
帧率	90.1fps
数据接口	USB3.0

(2)镜头选型与性能分析

针对楔形片表面微米级瑕疵的放大需求，本研究选用 OlympusPlanN4x（RMS4X）平场消色差物镜如图 2-3 所示。



图 2-3 OlympusPlanN4x（RMS4X）实物图

该镜头具有 4×放大倍率，数值孔径（NA）为 0.10。选用该组合的物理依据及计算如下：

图像采集系统的物方分辨率 σ （即图像中单个像素所代表的实际物理尺寸）由相机像元尺寸 s 与光学放大倍率 β 决定，公式如下：

$$\sigma = \frac{s}{\beta} = \frac{5.5\mu m}{4} = \frac{1.375\mu m}{pixel} \quad (2-1)$$

经计算，本系统的物方分辨率为 1.375 μm /pixel。对于本研究涉及的微米级瑕疵，如直径在 3-5 μm 左右的麻点，在图像中可占据约 2-4 个像素。根据奈奎斯特采样定律，为了可靠地识别一个特征，其采样频率至少应为特征频率的 2 倍。本系统的分辨率确保了微米级瑕疵不会因采样不足而发生空间混叠，能够保留瑕疵的形态特征。

Olympus4x 物镜的平场设计能够有效校正像面边缘的模糊，确保在 2048×2048 像素范围内画质均匀。同时，1.375 μm /pixel 的分辨率在满足精度的前提下，提供了约 2.8mm×2.8mm 的单幅成像视场，兼顾了微观检测精度与宏观采集效率。通过上述相机与镜头的优化组合，系统构建了一个高灵敏度、高帧率的成像链路，为后续章节中多波段图像的物理特征提取奠定了坚实的数据基础。

2.3.2 光源和照明方式的选择

在光学表面微米级疵病的检测中，由于光学楔形片表面平整度极高，传统的明场同轴照明会产生强烈的镜面反射，导致微小瑕疵淹没在极亮背景中，对比度极低。为了克服这一光学瓶颈，本系统采用了暗场照明方式。暗场照明的核心逻辑是利用特定倾角的光束斜射被测表面：正常平整区域的反射光将偏离镜头视场，使图像背景呈现暗态；而瑕疵区域由于表面形貌的不连续性，会产生漫反射与散射，这部分向上的散射光被物镜收集，从而在极暗的背景下形成高亮的瑕疵特征，最大化地提升了微小瑕疵的信噪比。

为实现高质量、高均匀性的暗场照明效果，本研究最终选用了型号为 UST-RIL741560W-24V 的高亮度 LED 环形光源。该光源的三维结构图如图 2-4 所示。




图 2-4 环形光源结构示意图




图 2-5 环形光源工程参数图

该环形光源采用了紧凑的精密加工外壳，其外径为 74mm，总高度为 27mm。光源顶部安装孔径为 36mm，出光口内径为 53mm。这种中空的结构设计，使其能够无缝套接于暗场色散模块的物镜外围，既节省了系统的纵向空间，又保证了光源与物镜光轴的高度同轴。此外，光源顶部均布了 4-M3 深度为 4mm 的安装螺纹孔，便于与视觉检测平台的 Z 轴升降机构实现高刚性连接，避免了运动过程中的光源抖动。

构建暗场环境的关键在于入射光的角度控制。UST-RIL741560W-24V 内部的发光阵列呈截锥形分布，其内壁发光面倾角被精确设计为 60°。这一大角度斜射光路设计，使得入射光以极大的入射角掠射楔形片表面。根据光路追踪分析，该

角度的镜面反射光将完全落在物镜的数值孔径接收范围之外，而瑕疵产生的微弱散射光则能有效向上传播进入色散管镜。这种结构从物理硬件层面为后续的分波段分离提供了纯净、无耀斑的光学本底。

2.3.3 不同波段下瑕疵敏感度分析

麻点类瑕疵通常表现为微小的表面凹坑或点状瑕疵，其特征是尺寸微小且深度有限。较短波长具有更强的散射能力，对微观表面结构更为敏感，因此能更清晰地呈现精细的表面形貌和微观特征。在紫外蓝光照射下，麻点的阴影与反射变化更为显著，有助于算法检测。卢荣胜^[39]等人所述，紫外光相较于可见光和近红外光具有更优的散射特性。当可见光或近红外波段成像效果不佳时，紫外光能生成相对清晰的图像。此外，短波紫外光与颗粒物的散射相互作用更强。因此，采用 370nm-460nm 纳米紫外光获取的图像能捕捉到麻点类瑕疵更丰富的物理特性。

对于划痕的检测，采用 465nm-505nm 纳米蓝绿色光谱带进行采集。划痕构成的线性表面损伤通常会引起表面反射的方向性改变。蓝绿色光谱带在表面反射与散射效应之间实现了最佳平衡——它能增强形态学差异，同时避免对短波紫外线特有的表面粗糙度过度敏感。该光谱区域对微观形貌变化尤其对于划痕具有优异的响应性，从而增强了划痕与背景之间的对比度。

最后，崩边类型的瑕疵属于大规模结构瑕疵，通常表现为边缘缺口或裂纹。与尺寸极小的麻点和不规则划痕相比，这类瑕疵通常更容易被检测到。罗茂^[40]的实验发现表明，在波长超过 550nm 时，可检测到的微瑕疵数量显著减少，这说明在此光谱范围内获取的图像能有效过滤掉微小瑕疵的信息。基于这一特性，本文采用 520nm-610nm 波段进行图像采集。这种波长范围能有效过滤麻点和划痕等比崩边更微小的瑕疵，从而突出崩边瑕疵的物理特征，同时最大限度减少其他瑕疵类型的干扰。

为了进一步确证前述不同光学波段在捕捉表面瑕疵时的响应差异，本研究设计了定量的图像对比分析方案。在保持成像系统视野严格对齐的前提下，系统地采集了特定目标区域在多种单一入射波长照射下的图像序列。研究的核心在于深入挖掘这些视觉图像中的灰度分布演变规律，通过提取瑕疵本身及其周边背景的像素级灰度波动差异，客观推演出目标瑕疵对不同波长光照的具体敏感度。

考虑到瑕疵光学表现形式的多样性与复杂性，单一测度往往难以全面反映实际情况。因此，本研究所构建的敏感度评价体系融合了四项关键的图像特征：用于反映灰度变化剧烈程度的梯度强度、表征瑕疵在局部背景中凸显情况的局部对比度、体现目标物理轮廓细节的边缘密度，以及衡量其微观形貌特性的纹理清晰

度。在数据合成阶段，为保证综合评估的客观性与鲁棒性，避免单一特征的过度主导，模型采取了等权重的线性组合策略。即上述四项计算指标在总敏感度得分中均严格占据 25% 的比重，从而得出一个能够全面、稳定反映波段敏感性差异的量化数值。具体而言，梯度强度通过 Sobel^[41]算子计算 x 和 y 方向的梯度幅值获得；局部对比度通过计算 15×15 邻域窗口内的局部方差和平方差来量化局部区域的灰度变化；边缘密度通过 Canny^[42]算子检测边缘像素占总像素的比例确定；纹理清晰度指标则基于拉普拉斯方差响应幅度评估图像锐度^[43]，其中较高方差值表示图像更锐利且纹理细节更明显，较低方差值则对应模糊图像。




图 2-6 不同入射波长下麻点瑕疵的光谱敏感性分析

图 2-6 结果显示，麻点瑕疵在 370nm-460nm 波段呈现峰值敏感度，而对于波段区间在 520nm-610nm 的敏感度低。对于麻点类型瑕疵，其最敏感波段区间的敏感度比最不敏感波段区间高出 42.2%。图 2-7 数据表明，划痕瑕疵在 465nm-505nm 波段区间内达到最大敏感度，而在 520nm-610nm 波段区间灵敏度最低。划痕类型瑕疵的最高波区间敏感度比最低波段高出 85.8%。上述实验表明，当利用 520nm-610nm 波段获取的崩边类瑕疵的物理特征时，能有效抑制麻点、

划痕以及微小粉尘的干扰。通过针对不同瑕疵类型在不同光谱波段进行特征提取，可实现深度学习模型以获取更丰富、更深层次的高维信息。




图 2-7 不同入射波长下划痕瑕疵的光谱敏感性分析

2.4 本章小结

本章针对光学楔形片表面微小疵病对比度低、成像干扰大等难题，设计并搭建了一套基于三波段暗场成像的图像获取系统。针对麻点、划痕与崩边三类典型表面瑕疵，明确了楔形几何结构带来的重影干扰、微米级尺度与大视场的精度矛盾，以及透明材料极低对比度等底层光学挑战，为后续系统设计确立了目标。选用 60°大倾角 LED 环形光源构建高质量暗场照明，从物理层面压制了背景噪声；搭配 4 倍平场消色差物镜与大像元高速工业相机，实现了 1.375 $\mu\text{m}/\text{pixel}$ 的高物方分辨率，确保微观瑕疵在成像时具备充足的像素支撑。引入了二向色镜物理分光机制，并定量验证了不同波段对特定瑕疵的增强效果。实验结果表明，370nm-460nm 波段对麻点最为敏感，465nm-505nm 波段能有效增强划痕特征，而 520nm-610nm 波段则能突出崩边瑕疵并过滤微小粉尘干扰。

综上所述，本章搭建的光学成像硬件系统从物理层面上成功实现了瑕疵的高对比度显现与特征解耦，彻底避免了单色盲区与软件滤光的精度损失，为下一章基于深度学习模型的多波段物理特征融合提供了高质量的原始数据支撑。

第三章 基于深度学习的瑕疵检测算法研究

在第二章构建的三波段光学成像方案的基础上,本章旨在针对光学楔形片表面微米级麻点、划痕及边缘崩边这三类瑕疵,提出一种耦合物理信息与深度学习特征的检测算法体系。传统纯数据驱动的卷积神经网络在面对对比度极低且尺度极小的瑕疵时,往往存在泛化能力差、特征提取不充分等瓶颈。为此,本章提出了一种含有物理信息偏置的深度学习模型——PINN-Swin-Unet。该算法的核心逻辑在于:利用第二章获取的三波段光谱图像作为高维输入,通过设计物理信息特征提取模块(Physics-Informed Feature Extraction, PIFE),将瑕疵在不同波段下的物理散射特性编码并嵌入至神经网络的跳跃连接层中;同时,引入基于电磁场边界条件的物理诱导偏置,通过构建物理约束损失函数,引导模型学习瑕疵区域的能量梯度分布规律。

本章将从以下三个维度展开详细论述:首先,介绍基于实测样本构建的三波段瑕疵数据集及其预处理流程;其次,详述 PINN-Swin-Unet 算法的骨干架构及 PIFE 物理模块的实现原理;最后,阐述如何将麦克斯韦方程组启发下的物理约束融入损失函数。

3.1 数据集构建

训练高精度检测模型的核心前提是构建一个兼具高可信度与形态多样性的样本库。本文采集并构建了涵盖划痕、麻点与崩边三类典型瑕疵的工业数据集。实验数据源自福特科光学股份有限公司的光学楔形片生产线:通过 EtherCAT 工业以太网协议驱动三轴运动平台,并在控制 Z 轴电机进行精密对焦补偿的同时,实现了采集触发与运动坐标的毫秒级同步,最终由海康威视工业相机 MV-CS040-A0UM 捕获分辨率为 2048×2048 像素的原始图像。

3.1.1 数据集标注

在完成原始图像采集后,为了满足 Swin-Unet 语义分割网络对像素级监督信号的需求,本文制定了严格的标注流程与数据封装协议。采用开源标注工具 LabelMe 对 716 张三波段原始图像进行手工标注。标注过程由五名经过专业培训的质检人员独立进行,并交叉校验以消除主观判定误差。

标注的 716 张原始图像共包含 8,917 个标注瑕疵实例,具体标注图如图 3-1 所示,各实例数量如表 3-1 所示。其中麻点 7287 例、崩边 1095 例、划痕 535 例。统计分析表明数据集存在极度的类别不均衡现象,其中麻点类瑕疵实例高达

4924 个，占比约 81.7%，而划痕类瑕疵仅有 362 个，占比不足 6%。这种显著的长尾分布特性会导致模型在训练过程中过度关注多数类样本，严重抑制对少数类关键瑕疵特征的学习。此外，原始图像中微小瑕疵的像素占比极低，直接输入网络容易导致特征在下采样过程中丢失，因此必须通过特定的预处理与增强策略来优化数据分布。




图 3-1 标注图

表 3-1 瑕疵种类实例统计

瑕疵类别	实例数量	图像总数	主要挑战指标
		(具有该类瑕疵即记入)	
麻点	7287	680	微小，模糊,局部环境噪声
划痕	535	253	低对比度,细长形几何
崩边	1095	479	边缘干扰,形态不规则
总计	8917	716	类别分布极度不均衡

3.1.2 数据增强

针对前述数据集存在的样本规模有限、类别分布极度失衡以及微小瑕疵语义特征不明显等瓶颈问题，本研究设计了一套在线数据增强与实例级混合增强相结合的预处理策略^[44]，旨在提升 Swin-Unet 模型在复杂工业背景下的泛化性能与鲁棒性。

为了增强模型对光学成像过程中随机噪声的抗干扰能力,训练过程中引入了像素级的环境扰动算子^[45]。通过引入高斯模糊^[46]与色彩扰动^[47],模拟传感器热噪声、光学系统色散及工厂照明波动的极端情况。这一策略迫使 Swin-Unet 的 Transformer 架构在特征提取过程中,不仅依赖局部的颜色强度,更需学习瑕疵区域与其邻域之间的深层纹理梯度特征。

在图像级增强方面,本研究采用了概率为 1.0 的 Mosaic 增强策略^[48]。该方法通过将四张训练图像进行随机缩放、裁剪与拼接,将不同尺度、不同背景下的瑕疵实例强制耦合在同一采样视场中。这不仅显著增加了批次数据的空间语义多样性,还通过改变瑕疵在图像中的位置,缓解了 Swin-Unet 对特定坐标偏移的过拟合风险。

针对划痕瑕疵样本稀缺的问题,本研究引入了实例级 Copy-Past 与 Mixup 策略。Copy-Paste 策略(概率为 0.8)利用标注阶段获取的像素级掩膜,将少数类瑕疵(如细长划痕)从原始背景中精确剥离,并随机“粘贴”至其他正常或含有瑕疵的图像中。这种方式人为地提升了稀有瑕疵在训练流中的出现频率,有效纠正了损失函数在优化过程中产生的类别偏置。Mixup 策略(概率为 0.2):通过对两张图像及其对应的标签掩膜进行线性插值,扩大了模型的决策边界,增强了系统处理重叠瑕疵或复杂混叠背景时的分割精度。

此外,结合自动增强技术^[49]与概率为 0.4 的随机擦除^[50],模拟工业现场可能存在的遮挡或局部过曝情况,进一步挖掘模型对残缺物理特征的补全能力。

为了确保模型能够从增强后的多样化分布平滑过渡到真实物理分布,本研究采用了动态训练策略:在训练过程的最后 10 个 Epoch 自动关闭 Mosaic 等剧烈增强操作。这一机制引导 Swin-Unet 在微调阶段回归真实的数据分布,避免过度扭曲的增强图像干扰最终的边界分割精度。通过上述复合预处理流程,原始的 716 张样本图像被动态扩充为具有高度物理代表性的训练数据流,为后续高精度检测算法的研究奠定了坚实的数据基础。

3.1.3 数据集划分

由于本研究采用的 Swin-Unet 架构在训练阶段通常采用高效的二进制序列化存储方案,因此需要将原始图像与对应的标签掩膜转换为 .npz 格式。考虑到 2048×2048 像素的原始尺寸对显存压力较大,本研究将大图切分为 512×512 或的局部块,以适配 Swin-Unet 的窗口注意力机制。最后利用 NumPy 库将图像数组与掩膜数组封装至同一个 .npz 文件中。这种存储方式不仅能显著提升磁盘 I/O 读取效率,还能确保图像像素与标注信息在随机打乱过程中保持严格的一致性。将

第二章获取的三波段图像沿通道维度进行堆叠，形成高维特征张量。

经过格式转换后，最终生成了包含三波段物理信息的.npz 样本库。按照 8:1:1 的比例将其划分为训练集、验证集与测试集。其中训练集用于模型参数的梯度更新，验证集用于调整 Swin-Unet 的超参数，而测试集则用于最终评估模型对光学楔形片表面瑕疵的泛化检测精度。

3.2 PINN-Swin-Unet 网络总体架构设计

3.2.1 Swin-Unet 基准算法简述

针对光学楔形片表面瑕疵的语义分割任务，本研究选用 Swin-Unet 作为基础算法框架，其框架图如图 3-2 所示。为了克服传统卷积神经网络在处理长距离依赖关系和全局空间信息时的局限性，Swin-Unet 是一种完全基于 Transformer 构建的对称 U 型架构。Swin-Unet 的编码器部分由一系列 SwinTransformer 模块^[51]组成。与传统 VisionTransformer^[52]不同，SwinTransformer 引入了层级化架构，通过 PatchMerging^[53]操作逐渐降低特征图的分辨率并增加通道数。这种设计模拟了 CNN 的感受野扩大过程，使模型能够同时捕捉麻点的局部细节特征与划痕的长距离空间上下文信息。

考虑到传统 Transformer 在处理高分辨率图像时面临的庞大计算开销，本文选用了基于局部窗口自注意力机制的 Swin-Unet。该网络将输入图像切割为若干非重叠窗口，将原本呈平方级暴涨的计算复杂度强行压降至线性水平。当然，单纯的局部划分难免会割裂全局信息，为此，网络中特有的移位窗口机制发挥了关键作用。这种在相邻网络层间交替错位的处理手法，如同搭桥一般打通了跨窗口的信息流，从而牢牢抓住了全局语义的连贯性。这对于捕捉光学楔形片上那些形态跨度较大的细长划痕或大面积崩边尤为关键。

在特征重建阶段，解码器沿用了完全对称的 Transformer 架构，并依赖补丁扩展层逐级恢复空间分辨率。为了防止微米级瑕疵的边缘细节在深层网络中被抹平，算法保留了 U-Net 经典的跳跃连接策略。通过在通道维度上直接“拼接”浅层的高分辨率特征与深层的抽象语义，网络成功找回了下采样途中丢失的空间位置线索，大幅收窄了疵病边界的定位误差。整体而言，Swin-Unet 赋予了系统动态锁定低对比度微小瑕疵的敏锐度，这不仅完成了基础的视觉特征提取，更为后续无缝植入物理信息约束、最终成型 PINN-Swin-Unet 模型搭建了极具扩展性的底层架构。




图 3-2 Swin-Unet 框架图

3.2.2 PINN-Swin-Unet 改进策略概述

虽然 Swin-Unet 基准算法在处理长距离空间依赖方面展现出显著优势，但对于光学楔形片表面对比度极低、尺度极其微小的瑕疵，单纯依靠数据驱动的卷积或自注意力机制往往难以从复杂的背景纹理中精准解耦瑕疵特征。此外，传统模型忽略了光学成像背后蕴含的物理特征，导致其在面对不同光照条件或镀膜环境时的泛化能力受限。

为此，本文提出了一种物理信息启发式 PINN-Swin-Unet（Physics-Informed Swin-Unet）模型。该模型的改进策略核心在于将光学成像的物理先验知识深度融入深度学习的特征提取与参数优化过程中，构建“物理-数据”双驱动的检测范式。改进策略主要分为以下两个维度展开：

（1）多波段物理信息特征提取模块集成针对第二章构建的三波段成像系统，改进算法不再将多光谱图像视为简单的颜色通道堆叠，而是通过 3.3 节设计的物理信息特征提取模块，提取不同波段下瑕疵的散射能量分布差异。该模块利用物理演化算子对输入张量进行预处理，并将提取到的物理特征通过改进的跳跃连接层^[54]注入 SwinTransformer 块，从而在模型底层增强瑕疵特征与背景噪声的区分

度。

(2) 基于物理一致性的约束损失函数构建为了使网络学习到的语义分割图符合光学成像的物理逻辑, 本研究改变了以往仅依赖交叉熵或 Dice 损耗的优化方式。在 3.4 节中, 将重点论述如何构建物理约束损失函数。该策略通过引入电磁散射梯度的物理偏差项, 对预测掩膜的边缘连续性与能量强度进行约束, 迫使模型在反向传播过程中遵循物理一致性原则。这种约束机制能够有效修正由于离焦或噪声引起的虚警, 确保模型在复杂工况下的稳健收敛。

通过上述“架构-目标”双重维度的改进, PINN-Swin-Unet 不仅继承了 Transformer 的全局建模能力, 更具备了对光学物理过程的感知力, 为实现高精度、强泛化的瑕疵检测奠定了理论与算法框架。

3.3 物理信息特征提取模块

3.3.1 三波段瑕疵物理信息特征提取

为了充分挖掘光学楔形片瑕疵在不同光谱波段下的物理散射差异, 本研究设计并实现了一个名为物理信息特征提取 (Physical Information Feature Extraction, PIFE) 的专用神经网络模块。该模块作为 Swin-Unet 主干架构的并行分支, 通过端到端的联合训练方式, 将高维光谱物理先验深度嵌入至语义分割任务中。

PIFE 模块的设计核心在于对多源信息的独立解耦与跨光谱融合。如图 3-3 所示, 该模块构建了三个平行的特征提取分支, 分别对应第二章所述的三个特定波段图像。输入图像分辨率统一定义为 1024×1024 。不同波段的光线在经过楔形片表面的划痕、麻点或崩边时, 受限于瑕疵的深度与粗糙度, 会产生差异化的散射分布。三个独立分支能够使模型可以分别捕捉各光谱下瑕疵特有的反射强度梯度与形态分布属性, 从而实现对瑕疵特异性物理属性的跨光谱学习。

为了在特征投影过程中避免空间结构信息的丢失, PIFE 模块采用了基于 1×1 卷积运算的类全连接架构, 而非传统的扁平化全连接层。FC3 融合层将三个特征分支提取到的原始响应在通道维度进行拼接, 并由 FC3 模块进行初步的跨通道交互与非线性融合。接收高维融合特征后, FC4 通过 1×1 卷积进行线性变换。在保持空间分辨率一致的前提下, 该层有效消除了多波段数据间的冗余信息, 提取出紧致的高层次表征。最后 FC5 任务映射层负责将抽象的物理特征映射至特定的输出空间, 生成与 Swin-Unet 跳跃连接层通道维度完全匹配的特征图。

在集成策略上, PIFE 模块生成的物理特征图并不直接参与最后的分类, 而

是作为跳跃连接层的辅助补偿特征。通过与 Swin-Unet 下采样路径获得的图像特征进行逐像素融合，PIFE 编码的物理分布知识能够引导解码器更准确地重建微小瑕疵的边缘。这种设计确保了模型即便在单波段对比度极低的情况下，仍能依靠 PIFE 提供的跨光谱物理证据实现精确分割。




图 3-3 物理信息特征提取模块

本文对 FC3 像素级特征融合机理进行进一步的阐述。在特征聚合阶段，PIFE 模块通过 FC3 层实现跨波段信息的深度耦合。设三波段分支提取的原始特征图序列为 $\{F_{UV}, F_G, F_Y\} \in H \times W \times C$ 其中 H, W 分别为特征图的高与宽, C 为单个分支的通道维度。FC3 的融合过程可由式（3-1）表达：

$$F_{fuse} = \sigma(W_{fc3} * [F_{UV} \oplus F_G \oplus F_Y] + b) \quad (3-1)$$

其中， $\oplus$ 表示沿通道轴的拼接操作，将输入维度扩充为 $3C$ ； W_{fc3} 代表 1×1 卷积核的权重矩阵， b 为偏置项； $*$ 为卷积运算； σ 为非线性激活函数 ReLU^[55]。

这种设计的核心逻辑在于：利用 1×1 卷积核在空间坐标上的“探针”特性，对同一像素位置在不同波段下的物理响应进行线性加权与非线性映射。相比于简单的逐元素相加，该机制允许模型自动学习不同波段特征的权重系数。例如，若划痕在 UV 波段表现出更高的信噪比，模型通过反向传播会自发增大该波段对应的权值权重，从而在融合特征 F_{fuse} 中强化关键瑕疵信号。

3.3.2 补充物理信息的跳跃链接

在标准 Swin-Unet 架构中，跳跃链接的主要作用是将编码器提取的高分辨率浅层特征直接传递至解码器，以弥补下采样过程中造成的空间位置信息损失。然

而，对于光学楔形片表面极低对比度的瑕疵，单纯依靠图像纹理特征往往难以在复杂的背景中维持足够的辨识度。为了克服这一瓶颈，本研究对传统的跳跃连接进行了物理增强，设计了补充物理信息的跳跃连接机制。其核心逻辑是将 3.3.1 节中 PIFE 模块提取的跨光谱物理特征，作为一种物理先验约束注入主干网络的特征流中。如图 3-4 所示，物理信息的融合并非简单的像素叠加，而是一个多维特征的重塑过程。




图 3-4 PIFE 模块增强跳跃连接与补偿瑕疵物理特征的 Swin-Unet

首先，Swin-Unet 编码器在对应的下采样层级提取出空间纹理特征 F_{enc} ；同时，PIFE 模块通过多波段分支生成的物理特征图 F_{phys} 。为了实现二者的有效对齐，本研究采用拼接融合，拼接融合公式如式（3-2）所示：

$$F_{fused_{skip}} = Conv_x^{1 \times 1}([F_{enc} \oplus F_{phys}]) \quad (3-2)$$

其中， $\oplus$ 表示通道维度的拼接。通过 1×1 卷积操作，模型能够在保留像素空间位置的同时，自动学习物理特征与纹理特征之间的相关性权重。这种融合表征作为跳跃连接层的补充信息，被整合到 Swin-Unet 的跳跃连接层中，PIFE 模块提供的额外瑕疵物理信息与原始跳跃连接特征融合为补充特征。这些补充特征保持与原始跳跃连接特征相同的空间分辨率和通道维度，随后进行特征加权融合，融合后的特征图在网络上采样过程中被传递至编码器阶段。

在光学楔形片的实际检测中，微米级麻点等细小瑕疵在图像中通常仅占据数个像素。这类微弱特征在经过主干网络的多层下采样与卷积操作后，极易被过度平滑甚至完全丢失。为了克服这一特征消失瓶颈，本研究利用 PIFE 模块提取包含丰富高频细节的物理特征图。这些特征图通过改进的跳跃连接，直接跨越编码器的深层网络，无损传递至解码器的特征重建阶段。该机制实质上为解码器提供了一套精确的像素级空间定位基准。在还原瑕疵边缘时，网络不再仅仅依赖高度抽象的深层语义信息，而是能够同步参考局部区域原始的物理散射能量分布。此外，考虑到楔形片表面多层镀膜或加工纹理在不同光谱下的反射往往具有特定的物理规律，PIFE 模块提取的跨光谱特征能将带有物理先验的特征与编码器特征进行融合，可以显著抑制环境随机噪声造成的干扰，大幅提升模型对极细微划痕等低对比度瑕疵的识别鲁棒性。

在网络训练阶段，上述设计实现了物理模块与主干架构的端到端联合优化。PIFE 模块输出的物理信息不再作为静态的孤立辅助通道，而是被深度内化到整个深度学习模型的参数更新闭环中。具体而言，在反向传播过程中，解码器计算得出的梯度误差信号能够沿着增强后的跳跃连接，同步回传至 Swin-Unet 主干编码器与并行的 PIFE 模块。这种双向反馈路径构建了一种协同演化机制。在该机制的引导下，模型能够自适应地调整网络权重，寻找“纯数据驱动”的图像纹理特征与“物理启发”的多光谱光学特征之间的最佳平衡点，最终生成与 Swin-Unet 拓扑结构完全对齐的深度融合特征张量。

综上所述，引入物理信息后的跳跃连接突破了传统 U 型网络中简单的特征拼接功能，演变为了一个具备物理感知与鉴别能力的特征增强中枢。这一架构级的改进有效弥补了纯数据驱动模型在微观特征提取上的不足，为后续解决光学楔形片瑕疵检测中长期存在的高虚警率与高漏检率难题，提供了关键的技术支撑。

3.4 物理约束损失函数构建

为提升模型的物理可解释性与泛化能力，本文创新性地设计了一种基于物理信息的损失函数，该函数在训练过程中起到归纳偏置的作用。本文没有依赖定性类比，而是从电磁散射理论及介质界面处波的行为中明确推导出这些约束条件。

3.4.1 麦克斯韦方程组与散射机理简述

本研究提出的物理约束损失函数，其核心灵感源于经典电动力学中的麦克斯韦方程组^[56]。在光学楔形片表面瑕疵检测中，光线与楔形片表面瑕疵的交互本质上是电磁波在非均匀介质中的散射过程。麦克斯韦方程组的微分形式如式(3-3)：

$$\left\{ \begin{array}{l} \nabla \cdot \mathbf{E} = \frac{\rho}{\epsilon^0} \\ \nabla \cdot \mathbf{B} = 0 \\ \nabla \times \mathbf{E} = -\frac{\partial \mathbf{B}}{\partial t} \\ \nabla \times \mathbf{B} = \mu^0 \left(\mathbf{J} + \frac{\epsilon^0 \partial \mathbf{E}}{\partial t} \right) \end{array} \right. \quad (3-3)$$

其中, $\mathbf{E}$ 和 $\mathbf{B}$ 分别表示电场和磁场。当入射光波接触到光学楔形片表面的微米级瑕疵时, 由于瑕疵区域与正常区域的折射率存在不连续性, 会导致电磁场边界条件发生突变。

受此启发, 瑕疵在图像中呈现的亮度梯度分布并非随机, 而是遵循电磁波在边界处的能量守恒与相位演化规律。传统的损失函数仅关注像素值的统计分布, 忽略了这种空间梯度上的物理一致性。因此, 本研究通过引入麦克斯韦方程组启发的梯度约束, 迫使网络学习符合物理散射规律的瑕疵特征。

3.4.2 物理约束复合损失函数设计

本文设计的复合损失函数首先引入了受麦克斯韦方程启发的三项约束条件, 这三项约束条件分别是: 基于能量密度梯度奇点的边界约束; 内部均匀性约束; 背景抑制约束。

(1) 基于电磁能量密度的边界约束 (L_{maxwell})

首先, 本文建立所捕获图像与物理场之间的数学联系如式 (3-4) 所示。其中 I 传感器记录的图像强度, 即成像系统采集到的光强信号。 S 表示电磁能流密度, 即单位时间内通过单位面积的电磁能量。 E 为光波电场强度的幅值。 ϵ 为介质的绝对介电常数, 反映材料在电场作用下的极化特性。 μ 为介质的绝对磁导率。传感器记录的图像强度 I 与坡印廷矢量 S 的时间平均幅度成正比, 而坡印廷矢量 S 与电场振幅 E 和介质阻抗 η ($\eta = \sqrt{\mu/\epsilon}$) 相关:

$$I \propto \langle |S| \rangle \propto \sqrt{\frac{\epsilon}{\mu}} |E|^2 \quad (3-4)$$

因此, 图像强度 ∇I_i 的空间变化可直接反映电磁能量密度的空间变化。诸如划痕和缺损之类的瑕疵本质上代表了两种介质 (介电常数为 ϵ_1 的玻璃和介电常数为 ϵ_2 的空气) 之间的边界。根据麦克斯韦边界条件, 电位移场 $\mathbf{D}$ 的法向分量必须在界面上连续 (假设没有自由表面电荷):

$$\hat{n} \cdot (\mathbf{D}^1 - \mathbf{D}^2) = 0 \Rightarrow \epsilon_1 E_{1\perp} = \epsilon_2 E_{2\perp} \quad (3-5)$$

由于 $\epsilon_1 \neq \epsilon_2$ ，电场 $E_{\perp}$ 的法向分量在瑕疵边界处必须经历一个突变。这种物理场的不连续性需要能量密度($|E|^2$)的急剧梯度，因此，图像强度梯度 ∇I_i 也会出现跳变。为了对这一理论推导进行实证验证，本文对数据集进行了统计 t 检验^[57]（见图 3-5）。结果（ $T=180.55$, $p<0.001$ ）证实，瑕疵边界处的梯度幅度显著高于非瑕疵区域。基于此，如公式 3-6 所示本文定义了 $L_{maxwell}$ 约束，以严格满足梯度不连续性要求：

$$L_{maxwell} = \frac{1}{N} \sum_{\{i \in edge\}} (\nabla I_i - \nabla P_i)^2 \quad (3-6)$$

在公式(3-6)中， ∇I_i 表示通过 Sobel 算子计算得到的原始图像在像素 i 处的梯度， ∇P_i 表示模型预测概率图在像素 i 处的梯度， $edge$ 表示真实边界的掩码区域。该损失函数约束模型预测的边界与原始图像中实际的亮度变化相一致，增强了边界检测的物理合理性，并强制预测边界与实际的物理散射特征相吻合。该损失函数通过约束模型预测边界，与原始图像实际亮度变化的对齐，既增强了边界检测的物理合理性，又迫使预测边界与实际物理散射特征保持一致。




图 3-5 瑕疵边界处梯度幅值的统计学验证

（2）瑕疵内部连续性约束（ L_{cont} ）

电磁场在均匀介质中呈现连续性与平滑性。由此推论，瑕疵内部（单一介质）应保持相干性与均匀性，避免过度碎片化或突变性高频波动。为减少错误分割并确保类内一致性，本文定义了连续性约束损失如式（3-7）所示。

$$L_{cont} = \frac{1}{C-1} \sum_{C=1}^{C-1} \frac{1}{N_c} \sum_{i \in mask_c} |\nabla P_{\{c,i\}}| \quad (3-7)$$

电场在均匀介质中表现出连续性和平滑性。类似地，在分割任务中，瑕疵内部也应具有连贯性和均匀性，避免过度破碎或突变。在公式(3-7)中， C 表示类别数（本任务中 $C=4$ ）， N_c 表示第 c 类真实掩码所包含的像素总数， $mask_c$ 表示类别 C 的真实掩码， $\nabla P_{\{c,i\}}$ 表示像素 i 处类别 C 的预测概率图的梯度。该损失函数约束模型在同一瑕疵类别内生成平滑的预测结果，从而减少错误分割。

（3）背景抑制约束（ L_{bg} ）

抑制背景干扰。根据能量最小化原理，背景通常由低能量（低亮度）区域构成。亮度值低的区域被视为“无场”区域，模型训练权重在这些区域会降低。在公式（3-8）中， I_i 表示归一化图像亮度， $P_{bg,i}$ 表示像素被预测为背景的概率。该损失函数约束模型在暗背景区域中将检测目标预测为非背景概率。

$$L_{bg} = \frac{1}{N} \sum_i (1 - I_i) \cdot (1 - P_{bg,i})^2 \quad (3-8)$$

（4）总损失函数（ L_{total} ）

基于物理约束的总损失函数，即上述三个损失函数的加权组合，如式（3-9）所示：

$$L_{physics} = \lambda_{maxwell} L_{maxwell} + \lambda_{cont} L_{cont} + \lambda_{bg} L_{bg} \quad (3-9)$$

基线 Swin-Unet 模型采用了一种结合 Dice 损失和交叉熵损失的组合损失函数策略。因此，本文改进模型的总损失函数由公式(3-10)定义。物理约束的强度可以通过调整超参数 λ_p 来调节：

$$L_{total} = \lambda_o L_{original} + \lambda_p L_{physics} \quad (3-10)$$

为验证因介电边界引发能量密度奇异性从而导致图像梯度急剧变化的理论推导，本文对扩展数据集的梯度特征进行了统计假设检验。图 3-5 展示了瑕疵边界、内部区域及背景区域梯度幅值的箱线图分布。 $L_{maxwell}$ 配对 T 检验证实，瑕疵边界处的梯度幅值显著高于背景区域（ $T=180.55$ ， $p<0.001$ ），平均梯度比为 2.34 倍。这从统计学上验证了的物理前提——瑕疵边缘表现为与背景场明显区别的显著电磁不连续性。

此外，本文按瑕疵类型分析了梯度分布。统计结果表明，典型散射瑕疵与麦克斯韦边界模型完全吻合。其中，麻点边界梯度显著超过内部梯度（ $T=71.81$ ， $p<0.001$ ），表明边缘与均匀内部之间存在明显分离。同样地，划痕表现出统计学显著的边界优势（ $T=11.55$ ， $p<0.001$ ）。对于崩边瑕疵，由于表面纹理复杂且

破碎，内部梯度相对较高，但边界与背景的对比度在统计学上仍具有显著性，从而确保有效分割。这些实证证据支持本文基于物理信息设计约束条件，证实引导网络聚焦于梯度奇点并非仅是启发式方法，而是有数据支持的物理需求。

3.5 本章小结

本章针对光学楔形片表面对比度低、尺度极小的瑕疵检测瓶颈，提出了一种耦合物理先验信息与深度学习特征的 PINN-Swin-Unet 检测算法。通过将光学物理规律融入数据驱动模型中，有效提升了网络对微小瑕疵的特征提取能力与泛化性能。

在此章节中针对实际产线采集图像中类别极度不均衡及瑕疵特征微小的问题，构建并优化了三波段瑕疵数据集；以 Swin-Unet 为基准骨干网络，引入并行的 PIFE 物理模块。融合后的特征作为物理先验知识，通过改进的跳跃连接层注入主干网络，引导解码器更精准地重建瑕疵边缘，减少背景噪声干扰。

最重要的是构建了基于麦克斯韦方程组的物理约束损失函数，该方法突破了传统纯统计学损失函数的局限，从电磁场边界条件出发，创新性地提出了复合损失函数。该函数包含边界能量梯度约束、内部连续性约束以及背景抑制约束。统计学检验证明了瑕疵边缘梯度跳变的物理合理性。这一机制迫使模型在反向传播中遵循物理一致性原则，有效降低了虚警率。

综上所述，本章从“数据预处理—更改网络架构—优化损失函数”三个维度完成了 PINN-Swin-Unet 算法的理论设计，构建了物理信息与数据双轮驱动的检测范式，为后续的对比如实验与性能验证奠定了完整的算法框架。

第四章 光学楔形片表面瑕疵精确定位算法研究

在工业精密质检流程中，完成基于深度学习的瑕疵语义分割仅是实现自动化检测的第一步。由于光学楔形片具有半径为 2.2mm 的微小尺寸以及包含 5.5°楔角、0.2mm-0.45mm 厚度梯度的非对称几何结构，楔形片尺寸图如图 4-1 所示，实物图如图 4-2 所示。图像像素空间与真实的物理空间存在非线性映射关系。单纯依靠像素计数法进行瑕疵度量会产生严重的几何失真，尤其是在厚度梯度方向上，透视缩减效应会导致测量结果偏小。




图 4-1 楔形片尺寸示意图




图 4-2 楔形片实物图

本章旨在建立一套针对光学楔形片的精密几何度量体系。首先，通过亚像素边缘提取^[58]与最小二乘拟合^[59]确定镜片的基准坐标系；随后，针对划痕、崩边、麻点三类典型瑕疵，分别构建特定的几何评价模型，并引入 5.5°倾角补偿因子，实现微米级的尺寸还原与精确定位。

4.1 楔形片边缘轮廓亚像素拟合与基准校准

楔形片的物理中心及其边缘是所有定位算法的零点基准。由于其边缘厚度从 0.2mm 过渡到 0.45mm，成像时边缘处的散焦和光强分布并不均匀，传统算子难以保证精度。为此本文设计了楔形片边缘轮廓亚像素拟合与基准校准方法。具体流程如图 4-3。




图 4-3 楔形片边缘轮廓亚像素拟合与基准校准方法流程图

本流程展示了系统建立物理度量基准的关键步骤。首先，针对采集到的楔形片原始图像进行双边滤波^[60]与顶帽变换^[61]，旨在消除因厚度梯度带来的非均匀背景光场干扰。随后，算法引入 Zernike 矩算子^[58]对镜片边缘进行亚像素级提取，利用低阶矩的旋转不变性克服了传统算子在 5.5°边缘处产生的阶跃响应弥散。通过最小二乘法对边缘点集进行圆拟合，确定了镜片的几何中心 O_c 与像素半径。最后，结合镜片 2.2mm 的物理半径完成像素当量 K 的标定，并通过灰度质心偏移矢量确立了由薄边指向厚边的 X 轴基准坐标系，为后续所有瑕疵的精确定位提供了唯一的物理空间参考。

4.1.1 Zernike 矩亚像素边缘检测

为了克服像素量化带来的截断误差，本研究采用基于 Zernike 矩的亚像素边缘检测算法。Zernike 矩作为一种经典的矩方法是一种通过利用矩不变原理来比较实际边缘与理想阶跃边缘模型的矩，通过计算图像边缘的矩方程以得到亚像素的实际边缘位置的算法。相较于差值法^[62]和曲线拟合法^[63]这两种亚像素边缘检测方法，具有高检测精度和对噪声不敏感等特点，在亚像素边缘检测领域具有较好的应用效果。Zernike 矩具有旋转不变性^[58]，能提取图像特征的积分特性。

设图像灰度分布为 $f(x, y)$ ，其 n 阶 m 重 Zernike 矩定义为：

$$A_{\{nm\}} = \left[\frac{n+1}{\pi} \right] \iint_{\{x^2+y^2 \leq 1\}} f(x, y) V_{\{nm\}} * (\rho, \theta) dx dy \quad (4-1)$$

其中 $V_{nm}(\rho, \theta)$ 为极坐标下的 Zernike 多项式。对于边缘提取，主要利用低

阶矩 A_{00}, A_{11}, A_{20} 根据阶跃边缘模型，边缘点到掩膜中心的距离 l 以及边缘两侧的灰度差 k 可推导为：

$$l = \frac{(3A_{\{20\}} + A_{\{00\}})}{4A_{\{11\}}} \quad (4-2)$$

$$k = \frac{A^{11}}{(\sin [\arccos (l)] / \pi)} \quad (4-3)$$

通过滑动窗口计算每个像素点的亚像素偏移量 $\delta = l \cdot d$ （ d 为窗口尺寸），从而获得一组高精度的边缘点坐标集 $P = \{(x_i, y_i), i = 1, 2, \dots, N\}$ 。

4.1.2 基于最小二乘法的圆拟合

获取亚像素边缘点后，需拟合出楔形片的理想圆廓。设圆心坐标 (x_c, y_c) 为半径为 R 。圆的隐式方程为：

$$(x_i - x_c)^2 + (y_i - y_c)^2 = R^2 \quad (4-4)$$

定义目标函数（误差平方和）：

$$E(x_c, y_c, R) = \sum\{i = 1\}^N [(x_i - x_c)^2 + (y_i - y_c)^2 - R^2]^2 \quad (4-5)$$

令 $a = -2x_c, b = -2y_c, c = x_c^2 + y_c^2 - R^2$ ，则方程转化为线性形式： $x_i^2 + y_i^2 + ax_i + by_i + c = 0$ 。通过矩阵运算求得 a, b, c 的最小二乘解，进而求得物理圆心 O_c 与像素半径 R_{pixel} 。

4.1.3 基于厚度梯度的坐标系建立

楔形片的厚度沿梯度方向单调变化，这一方向被定义为系统唯一的定位轴。由于材料对光的吸收程度随厚度增加，在成像结果中，从薄侧（厚度 0.2mm）到厚侧（厚度 0.45mm）呈现出逐渐变暗的灰度梯度场。

为了识别这一方向，首先计算整幅图像的灰度重心，记作点 $G(G_x, G_y)$ 。将楔形片的几何中心记为 O_c ，则矢量 $V_{grad} = O_c \rightarrow G$ 即指示了由薄侧指向厚侧的梯度方向。将该矢量方向定义为坐标系的 X 轴，并建立与之垂直的 Y 轴，完成成像主轴的方向标定。

在完成方向标定的基础上，进一步计算图像的像素当量，用于建立图像坐标与物理尺寸之间的换算关系如式（4-6）所示：

$$\mu = \frac{2.2 \text{ mm}}{R_{\text{pixel}}} \quad (4-6)$$

其中 μ 为单个像素代表的物理尺寸（ mm/pixel ）。

4.2 划痕定位与尺寸计算

划痕通常表现为细长、不规则的线段。作为典型的线型瑕疵，具有高长宽比的几何特征。对于此类瑕疵，核心评价指标包括划痕的长度与平均宽度。对划痕类瑕疵具有高长宽比的线型几何特征。划痕定位与尺寸计算流程图如图4-4所示：




图 4-4 划痕定位与尺寸计算流程图

本流程设计了基于骨架提取的几何度量算法。在获得 PINN-Swin-Unet 分割掩膜后，首先进行形态学去噪以消除非连续性伪影。算法核心采用 Zhang-Suen^[64] 细化算子提取划痕的单像素级中轴线（骨架），通过遍历骨架像素点并累加相邻像素间的欧氏距离，计算出划痕在图像平面的初始长度。由于 5.5°楔角的存在，划痕在厚度梯度方向会产生投影缩短效应。为此，算法提取划痕端点坐标，通过三角函数补偿模型对 X 轴分量进行修正，从而还原划痕真实的物理长度与平均宽度。最终，通过计算划痕中心点在基准坐标系下的极坐标，实现瑕疵位置的量化

描述。

4.2.1 基于骨架细化的长度提取

首先，对分割得到的划痕掩膜进行二值化处理，并采用形态学开运算去除孤立的噪声点，从而获得清晰的划痕区域。然后，利用 Zhang-Suen 细化算法提取划痕的骨架，即其中轴线。该骨架由单像素宽的连续像素点构成，能够准确反映划痕的走向与拓扑结构。最后，基于骨架线计算划痕的像素长度 L_p ，其值为骨架上所有相邻像素点之间欧氏距离的累加和，即沿骨架逐点计算距离并求和。具体求和公式如式（4-7）所示：

$$L_p = \sum_{i=1}^{n-1} \sqrt{(x_{\{i+1\}} - x_i)^2 + (y_{\{i+1\}} - y_i)^2} \quad (4-7)$$

4.2.2 楔角 5.5°倾斜补偿模型

在实际成像过程中，楔形片表面与相机靶面并非完全平行，而是存在一个微小的倾斜角度 α ，本文中 $\alpha = 5.5^\circ$ 。这一倾斜导致沿梯度方向（即X轴）的投影长度被压缩，而垂直于梯度方向的Y轴长度不受影响。为了准确还原划痕的实际物理尺寸，必须对这一投影失真进行补偿。

设划痕骨架上两个端点在图像坐标系中的像素坐标差分别为 Δx 和 Δy 。考虑到倾斜仅发生在X方向，该方向的实际物理尺寸应为像素差 Δx 乘以像素当量 μ 后再除以 $\cos \alpha$ ，以消除压缩效应；而Y方向尺寸直接由 Δy 与 μ 相乘得到。因此，划痕的实际物理长度 L_{real} 可由下式计算：

$$L_{real} = \mu \cdot \sqrt{\left(\frac{\Delta x}{\cos \alpha}\right)^2 + (\Delta y)^2} \quad (4-8)$$

式中， μ 为像素当量（ $mm/pixel$ ）， α 为楔形片表面与相机靶面之间的夹角。该修正公式有效消除了因倾斜造成的测量值偏小的系统误差，确保了划痕长度测量的准确性。实际应用中，角度 α 可通过标定或几何关系预先确定。

4.2.3 划痕宽度与面积度量

划痕的面积 S 可通过统计二值化掩膜内的像素点个数直接获得。由于楔形片表面相对于相机靶面存在倾斜角 $\alpha=5.5^\circ$ ，每个像素所对应的实际物理面积并非简单的 μ^2 ，而需考虑沿梯度方向（X轴）的压缩效应。具体而言，单个像素在X方向的实际尺寸为 $\mu/\cos \alpha$ ，在Y方向为 μ ，因此其代表的实际面积为 $\mu^2/\cos \alpha$ 。于是，

划痕的实际物理面积 S_{real} 可表示为：

$$S_{real} = S \cdot \frac{\mu^2}{\cos \alpha} \quad (4-9)$$

在已求得划痕实际长度 L_{real} （由式 4-8 计算）的基础上，划痕的平均宽度 W_{real} 定义为实际面积与实际长度之比，即：

$$W_{real} = \frac{S_{real}}{L_{real}} = \frac{(S \cdot \mu^2)}{L_{real} \cdot \cos \alpha} \quad (4-10)$$

该公式综合考虑了倾斜对长度和面积的修正，能够准确反映划痕的几何特征。实际应用中， S 由图像处理获得， μ 和 α 为已知标定参数， L_{real} 由划痕端点坐标计算得出。通过这一计算，可得到划痕的平均宽度，为瑕疵评级提供依据。

然而，在实际工况中，光学楔形片表面的划痕往往呈现极不规则的曲线形态，且沿走向的宽度分布具有显著的非均匀性。传统的“面积/长度”法虽能从宏观上评估瑕疵的严重程度，但属于全局平均概念，无法捕捉划痕局部的突发性拓扑加宽，在评价高精度光学元件的损伤阈值时存在一定的度量偏差。为了实现微米级瑕疵的精细化表征，本研究引入距离变换算法对划痕宽度度量体系进行优化。

首先对提取的划痕二值掩膜图像 B 进行欧式距离变换。对于掩膜内的任意像素点 p ，计算其到最近背景像素点 q 的最短距离 $D(p) = \min |p - q|$ 。然后利用 4.2.1 节中提取的单像素骨架线作为采样基准，将距离变换结果映射至骨架点上。对于骨架上的每一个像素点 $p_i \in S_{skeleton}$ ，该点的局部物理宽度 $w(p_i)$ 定义为其最大内切圆直径，计算公式为：

$$w(p_i) = 2 \cdot D(p_i) \cdot \frac{\mu}{\cos \alpha} \quad (4-11)$$

通过遍历骨架线，获取划痕的局部宽度集合，进而求得最大物理宽度和修正后的平均物理宽度通过引入距离变换，算法能够完美解决不规则曲线带来的度量偏差，为瑕疵的分级评定提供更具物理意义的局部几何判据。

4.3 崩边定位与尺寸计算

崩边发生在楔形片的物理边缘，表现为边缘轮廓的缺失。崩边瑕疵通常依附于楔形片物理边缘，其严重程度主要取决于其向有效通光孔径区域侵入的深度。崩边定位与尺寸计算流程图如图 4-5 所示：




图 4-5 崩边定位与尺寸计算流程图

本流程首先通过连通域分析提取崩边区域的像素点集 P_{chip} ，并调用 4.2 节中拟合出的理想圆基准。算法通过计算点集中所有像素点到几何圆心 O_c 的距离 d_j ，寻找其中的最小值，并利用像素半径 R_{pixel} 与该最小值的差值定义为最大径向侵入深度。同时，考虑到崩边区域的非规则形态，算法在计算其实际物理面积时引入了 5.5°倾角补偿因子，确保了在镜片边缘处测量精度的一致性。该流程能够准确评估崩边是否触及光学元件的敏感功能区。

4.3.1 崩边深度计算

崩边通常指元件边缘的破损区域，其危害性主要由该区域侵入通光孔径的深度决定。为了量化这一深度，需要首先确定元件的几何中心及通光孔径的边界。通过拟合元件外圆轮廓，得到圆心坐标 $O_c(x_c, y_c)$ 以及通光孔径对应的像素半径 R_{pixel} 。对于崩边区域内任意一个像素点 (x_j, y_j) ，其到圆心的距离 d_j 可表示为：

$$d_j = \sqrt{(x_j - x_c)^2 + (y_j - y_c)^2} \quad (4-12)$$

由于崩边区域位于元件边缘，其内缘（即最靠近圆心的部分）决定了侵入的深度。因此，取所有崩边像素点到圆心距离的最小值 $\min\{d_j\}$ ，则崩边沿径向向内延伸的最大尺寸，即最大崩边深度 D_{max} ，由下式计算

$$D_{\max} = \mu \cdot (R_{\text{pixel}} - \min\{d_j\}) \quad (4-13)$$

式中， μ 为像素当量（ mm/pixel ）。该公式的物理意义在于：通光孔径的边界半径为 R_{pixel} ，崩边内缘距圆心的最小距离为 $\min\{d_j\}$ ，两者之差即为崩边在径向上的最大侵入深度，乘以像素当量后得到实际物理尺寸。该指标直接反映了崩边对有效通光区域的侵占程度，是评价元件边缘质量的重要依据。实际应用中，崩边区域可通过图像分割算法提取，圆心和半径由轮廓拟合获得，从而准确计算 $D_{\max}$ 。

4.3.2 崩边周向宽度计算

崩边的大小不仅由其径向深度决定，还与其沿圆周方向的范围有关。为量化崩边在圆周上的跨度，采用圆心角法进行描述。该方法基于元件拟合得到的圆心 O_c 和实际半径 R_{real} （单位：mm），通过计算崩边区域相对于圆心的极角范围，得到对应的圆弧宽度。

对于崩边区域内的每个像素点，利用其坐标 (x_j, y_j) 计算相对于圆心 O_c 的极角 θ_j 如式子（4-14），统计所有崩边像素点的极角，得到最小极角 θ_{start} 和最大极角 θ_{end} ，它们分别对应崩边沿圆周的起始位置与终止位置。考虑到崩边可能跨越角度零度线（如从 $-\pi$ 到 π 附近），需要进行相应的角度连续性处理，确保 $\theta_{\text{end}} - \theta_{\text{start}}$ 能够正确表示实际跨过的圆心角。

在获得圆心角跨度 $\Delta\theta = \theta_{\text{end}} - \theta_{\text{start}}$ 后，崩边在圆周方向的实际圆弧宽度 W_{arc} 由式（4-15）计算：

$$\theta_j = \text{atan2}(y_j - y_c, x_j - x_c) \quad (4-14)$$

$$W_{\text{arc}} = R_{\text{real}} \cdot |\theta_{\text{end}} - \theta_{\text{start}}| \quad (4-15)$$

R_{real} 为元件通光孔径的实际半径，可通过标定获得。该圆弧宽度反映了崩边沿边缘延伸的弧长，与径向深度 $D_{\max}$ 共同构成对崩边瑕疵的二维几何描述，为元件的边缘质量评估提供重要依据。实际应用中， θ_{start} 和 θ_{end} 可通过遍历崩边区域像素点并排序极角快速求得，必要时需考虑角度跨越 2π 的边界情况，以确保计算结果的准确性。

4.4 麻点定位与尺寸计算

麻点瑕疵在掩膜图像上表现为离散分布的小面积区域。麻点定位与尺寸计算流程图如图 4-6 所示：




图 4-6 麻点定位与尺寸计算流程图

本流程侧重于对这些离散目标的自动化统计与等效评估。在连通域标记的基础上，算法分别统计每个独立麻点的像素总数，并将其转化为考虑了 5.5° 投影面修正后的物理面积。为符合国际标准（如 ISO10110），算法引入等效圆模型，将不规则的麻点转化为等效物理直径 D_{eq} 。在定位层面，算法通过计算各麻点的灰度形心，将其坐标映射至建立的基准极坐标系中，输出其径向位置 ρ 与方位角 ϕ 。这一过程能够有效分析麻点在薄边与厚边区域的分布规律，为生产工艺的稳定性分析提供量化数据。

4.4.1 等效直径算法

麻点通常指元件表面微小的点状瑕疵，其尺寸采用等效直径进行量化。对于检测到的第 k 个麻点，首先统计其 c 二值化掩膜所覆盖的像素个数 N_k 。由于楔形片表面相对于相机靶面存在 5.5° 的倾斜，单个像素对应的实际物理面积并非简单的 μ^2 ，而是需考虑沿梯度方向的拉伸效应。结合像素当量 μ 和倾斜角，该麻点的实际物理面积 A_k 由下式计算：

$$A_k = N_k \cdot \mu^2 \cdot \left(\frac{1}{\cos 5.5^\circ} \right) \quad (4-16)$$

该式中, μ^2 为单个像素在无倾斜时对应的理想面积, 乘以 $1/\cos\alpha$ 修正了因倾斜造成的投影压缩, 从而得到真实的瑕疵面积。在获得实际面积后, 采用等效圆模型将不规则麻点转化为面积相等的圆形, 以便直观比较其大小。等效圆的物理直径 D_k 由式 (4-17) 给出

$$D_k = 2 \cdot \sqrt{\frac{A_k}{\pi}} \quad (4-17)$$

该直径反映了麻点的平均径向尺度, 是评价麻点严重程度的重要指标。实际应用中, 通过统计每个麻点的像素数, 结合标定的 μ 和 α , 即可依次计算出面积和等效直径, 为后续瑕疵评级提供依据。

4.4.2 麻点精确定位

麻点的空间分布信息对于分析瑕疵成因、优化工艺流程具有重要意义。在图像处理中, 每个麻点的位置通常由其几何形心 $P(x_g, y_g)$ 表示。然而, 由于楔形片表面相对于相机靶面存在倾斜, 沿梯度方向 (X 轴) 的坐标需要经过投影修正, 才能反映真实的物理位置。

设元件拟合圆心为 $O_c(X_c, Y_c)$, 像素当量为 μ 。对于形心坐标为 (X_g, Y_g) 的麻点, 其相对于圆心的实际物理距离极径 ρ 可通过下式计算:

$$\rho = \mu \cdot \sqrt{\left(\frac{(x_g - x_c)}{\cos 5.5^\circ}\right)^2 + (y_g - y_c)^2} \quad (4-18)$$

式(4-17)的修正逻辑在于: X 方向的像素差因倾斜被压缩, 需除以 $\cos 5.5^\circ$ 还原为实际尺寸; 而 Y 方向与倾斜方向垂直, 不受影响, 因此直接采用像素差。计算得到的 ρ 即为麻点到圆心的真实径向距离。在此基础上, 还可结合式 (4-14) 的极角构成完整的极坐标 (ρ, θ) , 从而精确定位麻点在元件表面的位置。

4.5 算法验证与实验分析

为了验证算法精度, 本研究选取了 20 个有瑕疵的光学楔形片通过标定板进行对比测试。标定板设计如图 4-7 所示, 每一小格的标定框边长为 0.05mm 标定板在显微镜下的显示如图 4-8 所示。




图 4-7 标定板设计图




图 4-8 标定板在显微镜下显示图

表 4-1 对比实验测试结果

瑕疵类型	标定板真值 (mm)	未补偿量真值 (mm)	本文算法测量真值 (mm)
划痕长度	0.700	0.682	0.707
崩边深度	0.120	0.109	0.113
麻点直径	0.030	0.025	0.028

通过多角度旋转测试，圆心重复定位精度优于 0.5 像素。表 4-1 对比了未进行楔角补偿与进行 5.5°补偿后的测量值。据表明，引入倾角补偿模型后，在梯度方向上的长度测量误差显著降低，证明了算法对非对称楔形片的适用性。

4.6 本章小结

本章针对光学楔形片因 5.5° 楔角及厚度梯度导致的成像畸变问题，构建了一套完整的精密几何度量体系。首先，采用 Zernike 矩亚像素边缘检测与最小二乘圆拟合，精确提取镜片边缘轮廓，并结合灰度重心偏移建立了以厚度梯度方向为 X 轴的基准坐标系。在此基础上，针对划痕、崩边和麻点三类典型瑕疵，分别设计了专用的几何评价模型。对于划痕类瑕疵的度量是通过骨架提取获得中轴线，累加像素间距计算长度，并引入倾斜补偿公式修正 X 轴投影压缩；同时结合面积计算平均宽度。对于崩边类瑕疵的度量是通过分析分析瑕疵像素点到圆心的距离，定义最大径向深度；利用极角范围计算圆弧宽度，实现二维几何描述。对于麻点类瑕疵的度量是通过统计像素个数并考虑面积倾斜补偿，采用等效圆模型计算等效直径；通过修正后的极径公式将麻点映射至极坐标系，分析其空间分布。

实验选取 20 个样品，使用标定板进行对比测试。结果表明，经 5.5° 倾角补偿后，划痕长度、崩边深度和麻点直径的测量误差显著降低，圆心重复定位精度优于 0.5 像素，验证了该方法的准确性与可靠性。

第五章 验证与分析

本章将在真实光学楔形片生产环境中验证所提 PINN-Swin-Unet 模型的有效性。首先介绍实验的软硬件配置与评价指标。然后通过参数敏感性分析确定物理损失权重,并设计消融实验分别检验物理信息特征提取模块和各项损失分量的作用。接着将本模型与 U-Net、VM-Unet、YOLOv13 及 Halcon 等主流方法进行对比,从精度、实时性和误检率等方面综合评估其优势。最后结合典型瑕疵的检测结果进行可视化分析,直观说明模型在崩边、划痕和麻点三类缺陷上的实际表现。

5.1 训练环境及参数设置

实验设备部署于光学楔形片生产工厂内,如图 5-1 所示。实验服务器硬件配置为:CPU 为 16 核 AMD EPYC9354, GPU 为 NVIDIA RTX4090 (配备 25.2GB 显存),内存为 60.1GB。采用的深度学习框架为 PyTorch2.0.1。




图 5-1 光学楔形片生产线实验装置部署示意图

5.2 评价指标

为了评估分割精度,本研究采用了平均 IoU 值、每个瑕疵类别的 IoU 值以及 Dice 系数。由于麻点型瑕疵本质上是微观的,其尺寸大小通常尺寸在微米级,在图像中仅占 10-20 个像素,人工标注难以精确地勾勒出它们的边界。因此,对于麻点型瑕疵的评估, Dice 系数比 IoU 值更能可靠地反映其性能。瑕疵分类精度则使用召回率和精确率指标进行评估。

5.3 实验结果及分析

5.3.1 瑕疵检测性能比较分析

本研究采用 Swin-Unet 作为基准模型。相比之下，PINN-Swin-Unet 模型整合了第 3 章提出的瑕疵物理信息补充模块和物理信息损失函数。除这些改进外，两个模型保持完全相同的超参数设置，并使用相同数据集进行实验。所有评估均在相同的验证集和测试集上进行。表格中，数字前缀“ λ ”表示物理信息损失函数在 Swin-Unet 总损失中的权重系数。

为确定超参数 λ_p 的取值范围，本文将 λ_p 的取值范围从 0.05 调整至 0.50，每次调整 0.05，并记录所有瑕疵类型的平均分割指标（IoU、Dice 计数、召回率和精确率）。结果如图 5-2 所示。纵轴表示不同瑕疵检测性能的数值指标，横轴表示 λ_p 的数值。

随着 λ 从 0.05 逐渐增大，所有指标均呈现提升趋势，这表明引入物理约束能有效引导网络学习更具鲁棒性的特征。多数指标在 $\lambda=0.3$ 时达到性能峰值。性能曲线在峰值附近（区间[0.25,0.35]）保持相对平缓，说明该模型在数学上具有稳定性，且对超参数在此范围内的微小波动不敏感。当 λ 超过 0.4 时性能下降。这表明过度的物理约束可能与数据分布冲突，导致过度正则化。过强的梯度约束（ $L_{maxwell}$ ）可能使模型对背景噪声过于敏感，略微增加假阳性率。然而，综合指标（IoU 和 Dice 系数）证实 $\lambda=0.3$ 是仍是全局最优解，在多种分区指标间实现了最佳平衡。




图 5-2 λ_p 敏感性分析

如表 5-1、5-2、5-3 所示，与基线模型相比，PINN-Swin-Unet 在所有三种瑕疵类别中均展现出显著更优的瑕疵检测性能。随着 λ 值的增加，模型性能呈现适度提升，特别是在麻点检测方面实现了 10.1%的提升。然而，当 $\lambda=0.4$ 时，评估指标开始出现波动。当基于物理的损失权重设置 λ_p 为 0.3 时，模型达到最优性能。

表 5-1 物理约束权重与基线模型在崩边检测中的比较

	IoU	Dice	Recall	Precision
Swin-Unet	0.795	0.793	0.895	0.884
$0.1\lambda_p$	0.918	0.938	0.952	0.923
$0.2\lambda_p$	0.924	0.940	0.958	0.925
$0.3\lambda_p$	0.928	0.943	0.961	0.926
$0.4\lambda_p$	0.922	0.941	0.957	0.922

表 5-2 物理约束权重与基线模型在划痕检测中的比较

	IoU	Dice	Recall	Precision
Swin-Unet	0.523	0.641	0.637	0.601
$0.1\lambda_p$	0.705	0.827	0.860	0.828
$0.2\lambda_p$	0.710	0.831	0.864	0.825
$0.3\lambda_p$	0.712	0.835	0.868	0.823
$0.4\lambda_p$	0.708	0.852	0.867	0.822

表 5-3 物理约束权重与基线模型在麻点检测中的比较

	IoU	Dice	Recall	Precision
Swin-Unet	0.679	0.733	0.741	0.788
$0.1\lambda_p$	0.782	0.890	0.877	0.892
$0.2\lambda_p$	0.813	0.896	0.903	0.898
$0.3\lambda_p$	0.861	0.911	0.915	0.894
$0.4\lambda_p$	0.849	0.901	0.895	0.883

5.3.2 消融实验

为全面验证所提出的 PINN-Swin-Unet 模型的有效性，本文在相同的测试集上进行了两个阶段的消融研究。首先，本文评估了物理信息特征提取模块和物理信息损失函数两个核心组件的独立贡献。如表 5-4 所示，基线 Swin-Unet 模型的平均交并比（mIoU）为 0.685。引入 PIFE 模块后性能提升最为显著，mIoU 提升 18.9%至 0.815。这证实了从三波段成像系统中提取的显式光谱特征提供了基线网络无法从白光或单通道输入中恢复的关键信息。单独应用物理损失函数对基线模型仅带来中等程度的改进（+7.1%），证明物理约束可作为有效的正则化手段。两个模块的组合（完整模型）实现了最高的 mIoU 值 0.873，表明物理信息归纳偏置在应用于物理特征丰富的数据时效果最佳。

为详细分析物理信息损失函数（ $L_{physics}=L_{maxwell}+L_{cont}+L_{bg}$ ）中的具体贡献，本文在表 5-5 中进行了详细分解。 $L_{maxwell}$ 在损失函数中贡献了最显著的个体增益，提升了模型对锐利瑕疵边界的区分能力。虽然单独贡献较小， L_{cont} 和 L_{bg} 分别通过平滑瑕疵内部和抑制背景噪声进一步优化分割效果。当同时施加所有三个约束时，模型可以获得最佳性能。

表 5-4 模块级消融实验结果

	mIoU	Dice	Recall	Precision
Swin-Unet	0.685	0.742	0.785	0.710
Swin-Unet+PIFE	0.815	0.852	0.875	0.842
Swin-Unet+ L_{total}	0.725	0.778	0.810	0.775
Swin-Unet+PIFE+ L_{total}	0.873	0.905	0.931	0.893

表 5-5 各项损失分量消融实验结果

	mIoU	Dice	Recall	Precision
Swin-Unet+PIFE+ $L_{maxwell}$	0.845	0.878	0.905	0.858
Swin-Unet+PIFE+ L_{cont}	0.828	0.862	0.892	0.838
Swin-Unet+PIFE+ L_{bg}	0.822	0.858	0.888	0.832

	mIoU	Dice	Recall	Precision
Swin-Unet+PIFE+ $L_{\text{maxwell}}+L_{\text{cont}}$	0.862	0.895	0.922	0.875
Swin-Unet+PIFE+ $L_{\text{maxwell}}+L_{\text{bg}}$	0.858	0.890	0.915	0.870
Swin-Unet+PIFE+ $L_{\text{cont}}+L_{\text{bg}}$	0.835	0.870	0.900	0.845

5.3.3 MSE 有效性验证

在确定物理约束项的具体数学实现时，本文针对 L1 损失^[65]、余弦相似度^[66]与均方误差（MSE）^[67]进行了对比实验，目的是为了确定物理约束损失函数的最优度量准则，本文对比了上述三种距离函数在表征电磁场异常方面的效能。实验结果表明（见表 5-6），基于 MSE 构建的物理损失函数显著优于余弦相似度与 L1 损失。

表 5-6 损失分量对比实验结果

度量函数	数学特性	mIoU	Dice	Recall	Precision
余弦相似度	只关注向量方向	0.852	0.880	0.895	0.861
L1	线性绝对值差异	0.865	0.892	0.910	0.878
MSE	平方误差	0.872	0.905	0.931	0.893

实验发现，虽然余弦相似度能较好地对齐梯度方向，但由于其忽略了幅值信息，而幅值正是电磁能量密度（ $|\mathbf{E}|^2$ ）在瑕疵边界的直接表征，这导致模型对低对比度划痕的能量辨识度不足。而 L1 损失在处理电磁场边缘跳变时存在“平滑效应”，难以捕捉微小的物理异常。

相比之下，MSE 通过平方项加大了对能量偏差的约束力度，能够同时实现对散射场方向与强度的精准约束。它不仅约束了散射场梯度的方向一致性，还通过平方权重强化了对电磁能量密度不连续性的惩罚。这一设计使得物理约束的损失函数能够有效引导 PINN-Swin-Unet 学习到具有物理意义的瑕疵特征，而非仅仅停留在图像像素的统计匹配上。因此，本研究最终采用 MSE 作为物理约束项的核心算子，以确保模型输出的瑕疵特征符合麦克斯韦方程组定义的能量演化规律。

5.4 模型对比及分析

本节旨在通过定量指标评估 PINN-Swin-Unet 对光学楔形片表面瑕疵的检测效能。实验选取了当前主流的语义分割网络（如 U-Net 变体）、前沿的视觉架构（如 VM-Unet^[68]、YOLOv13^[69]）以及工业界标杆软件 Halcon 进行对比。为消除随机误差对实验结果的影响，所有模型均进行了 N=5 次重复实验，并记录指标的平均值与标准差。详细的实验数据对比见表 5-7。

表 5-7 PINN-Swin-Unet 对比实验结果

	Chipping	Scratch	Splash	MIoU	FPS
	IoU/Precision	IoU/Precision	IoU/Precision		
Unet	0.611/0.833	0.324/0.569	0.355/0.771	0.488±0.008	49.7
Unet++	0.174/0.543	0.221/0.561	0.273/0.606	0.218±0.011	38.6
VM-Unet	0.479/0.552	0.316/0.407	0.157/0.172	0.335±0.013	94.3
Yolov13	0.622/0.718	0.479/0.383	0.810/0.776	\	132.1
Halcon	0.904/0.577	0.793 /0.217	0.859/0.136	\	55.2
Swin-Unet	0.795/0.884	0.523/0.601	0.679/0.788	0.685±0.007	26.1
0.3PINN-Swin-Unet	0.928/0.926	0.712/ 0.823	0.861/0.894	0.873±0.009	24.5

5.4.1 与深度学习模型的对比分析

（1）基于卷积神经网络的 U-Net 变体

实验结果表明，经典的 U-Net 模型与 U-Net++模型在本研究数据集上的表现并不理想。U-Net 模型的 mIoU 仅为 0.488，主要由于其受限于局部卷积核的感受野，难以捕获尺度跨度巨大的划痕和崩边两类瑕疵的长程空间特征。U-Net++虽然引入了密集的嵌套跳跃连接，但在背景纹理复杂的环境下产生了严重的过拟合，导致在崩边检测中的 IoU 降至 0.174。这证明了在低对比度工业场景下，单纯依靠增加模型深度和连接密度难以解决物理特征丢失的问题。

（2）基于状态空间模型（Mamba）的 VM-Unet

作为 2024 年提出的高性能架构，VM-Unet 在处理效率上表现卓越（FPS 达到 94.3），但在分割精度上却出现了显著退化，其 mIoU 仅为 0.335。分析认为，VM-Unet 的线性扫描机制虽然能捕捉长程依赖，但在应对光学瑕疵这种具有极

细微局部特征（如微米级麻点）的样本时，其特征解耦能力弱于具有窗口注意力的 Swin-Unet 架构。

5.4.2 与工业级软件及先进架构的对比分析

（1）工业视觉软件 Halcon 的局限性

作为工业视觉领域的标准，Halcon 的深度学习算法展现出极高的边缘灵敏度。在划痕与崩边检测中，其 IoU 分别达到了 0.793 与 0.904，甚至在某些维度略高于本研究模型。

Halcon 依赖于成熟的基于梯度的边缘检测算子，对线性的亮度波动极其敏感，能精确勾勒出瑕疵的物理轮廓。然而，如图 5-3 所示这种过度敏感导致其缺乏对瑕疵物理语义的判别力。实验中发现，Halcon 频繁将图像中的灰尘、水印及传感器噪声误报为真实瑕疵，导致其麻点检测的精确率仅为 0.136，误报率高达 80%以上。这一结果证明，传统的工业算法在复杂噪声干扰下无法实现高精度分类。




图 5-3 右侧图像中的红色和粉色区域是 Halcon 误检的瑕疵。从左至右依次为：原始图像、人工标注掩膜和 Halcon 预测掩膜

（2）YOLOv13 的检测特性

YOLOv13 在麻点类瑕疵的检测中表现出色（IoU 达 0.810），且实时性最高（FPS 达 132.1）。但由于其作为检测器更侧重于目标框的定位而非像素级分割，对于形态极其不规则的划痕与崩边，其生成的掩膜边界较为粗糙，难以满足光学楔形片精密质检的要求。

5.4.3 PINN-Swin-Unet 的性能优势论证

通过表 5-7 的综合对比可以发现，本文提出的 PINN-Swin-Unet 在多项核心指标上均实现了对现有主流模型的全面超越。相较于使用了官方预训练的 Swin-Unet 基准模型，PINN-Swin-Unet 的 mIoU 从 0.685 提升至 0.873，实现了

27.4%的大幅增长；同时，其平均精确率也实现了 16.3%的相对提升。这种性能的飞跃并非单纯源于网络参数的堆叠，而是物理信息先验与深度学习特征深度融合的直接结果，具体优势体现在以下三个维度：

（1）多波段物理信息对难检测特征的补全作用

在针对低对比度划痕的检测中，传统模型往往因瑕疵纹理与背景高度相似而导致严重的漏检。原生 Swin-Unet 在划痕类别的 IoU 仅为 0.523。而本研究引入的 PIFE 模块通过并行处理 370nm-460nm、465nm-505nm、520nm-610nm 三个不同波段，能够跨光谱捕捉瑕疵在不同波长下的微弱散射差异。这种物理属性的引入为模型提供了超越单纯视觉纹理的“第二特征空间”，使得划痕类别的 IoU 显著跃升至 0.712，增幅达 36.1%。这证明了物理信息能够有效引导模型在语义稀疏区域进行精准决策，显著提升了对弱信号目标的识别边界。

（2）麦克斯韦物理约束对复杂噪声的抑制机理

工业现场环境中，传感器热噪声与光学干扰极易造成高虚警率，这一点在工业算法 Halcon 的表现中尤为明显——尽管 Halcon 在某些维度具备较高的边缘敏感度，但其在麻点检测中的精确率仅为 0.136，误检率接近 90%。与此形成鲜明对比的是，PINN-Swin-Unet 在三类瑕疵上的精确率均稳定维持在 0.82 以上，其中麻点类瑕疵的精确率更是高达 0.894。这种卓越的可靠性源于本研究设计的受麦克斯韦方程启发的物理约束损失函数。该函数在训练阶段对预测掩膜施加了严格的电磁能量梯度约束，强制模型剔除不符合电磁波空间演化规律的随机像素跳变。这种“物理过滤器”机制使得模型具备了本质上区分“物理瑕疵”与“随机噪声”的能力，在维持高 IoU（0.861）的同时，解决了工业场景中常见的虚警难题。

（3）高精度分割与工业实时性的动态平衡

在实现精度突破的同时，PINN-Swin-Unet 依然保持了优秀的工程实用性。引入 TensorRT 推理引擎。通过 INT8/FP16 量化与算子融合等手段，在牺牲极小精度的前提下显著压缩显存占用，从而实现 PINN-Swin-Unet 在嵌入式 GPU 等工业边缘计算设备上的高效部署与毫秒级实时检测。虽然引入了 PIFE 物理分支与复杂的复合损失函数，但其检测速度（24.5FPS）与基准 Swin-Unet（26.1FPS）相比仅产生了微小的性能损耗。相比于 VM-Unet 虽具备 94.3FPS 的极速但 mIoU 仅有 0.335 的不可用状态，PINN-Swin-Unet 在 2048×2048 高分辨率视场下，以极小的计算开销换取了 160%以上的精度增益（相对于 VM-Unet）。

综上所述，PINN-Swin-Unet 通过物理信息特征提取模块与物理一致性损失约束的有机结合，不仅在崩边类瑕疵取得了接近完美的 0.928IoU，更在划痕与麻点这两类极具挑战性的任务中实现了精度与可靠性的双重突破。实验结果有力地论证了物理驱动与数据驱动协同优化的先进性，为精密光学元件的在线质检提供

了高性能、低误检的算法范式。

5.5 定性结果分析与可视化验证

为了直观验证 PINN-Swin-Unet 在实际测试集上的性能，图 5-3 展示了模型对光学楔形片表面三类典型瑕疵的检测结果。图中从左至右依次为：原始输入图像、人工标注的掩码图以及模型生成的预测掩膜。




图 5-4 检测结果可视化

在处理边缘崩边瑕疵时，模型展现了极佳的几何拓扑还原能力。可视化结果显示，预测掩膜在瑕疵的数量分布与空间轮廓上均与人工标注高度一致。尤其是在边缘锐度剧烈变化的区域，PINN-Swin-Unet 能够精准勾勒出崩边的锯齿状边界，并未出现传统 CNN 模型中常见的边缘平滑或形态失真现象。这直接证明了层级化 SwinTransformer 配合物理信息跳跃连接，在捕获高频边缘特征方面具有显著优势。

对于麻点类瑕疵，整体检测效果表现优异且稳健。在复杂的背景纹理及随机分布的亮斑干扰下，模型表现出极强的辨识力，能够准确区分真实的物理麻点与背景中的传感器热噪声。大尺寸的麻点实例被完整识别，且预测区域的质心与标注位置基本重合。虽然在面对极微小（仅占数个像素）的麻点时存在极小概率的

漏检现象，但在工业容差允许范围内，该性能已显著优于对比模型，充分体现了麦克斯韦约束损失函数对非物理伪影的抑制作用。

划痕的检测结果进一步论证了模型的全局建模能力。如图 5-4 所示，预测掩膜基本覆盖了标注的所有划痕区域。对于对比度极低、极易发生特征断裂的细长划痕，PINN-Swin-Unet 能够保持较好的结构连续性，并未出现严重的碎片化预测。这说明 PIFE 模块提取的多波段特征有效补偿了视觉信息的缺失，使模型能够感知到隐藏在噪声背景下的弱物理梯度，从而实现了划痕形态的整体把握。




图 5-5 鲁棒性检测实验

本文还进行了检测瑕疵的鲁棒性实验，如图 5-5 所示。将原图添加椒盐噪声用来模拟灰尘干扰效果，添加高斯模糊和散斑噪声用以模拟极端光照效果。实验显示，两种噪声的干扰对于崩边的检测几乎没有影响，椒盐噪声模拟的灰尘对小麻点的检测有一定程度的干扰，而高斯抹灰模拟的极端光照情况对划痕的检测干扰较大，这是因为划痕类瑕疵本身具有极细长的高长宽比特征，且与背景的对比度极低，属于典型的高频弱边缘信号。高斯模糊与散斑噪声在图像上会产生强烈的平滑和涂抹效应，严重削弱了划痕边缘原本就微弱的像素梯度幅度。由于本文提出的 PINN-Swin-Unet 模型及其构建的物理约束损失函数高度依赖于瑕疵边界处的电磁能量梯度跳变来进行特征定位，这种平滑效应直接破坏了划痕的物理梯度特征，导致微弱的线性散射信号彻底淹没在背景噪声中。这使得网络在特征提取时难以建立划痕的连续性空间依赖，最终造成划痕预测掩膜的严重断裂和漏

检。

综上所述，可视化结果与表 5-4 中的定量指标形成了闭环验证。PINN-Swin-Unet 在崩边、麻点及划痕三类瑕疵的检测任务中均表现出极强的稳健性与精确度。模型输出的预测掩膜不仅在语义层面达到了人工级标注水平，更在像素层面体现了物理先验对细节修复的积极干预，可以满足光学元件精密质检对分割精度与可靠性的严苛要求。

5.6 本章小结

本章对所提出的 PINN-Swin-Unet 瑕疵检测算法进行了全面的实验验证与性能评估。介绍了实验的软硬件环境与评价指标。通过对物理约束权重系数 λ_p 进行参数敏感性分析，确定了当 $\lambda_p=0.3$ 时，模型在各项评价指标间达到最优平衡，能够在引入物理约束的同时避免过度正则化。开展了多维度的消融实验。结果表明，单独引入 PIFE 模块可使 mIoU 大幅提升 18.9%，证实了多波段物理特征的极高价值；同时，实验从数学层面论证了采用均方误差构建物理损失函数优于 L1 与余弦相似度，能够更精准地约束电磁能量的不连续性。两者的结合使最终模型的 mIoU 达到了 0.873。

此外本章将本文提出的算法与传统 CNN、前沿架构及工业软件进行了定量对比。实验表明，PINN-Swin-Unet 不仅以 0.873 的 mIoU 全面领先，并在 2048×2048 高分辨率下保持了 24.5FPS 的良好实时性。

本章通过定量数据与定性可视化的闭环验证，充分论证了 PINN-Swin-Unet 算法在光学楔形片微小瑕疵检测任务中的高精度与强鲁棒性，证明了“物理-数据”双驱动策略在复杂工业视觉场景下的先进性与实用价值。

总结与展望

1. 工作总结

长期以来,精密光学元件的表面瑕疵检测高度依赖人工目视,不仅效率受限,且极易引入主观偏差。为解决光学楔形片表面微米级瑕疵难以稳定捕捉的痛点,本文抛弃了纯数据驱动的常规思路,探索出一条物理规律与深度学习深度融合的检测新路径。经真实产线环境验证,该方案较好地克服了高复杂背景下的高误检率问题。具体研究成果体现在以下三个主要方面:

第一,搭建了基于三波段散射特性的光学采集平台与专用数据集。考虑到微小疵病在单一光源下极易隐匿,本研究回归物理散射机理,自主设计了覆盖紫外、蓝绿、绿黄三个波段的暗场照明系统,从物理源头上提升了瑕疵的对比度与信噪比。在此基础上,面对工业现场真实存在的“长尾”现象,本文不仅制定了严苛的标注规范,还配套使用了在线 Mosaic 与实例级 Copy-Paste 混合增强技术,从根本上缓解了模型的类别偏置问题。

第二,提出了物理约束主导的 PINN-Swin-Unet 瑕疵检测架构。在网络层面,以 Swin-Unet 为基座,本文专门外挂了物理特征提取模块,将多光谱获取的先验信息经跳跃连接“喂”给解码层,专门用于修补残缺的瑕疵边缘。更核心的改进在于损失函数的设计:尝试将麦克斯韦方程组中的电磁边界条件数学化,作为一种强制约束引入网络训练中。这种做法逼迫模型必须按照“能量梯度跳变”的真实物理规律去预测,极大增强了其在强干扰环境下的抗噪底气。测试表明,该算法的平均交并比提升至 0.873,相比基线模型获得了 27.4% 的实质性跃升。

第三,确立了适配非对称楔形片的精密几何度量体系。楔形片自带的 5.5° 楔角不可避免会引发透视失真。为此,研究联合 Zernike 矩亚像素边缘提取与最小二乘法,实现了物理坐标系的精准锚定。随后引入倾斜补偿模型,专门用来抵消厚度渐变带来的投影压缩。经过这一环的修正,系统找回了微米级的真实尺寸,补偿后的圆心定位误差被严格控制在 0.5 像素以内,切实满足了精密光学的严苛度量标准。

2. 工作展望

本文通过将物理成像规律嵌入深度学习框架,实现了光学楔形片瑕疵的高效检测与量测。但受限于实验条件与研究周期,系统仍存在以下待改进之处:

(1) 复杂干扰下的特征解耦能力仍有待提升。在面对极端工况时,网络有时会把微小的表面粉尘误判为真实针孔类麻点,这意味着系统目前对车间的环境

洁净度仍有较高妥协。下一步的研究可以考虑叠加偏振或相位信息，试图从物质属性的根源上增强对“伪瑕疵”的过滤机制。

（2）算法的实时性与轻量化需进一步优化。客观来说，当前 24.5FPS 的处理速度能勉强满足产线需求，但在处理 2048×2048 超高分辨率图像时，物理约束损失的计算开销依然存在。后续研究可尝试采用模型剪枝或知识蒸馏技术，在保证物理一致性的前提下，进一步提升大规模在线检测的吞吐量。

（3）定位基准的鲁棒性亟待补强。现阶段的坐标系拟合过于依赖镜片边缘的完整入镜。一旦出现镜片摆放严重跑偏、导致边缘残缺的情况，整个度量体系的精度就会受到连累。后续计划引入基于局部轮廓或柔性模板匹配的对齐算法，让系统在非理想状态下也能保持稳定。

（4）处理重叠瑕疵仍是一项挑战。当划痕与崩边等不同类型的缺陷交织在一起时，本文前期设计的内部均匀性约束反而容易“弄巧成拙”。网络经常难以剥离叠加特征，甚至将其粗暴地揉成一个单一预测掩膜。如何引导模型学会更细粒度的特征拆解，是下一步算法迭代需要重点攻关的难关。

参考文献

- [1] 王旭东, 高爱华, 闫丽荣, 等. 不同波长的光源对疵病散射率的影响研究[J/OL]. *Laser & Optoelectronics Progress*, 2022, 59(11): 1112002.
- [2] 王科. 光学元件表面疵病散射法检测技术研究[D]. 西安: 西安工业大学, 2013.
- [3] 冯晓硕, 沈樾, 王冬琦. 基于图像的数据增强方法发展现状综述[J]. *Computer Science and Application*, 2021.11(2): 370-382.
- [4] 向弋川, 林有希, 任志英. 光学元件表面瑕疵检测方法研究现状[J]. *光学仪器*, 2018, 40(1): 78-87.
- [5] SHAN A, ZHENG J, LV F, et al. A review of optical component defect detection based on deep learning[C/OL]//Fourth International Conference on Advanced Algorithms and Neural Networks (AANN 2024): Vol 13416. SPIE, 2024: 345-353.
- [6] JING J, WANG Z, RÄTSCH M, et al. Mobile-Unet: An efficient convolutional neural network for fabric defect detection[J/OL]. *Textile Research Journal*, 2022, 92(1-2): 30-42.
- [7] TANG M, WANG W. FDTransUnet: An aluminum surface defect segmentation model based on feature differentiation[J]. *PloS one*, 2025, 20(3): e0320060.
- [8] SUN Y, YAN H, SHANG Z, et al. MCH-YOLOv12: Research on surface defect detection algorithm for aluminum profiles based on improved YOLOv12[J]. *Sensors*, 2025, 25(17): 5389.
- [9] LIU W, YUAN W. Supervised Focused Feature Network for Steel Strip Surface Defect Detection[J]. *Mathematics*, 2025, 13(20): 3285.
- [10] SUN M, LYU C, HAN Y, et al. Weakly supervised surface defect detection based on attention mechanism[J]. *Journal of computer-aided design & computer graphics*, 2021, 33(6): 920-928.
- [11] TANG M, LI Y, YAO W, et al. A strip steel surface defect detection method based on attention mechanism and multi-scale maxpooling[J]. *Measurement Science and Technology*, 2021, 32(11): 115401.
- [12] MINHAS M S, ZELEK J. Semi-supervised Anomaly Detection using AutoEncoders[A/OL]. *arXiv*, 2020[2024-04-29].
- [13] GUO Y, ZHONG L, QIU Y, et al. Using ISU-GAN for unsupervised small sample defect detection[J/OL]. *Scientific Reports*, 2022, 12(1): 11604.
- [14] XIONG J, HE Z, ZHOU Q, et al. Photovoltaic glass edge defect detection based on improved SqueezeNet[J/OL]. *Signal, Image and Video Processing*, 2024, 18(3): 2841-2856.
- [15] KONOVALENKO I, MARUSCHAK P, BREZINOVÁ J, et al. Research of U-Net-Based CNN Architectures for Metal Surface Defect Detection[J/OL]. *Machines*, 2022, 10(5): 327.
- [16] CAO H, WANG Y, CHEN J, et al. Swin-Unet: Unet-Like Pure Transformer for Medical Image Segmentation[M/OL]//KARLINSKY L, MICHAELI T, NISHINO K. *Computer*

- Vision – ECCV 2022 Workshops: Vol 13803. Cham: Springer Nature Switzerland, 2023: 205-218.
- [17] CUI H, XING T, REN J, et al. ESwin-UNet: A collaborative model for industrial surface defect detection[C/OL]//2022 IEEE 28th International Conference on Parallel and Distributed Systems (ICPADS). IEEE, 2023: 379-386.
- [18] XU H, LIU C, DUAN S, et al. A fabric defect segmentation model based on improved Swin-Unet with Gabor filter[J]. Applied Sciences, 2023, 13(20): 11386.
- [19] LIM W H, SFARRA S, YAO Y. A physics-informed neural network method for defect identification in polymer composites based on pulsed thermography[J]. Engineering Proceedings, 2021, 8(1): 14.
- [20] CHEN Y, LU L, KARNIADAKIS G E, et al. Physics-informed neural networks for inverse problems in nano-optics and metamaterials[J/OL]. Optics Express, 2020, 28(8): 11618.
- [21] LAWAL Z K, YASSIN H, LAI D T C, et al. Physics-informed neural network (PINN) evolution and beyond: A systematic literature review and bibliometric analysis[J]. Big Data and Cognitive Computing, 2022, 6(4): 140.
- [22] CAI S, MAO Z, WANG Z, et al. Physics-informed neural networks (PINNs) for fluid mechanics: a review[J/OL]. Acta Mechanica Sinica, 2021, 37(12): 1727-1738.
- [23] BAI J, WU D, SHELLEY T, et al. A Comprehensive Survey on Machine Learning Driven Material Defect Detection[J/OL]. ACM Computing Surveys, 2025: 3730576.
- [24] LEE S, POPOVICS J S. Ultrasonic defect detection in a concrete slab assisted by physics-informed neural networks[J]. NDT & E International, 2025, 151: 103311.
- [25] ZHANG N, DONG H, YE C. Synchronous imaging and multimodal fusion of optical and electromagnetic measurements for overlapping defects inspection[J]. IEEE Transactions on Industrial Informatics, 2023, 20(2): 2234-2243.
- [26] ROLIH B, FUČKA M, SKOČAJ D. SuperSimpleNet: Unifying Unsupervised and Supervised Learning for Fast and Reliable Surface Defect Detection[C] International Conference on Pattern Recognition (ICPR 2024), 2024: 47-65.
- [27] WU H, SHI L. Defect detection of mobile phone back covers under different spectral lighting conditions[C/OL]//Seventeenth International Conference on Digital Image Processing (ICDIP 2025): Vol 13709. SPIE, 2025: 569-579.
- [28] CHEN H, PANG Y, HU Q, et al. Solar cell surface defect inspection based on multispectral convolutional neural network[J/OL]. Journal of Intelligent Manufacturing, 2020, 31(2): 453-468.
- [29] CHEN Y, DAL NEGRO L. Physics-informed neural networks for imaging and parameter retrieval of photonic nanostructures from near-field data[J/OL]. APL Photonics, 2022, 7(1)010802.
- [30] SABA A, GIGLI C, AYOUB A B, et al. Physics-informed neural networks for diffraction

- tomography[J]. *Advanced Photonics*, 2022, 4(6): 066001-066001.
- [31] MEDVEDEV V, ERDMANN A, ROSSKOPF A. 3D mask simulation and lithographic imaging using physics-informed neural networks[C/OL]//*Proc. SPIE: Vol 12953*. 2024: 209-225.
- [32] SAMPAIO P, SARAIVA P, GUIMARÃES RODRIGUES A. ISO 9001 certification research: questions, answers and approaches[J]. *International journal of quality & reliability management*, 2009, 26(1): 38-58.
- [33] JIANG R J, BANSAL P. Seeing the Need for ISO 14001[J/OL]. *Journal of Management Studies*, 2003, 40(4): 1047-1067.
- [34] SPECIFICATION M. Optical Components for Fire Control Instruments; General Specification Governing the Manufacture, Assembly, and Inspection of[R/OL]. MIL-PRF-13830B. 1997. Available online: [https://elsmar.com/pdf_files ...](https://elsmar.com/pdf_files...), 1997.
- [35] 刘庆明, 盛益鹏. GB/T 1185 《光学零件表面疵病》与俄, 美相关标准对比分析[J]. *国防技术基础*, 2007(8): 6-10.
- [36] 苏程程, 万新军, 陈红豆, 等. 结合暗场散射与曲率成像的镜面瑕疵检测方法[J]. *光学仪器*, 2021, 43(3): 1-8.
- [37] 郑也, 何苗, 刘小溪, 等. 基于二向色镜的高功率激光组束实验研究[J]. *Laser & Optoelectronics Progress*, 2023, 60(15): 1514002.
- [38] HASSEN R, WANG Z, SALAMA M M. Image sharpness assessment based on local phase coherence[J]. *IEEE Transactions on Image Processing*, 2013, 22(7): 2798-2810.
- [39] 卢荣胜, 吴昂, 张腾达, 等. Review on Automated Optical (Visual) Inspection and Its Applications in Defect Detection[J/OL]. *Acta Optica Sinica*, 2018, 38(8): 0815002.
- [40] 罗茂, 步扬, 徐静浩, 等. Optical Element Surface Defect Measurement Based on Multispectral Technique[J/OL]. *Chinese Journal of Lasers*, 2017, 44(1): 0104001.
- [41] GAO W, ZHANG X, YANG L, et al. An improved Sobel edge detection[C/OL]//2010 3rd International conference on computer science and information technology: Vol 5. IEEE, 2010: 67-71.
- [42] RONG W, LI Z, ZHANG W, et al. An improved CANNY edge detection algorithm[C/OL]//2014 IEEE international conference on mechatronics and automation. IEEE, 2014: 577-582.
- [43] HASSEN R, WANG Z, SALAMA M M. Image sharpness assessment based on local phase coherence[J]. *IEEE Transactions on Image Processing*, 2013, 22(7): 2798-2810.
- [44] GHIASI G, CUI Y, SRINIVAS A, et al. Simple copy-paste is a strong data augmentation method for instance segmentation[C/OL]//*Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2021: 2918-2928.
- [45] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J/OL]. *Advances in neural information processing systems*,

- 2012.
- [46] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C/OL]//International conference on machine learning. PmLR, 2020: 1597-1607.
- [47] CUBUK E D, ZOPH B, SHLENS J, et al. Randaugment: Practical automated data augmentation with a reduced search space[C/OL]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2020: 702-703.
- [48] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection.
- [49] CUBUK E D, ZOPH B, SHLENS J, et al. Randaugment: Practical automated data augmentation with a reduced search space[C/OL]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition workshops. 2020: 702-703.
- [50] ZHONG Z, ZHENG L, KANG G, et al. Random erasing data augmentation[C/OL]//Proceedings of the AAAI conference on artificial intelligence: 卷 34. 2020: 13001-13008.
- [51] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C/OL]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [52] HAN K, WANG Y, CHEN H, et al. A survey on vision transformer[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(1): 87-110.
- [53] LI J, GUAN W. Patch merging refiner embedding UNet for image denoising[J]. Information Sciences, 2023, 641: 119123.
- [54] LIU F, REN X, ZHANG Z, et al. Rethinking skip connection with layer normalization[C/OL]//Proceedings of the 28th international conference on computational linguistics. 2020: 3586-3598.
- [55] AGARAP A F. Deep Learning using Rectified Linear Units (ReLU)[A/OL]. arXiv, 2019.
- [56] JACKSON J D. 经典电动力学[M]. 3 版. 朱培豫, 译. 北京: 高等教育出版社, 2003.
- [57] KIM T K. T test as a parametric statistic[J]. Korean journal of anesthesiology, 2015, 68(6): 540-546.
- [58] 刘婷婷, 王培光, 张娜. 基于 Zernike 矩亚像素的高反光金属工件瑕疵检测[J]. Laser & Optoelectronics Progress, 2019, 56(12).
- [59] WEISSTEIN E W. Least squares fitting[J/OL]. <https://mathworld.wolfram.com/>, 2002.
- [60] Paris S, Kornprobst P, Tumblin J, et al. Bilateral filtering: Theory and applications [J]. Foundations and Trends® in Computer Graphics and Vision, 2009, 4(1): 1-73.
- [61] ZANA F, KLEIN J C. A multimodal registration algorithm of eye fundus images using vessels detection and Hough transform[J]. IEEE Transactions on Medical Imaging, 1999, 18(5): 419-428.

- [62] 彭晶鑫. 基于机器视觉的圆孔形零件尺寸特征检测系统研究[D]. 无锡:江南大学机械工程学院,2021.
- [63] 彭露露. 圆环形汽车钢铁零件瑕疵检测系统[D]. 上海:上海师范大学信息与机电工程学院, 2022.
- [64] CHEN W, SUI L, XU Z, et al. Improved Zhang-Suen thinning algorithm in binary line drawing applications[C/OL]//2012 International Conference on Systems and Informatics (ICSAI2012). IEEE, 2012: 1947-1950.
- [65] JADON S. A survey of loss functions for semantic alignment and shape-based instance segmentation[J]. arXiv preprint arXiv:2006.14822, 2020.
- [66] YU T, KUMAR S, GUPTA A, et al. Gradient surgery for multi-task learning[C]//Advances in Neural Information Processing Systems. 2020, 33: 5824-5836.
- [67] KARNIADAKIS G E, KEVREKIDIS I G, LU L, et al. Physics-informed machine learning[J]. Nature Reviews Physics, 2021, 3(6): 422-440.
- [68] RUAN J, LI J, XIANG S. VM-UNet: Vision Mamba UNet for Medical Image Segmentation[A/OL]. arXiv, 2024.
- [69] LEI M, LI S, WU Y, et al. Yolov13: Real-time object detection with hypergraph-enhanced adaptive visual perception[J/OL]. arXiv preprint arXiv:2506.17733, 2025.

致 谢

从懵懂无知的小学算起，求学十九载的路程即将结束。这一路走来收获了许多，也得到了许多人的帮助。

首先，我衷心地感谢我的研究生导师。他是我科研道路上的引路人。从课题的选定到研究方案的设计，从实验的推进到数据的分析，导师始终以敏锐的学术洞察力和严谨的治学态度为我指明方向。在论文的写作过程中，从初稿的逻辑框架到定稿的字句斟酌，导师都不厌其烦地批注、修改，甚至连一个标点符号的误用都会细心指出。每当我在研究中遇到难题、陷入迷茫时，导师总是耐心地与我讨论，用他渊博的学识和丰富的经验帮我拨开迷雾。他不仅教会我如何做学问，更以身作则地教会我如何做人——那份对科研的敬畏、对学生的负责、对生活的热忱，都将成为我未来人生路上最宝贵的财富。

感谢我的父母，他们给我提供了轻松向上的家庭氛围，理解并尊重我，鼓励并托举我。二十多年来，让我在求学路上从为对生活担忧，是他们为我撑起现在自由的蓝天。我心怀感恩。感谢同门的小伙伴，是他们的陪伴让原本枯燥的科研生活增添了许多欢声笑语，他们的包容与帮助让我在压力之下依然能够保持前行的勇气。

最后真诚感谢百忙之中为本文提供宝贵意见和建议的评审专家和答辩老师。

求学十九载，始于懵懂，终于坚定。这一路所有的遇见与获得，都将化作我继续前行的光。谨以此文，致敬所有帮助过我的人。

个人简历、在学期间的研究成果及发表的学术论文

一、个人简历

姓名：吕非凡，1999 年 11 月出生。

2018.09-2022.06 就读于福建师范大学，通信工程专业，本科，获得工学学士学位；

2023.09-2026.06 就读于福建理工大学，新一代电子信息技术（含量子技术），在读硕士研究生。

二、攻读硕士学位期间发表的论文

[1] Physics-informed deep learning for surface defect detection on optical wedge plates: enhancing accuracy and generalization [J/OL]. Journal of Intelligent Manufacturing, 2026. DOI: 10.1007/s10845-026-02858-8. (JCR 一区，中科院二区，本人二作，导师一作)

[2] A review of optical component defect detection based on deep learning[C/OL]/Fourth International Conference on Advanced Algorithms and Neural Networks ,2024: Vol 13416. SPIE, 2024: 345-353 (IEEE 收录，通信作者)

三、攻读硕士期间申请的专利

[1] 一种基于电磁场先验约束的光学元件缺陷检测方法及其系统 [P].202610091681X (发明专利，第一发明人，实审中)

四、攻读硕士期间参与的科研课题

1、福州市科技重大项目：光学零部件（包括楔形）表面瑕疵及三维形貌检测装备研发和产业化；（2023-ZD-010）

2、福建省科技厅《科技特派团服务龙岩市武平县新型显示产业链专项》2025N0057

五、攻读硕士学位期间获得的奖励

(1) 2024 年，获得校学业奖学金三等奖

(2) 第十五届海峡两岸信息服务创新大赛暨福建省第十九届计算机设计大赛一等奖。