

基于多模态视觉注意力的楔形滤光片自动聚焦方法研究

0 摘要

楔形滤光片在精密光学系统中至关重要,但其特有的倾斜表面给显微成像带来了严峻的自动对焦挑战,导致现有基于三相机协同架构的缺陷检测系统效率低下。传统对焦方法因其迭代搜索机制和无法有效处理多视角关联信息,难以满足高精度、高效率的工业需求。为解决此瓶颈,本研究提出了一种基于多模态视觉注意力的鲁棒自动对焦方法,并构建了对比融合自动对焦网络(CFAN)。该模型以 Swin Transformer 为骨干,创新性地设计了三相机多视角输入架构;引入了视间注意力融合模块(IVAF),通过交叉注意力机制高效聚合多源特征;并采用辅助对比学习任务增强模型对微小离焦差异的判别能力。实验结果表明,CFAN 在离焦距离预测任务上表现卓越,平均绝对误差(MAE)和均方根误差(RMSE)分别达到 $20.6\mu\text{m}$ 和 $24.4\mu\text{m}$,在 $\pm 40\mu\text{m}$ 容差下的预测精度高达 91.51%,显著优于多种主流深度学习模型。此外,针对工业环境中的图像扰动问题,本研究通过在线数据增强策略训练的强化模型 CFAN-R,在面对高强度噪声、亮度及对比度变化时仍能保持高性能,展现出强大的鲁棒性与实际应用价值。本研究不仅为楔形滤光片的自动化检测提供了高效、精准的对焦方案,其所提出的多视角融合与对比学习框架也为解决其他复杂三维表面的精密对焦问题提供了新的思路与技术参考。

1 引言

楔形滤光片(Wedge Filter)作为光场调控领域的核心功能器件,凭借其独特的渐变厚度几何特性,在激光功率管理、高动态成像优化及精密光学测量系统中展现出不可替代的重要作用。这些高端应用的实现,对滤光片的表面质量提出了近乎苛刻的要求,使得高精度的自动化表面缺陷检测成为其生产制造中的关键环节。然而,在楔形滤光片生产过程中,现有表面缺陷检测系统面临严峻的技术瓶颈:受显微成像系统物理特性制约,检测镜头具有微米量级的有限景深,而楔形滤光片表面特有的倾斜楔形结构进一步加剧了显微成像系统的景深覆盖难题。为应对这一挑战,当前检测设备采用三相机协同成像架构:通过固定焦距的三组相机同步拍摄以覆盖完整样本表面。这种特殊架构对自动对焦方法提出了双重挑战:既需要确保中心相机精确聚焦于样本基准面,又需保证两侧相机同步获取偏移区域的清晰成像,这对自动对焦算法构成了严峻考验。

传统自动对焦方法主要基于对比度检测原理,通过分析图像高频分量(如边缘梯度信息)的局部极值搜索实现焦点定位^[1]。尽管此类方法具有亚像素级定位精度,但其固有的迭代搜索机制导致收敛速度受限,且在低照度、低对比度场景下易出现焦点振荡及误判现象^[2]。本研究所涉检测系统特有的三相机协同架构进一步放大了传统方法的局限性:中心相机的聚焦精度直接影响两侧相机的成像质

量，而传统基于对比度的检测算法难以建立多相机间的焦点关联模型，无法精确地将中心相机聚焦于样本中心区域，导致系统级对焦性能显著下降，影响后续缺陷检测任务。

近年来，深度学习技术在计算机视觉领域取得突破性进展，为自动对焦技术革新提供了新的解决思路^[3]。基于深度神经网络的智能对焦方法通过端到端特征学习，能够有效挖掘图像序列中的深度语义信息，在复杂成像条件下展现出超越传统方法的鲁棒性和适应性^[4]。Liao 等人(2021)提出了一种基于改进 MobileNetV3 的轻量级深度学习单次拍摄自动对焦方法，通过单幅离焦图像直接预测焦平面距离，在数字显微镜中实现了亚微米级对焦误差 ($0.68 \pm 0.58 \mu\text{m}$)^[5]；Wang 和 Liu (2025)开发了一种结合自适应区域选择与强化学习的晶圆微成像自动对焦控制方法，通过高斯策略梯度算法实现个性化区域聚焦，使晶圆不同区域的聚焦质量平均提升 4.0%，解决了传统方法在跨区域聚焦中的泛化不足问题^[6]；Pu (2022)设计了稀疏自编码网络(SAE-Net)，通过自监督方式同时实现合成孔径雷达(SAR)成像与自动对焦，在运动误差补偿中优于传统相位梯度算法^[7]；Liu 等人(2022)提出基于深度学习的非迭代式 SAR 自动对焦框架 AFnet 和 PAFnet，以熵损失函数实现实时相位误差校正，聚焦速度较传统最小熵算法提升百倍^[8]；Li 等人(2021)开发了基于双帧输入的深度学习光片荧光显微镜自动对焦系统，通过分类网络预测焦平面偏移量，在存在球差的厚组织成像中仍能保持亚微米级精度^[9]；Li 等人(2024)引入了一种基于优化 VGG 网络架构(ST-VGG)的深度学习自动对焦机制，通过改进卷积层和参数优化来提高效率，并结合全局平均池化和 Inception 架构实现多尺度特征融合，在公开数据集上实现了约 0.02 的验证损失降低^[10]；He 等人(2025)提出了一种基于深度学习的清晰度评估方法(FocusNet-CL)，用于多尺度特征提取和融合，并采用窗口选择综合策略(WSSS)，通过对比学习和全局-局部特征融合动态调整特征权重，在 20 纳米步长下实现了高精度评估，平均绝对误差(MAE)为 11.9210^[11]。上述研究证实了深度学习模型在常规样本自动对焦任务中具有显著精度与效率优势，然而针对楔形滤光片这类特殊光学元件，现有模型表现出显著的泛化性能衰减。其根本原因在于，这些模型大多为单视角输入设计，未能充分利用多相机系统提供的空间关联信息，也未针对性地解决由倾斜表面引入的系统性、非对称离焦问题。为突破这一技术瓶颈，本研究提出了一种面向楔形滤光片鲁棒自动对焦的对比融合自动对焦网络(Contrastive Fusion Autofocus Network, CFAN)。该网络基于 Swin Transformer 架构，通过引入多视角视觉注意力机制与对比学习，旨在高效解决上述挑战。本研究所作贡献如下：

- 提出了一个以三相机视角为输入的适用于楔形滤光片表面聚焦的自动对焦模型框架。

- 提出了一个辅助对比学习模块，使模型能够更加关注到不同电机位置的离焦差异。
- 提出了一种特征融合方法 IVAF (Inter-View Attention Fusion)，有效地提升了三视角之间的特征融合效果，提升了模型性能。

然而，在真实的工业生产环境中，成像系统常受到电磁干扰、光照波动、传感器老化等因素影响，导致采集的图像出现噪声、亮度和对比度变化等问题。一个在理想数据集上表现优异的模型如果缺乏对这些扰动的鲁棒性，其在实际部署中的价值将大打折扣。因此，本研究不仅致力于提升模型在标准条件下的预测精度，还将重点评估并提升模型在复杂工况下的鲁棒性，以确保其在实际应用中的稳定性和可靠性

2 方法

2.1 数据集构建

针对楔形滤光片表面特殊的几何特征，本研究设计了一种多视角联合成像的数据采集系统。实验装置采用三台海康威视 MV-CS040-90UM 工业相机（配备 4 倍物镜），通过分光光学系统实现三个视场分别聚焦于楔形滤光片的上、中、下区域。为充分利用多视角空间关联性，构建基于三相机同步采样的深度学习对焦网络，将同一位点获取的三视角图像作为联合输入样本。数据集构建遵循以下规范流程：首先由专业光学工程师通过精密电动位移台确定中心相机最佳焦面基准位置，以此坐标为原点，沿光轴方向以 $\pm 20\text{ }\mu\text{m}$ 为步长进行双向步进采样。每个采样组包含 101 个轴向位置点（ $-1000\text{ }\mu\text{m}$ 至 $+1000\text{ }\mu\text{m}$ ），每个位置同步采集三视角图像，形成包含 $101 \times 3 = 303$ 张图像的样本组。最终数据集由 84 个独立采样组构成，共计 25,452 张高分辨率工业图像（ 2048×2048 像素），完整覆盖楔形滤光片不同区域的焦平面变化特征。示例数据集图片如图 1 所示。




图 1 位于焦面位置的数据集示例

2.2 网络架构

本文创新性地提出了一种深度学习网络 CFAN（Contrastive Fusion Autofocus Network），旨在精确预测楔形滤光片与焦面之间的位置偏差，进而精确控制电机移动至理想焦面。该模型采用 Swin Transformer^[12]作为骨干网络，能够有效地从同一电机位置捕获的、具有不同聚焦状态的三张图像中提取关键特征。随后，这些特征向量被送入一个精心设计的三视图特征融合模块。通过上述模块的处理，图像特征得以充分混合，并经过显著的过滤与精炼。最终，融合后的特征向量将分别输入至线性回归预测全连接网络以及对比学习特征投影全连接网络，以完成最终的位置偏差预测。




图 2 网络整体架构

2.2.1 三视图输入

为充分利用三相机系统提供的丰富空间与深度信息，本研究创新性地构建了一个以来自上、中、下三个相机视角图像为输入的自动对焦模型。具体而言，模型同时接收三张同步捕获的图像：一张来自上方相机、一张来自中心相机以及一张来自下方相机。这三张图像在空间上垂直分布，各自捕获了楔形滤光片在当前电机位置下不同焦深范围内的细节，共同描绘了倾斜表面在这一瞬时的整体对焦状态，能够为模型提供更全面、更具梯度的深度与模糊模式信息。

在数据预处理阶段，每张原始图像均统一缩放至 256×256 像素分辨率。这三张预处理后的图像被堆叠成一个四维张量作为模型的输入，其维度为 $[B, 3, C, 256, 256]$ ，其中 B 代表批处理大小（Batch Size）， 3 代表上、中、下三个相机的视角， C 代表图像通道数。这种独特的多视角输入设计使模型能够学习并关联不同垂直视角下的离焦信息，从而更鲁棒、更准确地预测整个系统的离焦距离，为后续的缺陷检测任务提供高质量的对焦图像。

2.2.2 对比学习辅助任务

为提升模型在回归任务中的特征判别能力，使其能有效捕捉经不同聚焦获取的图像间的细微差异，进而实现楔形滤光片位置偏差的精确预测，本研究引入了一种辅助性的对比学习策略。对比学习的核心原理在于，通过优化样本在嵌入空

间中的相对位置，使相似样本（正样本对）彼此靠近，不相似样本（负样本对）相互远离，从而学习到对下游任务更具鲁棒性和判别力的特征表示^[13]。

在对比学习分支中，从三幅不同聚焦图像中提取并融合的特征向量，经投影头映射至一个低维嵌入空间，并进行 L2 范数归一化，使其位于单位超球面上。对于输入批次中的每个样本，正负样本对的构建是基于其对应的楔形滤光片位置真值标签：

正样本对 (Positive Pairs): 来源于具有相同楔形滤光片位置标签的图像组所生成的融合特征向量被定义为正样本对。此设定基于假设：尽管采集时的聚焦状态存在差异，但同一物理位置的图像组应蕴含共同的、与楔形滤光片真实位置相关的本质信息。模型的目标函数将引导这些正样本对在嵌入空间中距离最小化。

负样本对 (Negative Pairs): 批次内来源于不同楔形滤光片位置标签的图像组所生成的融合特征向量被定义为负样本对。模型通过最大化这些负样本对在嵌入空间中的距离，以学习更具鉴别力的融合特征，从而提升对位置偏差的预测精度。

本研究采用软标签 InfoNCE (Information Noise-Contrastive Estimation) 损失函数作为对比学习的核心组成部分。软标签 InfoNCE 损失通过为每个潜在的正样本引入一个连续的相似性权重，而非简单的二元判断。该权重与样本间标签的绝对差异呈指数衰减关系，具体由一个可学习的衰减因子 α 控制其衰减速率。这意味着标签值越接近的样本，其在对比损失中作为“软正样本”的贡献越大。这种连续的相似性度量机制，相较于离散的二元标签，更能适应回归任务中标签连续变化的特性，有助于模型学习到更精细的特征梯度。

给定一批次中的 N 个样本，表示为特征嵌入 $p_i \in \mathbb{R}^D$ 及其对应的连续标签 $y_i \in \mathbb{R}$ 。对于批次中的任一样本 p_i ，其与批次内其他样本 p_j 的相似度通过余弦相似度 $s_{i,j}$ 计算，定义如下：

$$s_{i,j} = \frac{p_i \cdot p_j}{\|p_i\| \|p_j\|}$$

软标签 InfoNCE 损失函数 L_{CL} 定义如下：

$$L_{CL} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\sum_{i \neq j} \exp(-\alpha |y_i - y_j|) \cdot \exp(s_{i,j}/\tau)}{\sum_{k \neq i} \exp(s_{i,k}/\tau)}$$

其中， τ 为可学习的温度参数，用于调节相似度分布的平滑度； α 为软标签衰减因子，控制标签差异对正样本权重的贡献； $|y_i - y_j|$ 表示样本 i 和样本 j 之间标签的绝对差异。分子项表示在排除了自相似性后，所有样本与 p_i 的相似度按其标签接近程度进行加权的指数和。分母项则表示在排除了自相似性后，所有样本与 p_i 相似度的指数和。

2.2.2 视间注意力融合模块 (Inter-View Attention Fusion, IVAF)

在多视图图像分析任务中，如何有效地聚合来自不同区域或视角的特征是提升模型性能的关键。传统的特征融合方法，如简单的拼接或加权平均，往往难以充分捕捉视图间的深层语义关联和互补信息。为了克服这一挑战，并在楔形滤光片自动对焦任务中实现更鲁棒的特征表示，我们提出了视间注意力融合模块 (Inter-View Attention Fusion, IVAF)。该模块作为 CFAN (Contrastive Fusion Autofocus Network) 的核心组件之一，旨在通过精细的注意力机制，促进来自三相机同步拍摄图像的特征之间的信息交互与融合。如图 1 所示，IVAF 接收来自三个独立的特征向量 v_1, v_2, v_3 作为输入，这些特征是从三个不同聚焦位置的图像中提取所得，每个特征向量的维度为 D (在我们的实现中， $D=768$)。

为实现视图间的交叉注意力，对于每一个待增强的视图 (作为查询视图)，我们将其特征 $v_1 \in \mathbb{R}^{B \times D}$ 转换为查询 (Query, Q) 向量，通过添加一个维度使其形状变为 $\mathbb{R}^{B \times 1 \times D}$ ，其中 B 为批次大小。与此同时，除 V_1 之外的另两个视图的特征被堆叠起来，共同构建为用于注意力计算的键 (Key, K) 和值 (Value, V) 矩阵，例如，当 V_1 作为查询视图时， V_2 和 V_3 的特征将组合形成 $\mathbb{R}^{B \times 2 \times D}$ 的 K 和 V 矩阵。这种构建方式确保了每个视图在执行交叉注意力时，能够充分利用其他视图提供的上下文信息和语义关联。IVAF 模块的核心是三个并行的多头交叉注意力 (Multi-Head Cross-Attention) 机制，每个注意力模块独立地处理一个视图的查询，并从其他视图的键值对中提取相关信息。具体而言，第一个交叉注意力模块接收 V_1 的特征作为 Q ，并以 V_2 和 V_3 的堆叠特征作为 K 和 V ，此过程产生一个增强的特征 $\hat{v}_1 \in \mathbb{R}^{B \times 1 \times D}$ ；类似地，第二个模块以 V_2 的特征作为 Q ，关注 V_1 和 V_3 ；第三个模块以 V_3 的特征作为 Q ，关注 V_1 和 V_2 ，它们分别输出 $\hat{v}_2 \in \mathbb{R}^{B \times 1 \times D}$ 和 $\hat{v}_3 \in \mathbb{R}^{B \times 1 \times D}$ 。通过采用多头机制，模型能够在不同的表示子空间中并行地捕捉和整合视图间的复杂依赖关系，从而显著提高特征融合的全面性和细粒度。会与其对应的原始视图特征进行残差连接。这种残差结构有助于保留原始特征的重要信息，并缓解训练深层网络时可能出现的梯度消失问题。随后，对相加后的特征应用层归一化 (Layer Normalization)，以稳定特征分布，从而加速模型收敛并提升模型泛化能力。此步骤之后，我们获得三个归一化且信息丰富的视图特征 v'_1, v'_2, v'_3 每个的维度保持为 D 。

最终，这三个经过处理的视图特征 v'_1, v'_2, v'_3 会在特征维度上进行拼接，形成一个维度为 $3D$ 的融合前特征向量 $v_{pre} \in \mathbb{R}^{B \times 3D}$ 。为了进一步捕捉拼接特征中的非线性关系和高阶特征交互，我们引入了一个由多层感知机 (Multi-Layer Perceptron, MLP) 构成的前馈网络 (Feed-Forward Network, FFN)。该 FFN 的

结构为: $Linear(3D, 2D) \rightarrow GELU \rightarrow Linear(2D, 3D)$ 。同样, 为利用残差学习的优势, FFN 的输出再次与 v_{pre} 进行残差连接, 最终生成维度为 3D 的融合特征 $v_{fused} \in \mathbb{R}^{B \times 3D}$ 。IVAF 模块通过上述精心设计的、基于交叉注意力的多阶段融合策略, 能够有效地聚合来自三相机不同视场的特征信息, 并解决多视图数据中的信息冗余和信息互补问题。这种强大的融合能力确保了最终融合特征的丰富性、判别力和鲁棒性, 从而为后续的离焦距离回归任务和对比学习提供了高质量且全面的表示。

2.2.3 损失函数

在损失函数优化阶段, 对比损失 L_{CL} 与主回归任务的平滑 L1 损失 (Smooth L1 Loss) $L_{SmoothL1}$ 通过指数移动平均 (EMA) 动态加权策略进行平衡。平滑 L1 损失能够结合 L1 损失对异常值的鲁棒性和 L2 损失在原点附近平滑的优点, 其定义为:

$$L_{SmoothL1}(x, y) = \begin{cases} 0.5(x - y)^2, & \text{if } |x - y| < 1 \\ |x - y| - 0.5, & \text{otherwise} \end{cases}$$

其中 x 是模型的预测值, 而 y 是真值标签。

最终, 总损失函数 L_{total} 由平滑 L1 损失 $L_{SmoothL1}$ 和动态加权后的对比损失 L_{CL} 组成, 其形式如下:

$$L_{total} = L_{SmoothL1} + \lambda_{CL} \cdot \text{clamp}(R_{EMA}, R_{min}, R_{max}) \cdot L_{CL}$$

其中, λ_{CL} 为初始对比损失权重, $\text{clamp}(R_{EMA}, R_{min}, R_{max})$ 表示将 R_{EMA} 限制在预设的最小值 R_{min} 和最大值 R_{max} 之间, 以避免权重过大或过小, 从而促进模型的稳定收敛并提升整体性能。

3 实验

3.1 训练配置与评价指标

本研究中的模型训练采用以下配置: 所有图像均统一调整为 256x256 像素。网络优化器选用 AdamW, 初始学习率为 0.0001, 并采用线性学习率递减策略。为防止过拟合, 权重衰减 (L2 正则化) 设置为 0.0001。为确保实验的可复现性, 随机数种子固定为 42。训练批次大小 (batch size) 设置为 32, 数据加载过程由 16 个工作线程并行处理, 以提高效率。模型训练与测试均在配备单张 NVIDIA GeForce RTX 4090 显卡的硬件环境下进行。

为了全面评估所提出的 CFAN (Contrastive Fusion Autofocus Network) 在离焦距离预测任务上的性能, 本研究主要采用以下评估指标, 其中 N 为样本总数, y_i 为第 i 个样本的真实离焦距离, $\hat{y}_i$ 为模型预测的离焦距离, $\bar{y}$ 为所有真实离焦距离的平均值:

- 平均绝对误差 (Mean Absolute Error, MAE): MAE 衡量预测值与真实值之间的

平均绝对偏差。

$$MAE = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|$$

- 均方根误差 (Root Mean Squared Error, RMSE): RMSE 衡量预测值与真实值差方均的平方根，对较大误差更为敏感。

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}$$

- 预测精度 (Prediction Accuracy at $\pm\delta\mu m$ tolerance): 该指标评估预测值与真实值之差的绝对值在特定容忍度 δ 内的样本百分比，直观反映模型在实际对焦精度要求下的表现。在本研究中，选取 $\delta = 40\mu m$ 为预测精度评估阈值。

$$Accuracy@ \delta \mu m = \frac{Number\ of\ samples\ where\ |\hat{y}_i - y_i| \leq \delta}{N} \times 100\%$$

3.2 对比实验

为了全面评估本文提出的 CFAN 模型的性能，我们与目前主流的几种深度学习模型进行了对比实验。对比模型包括：MobileNetV3-Large^[14]、Resnet50^[15]、Vit-Base-16^[16]、VGG16^[17]以及 EfficientNetB1^[18]。这些模型在计算机视觉任务中具有代表性，涵盖了不同架构类型，包括轻量级网络、深度残差网络、Vision Transformer 基线模型和经典的卷积神经网络。所有对比模型均在相同的数据集上进行训练和测试，并采用统一的评估指标：平均绝对误差(MAE)、均方根误差(RMSE)以及在 40 μ m 误差范围内的准确率(Accuracy@40μm)。为了确保比较的公平性，所有模型的超参数均经过调优，以达到各自的最优性能。

由表 1 可见，在评估所有模型之后，CFAN 的性能表现最佳。CFAN 模型取得了 20.6 的 MAE 和 24.4 的 RMSE，这远低于所有对比模型。这表明 CFAN 模型在预测的平均误差和误差的离散程度上都具有更高的精确性和稳定性，能够更准确地捕捉目标特征。在准确率方面，CFAN 模型达到了惊人的 91.51%，而其他模型的最高准确率仅为 55.76%(MobileNetV3-Large)。这表明 CFAN 模型在 40μm 的容忍误差范围内，能够进行绝大多数的准确预测，显著提升了模型的实用价值和可靠性。高达 91.51%的准确率证明了 CFAN 模型在关键指标上的卓越性能。

表 1 对比实验结果

Model	MAE	RMSE	Accuracy@40μm
MobileNetV3-Large	44.7	58.8	55.76%
Resnet50	76.0	108.1	40.49%
Vit-Base-16	64.8	99.8	48.67%
VGG16	51.3	67.7	48.67%
EffecientNetB1	58.2	80.9	48.46%
CFAN(Ours)	20.6	24.4	91.51%

3.3 消融实验

为了深入探究本文所提出的 CFAN 模型中各个关键模块和策略的有效性及其对最终性能的贡献,我们进行了一系列严格的消融实验。这些实验旨在逐层剥离或添加模型的特定组件,以量化每个设计选择所带来的性能增益,从而验证其设计的必要性和合理性。我们以 Swin Transformer 作为骨干网络,逐步构建模型,并最终形成完整的 CFAN 架构。所有消融实验均在与对比实验相同的训练配置、数据集划分和评估指标(平均绝对误差 MAE、均方根误差 RMSE 以及在 $40\mu m$ 误差范围内的预测准确率 $Accuracy@40\mu m$)下进行,以确保结果的公平性和可比性。

从表 2 的消融实验结果中,我们可以清晰地观察到 CFAN 模型中每个关键组件对最终卓越性能的累积贡献。以 Swin-Tiny 独立处理单张图像作为基准(MAE $23.0\mu m$, RMSE $28.4\mu m$, Accuracy 81.87%),首先引入多视图输入策略(如 2.2.1 节),模型性能得到初步提升(MAE $22.0\mu m$, RMSE $26.9\mu m$, Accuracy 85.10%),这验证了利用多视角信息应对楔形滤光片倾斜表面聚焦挑战的有效性。在此基础上,集成视间注意力融合模块(IVAF)(详见 2.2.3 节)带来了性能的显著跃升,MAE 降至 $21.1\mu m$, RMSE 降至 $25.3\mu m$,而 Accuracy 大幅提升至 89.94%。这一提升(近 4.84 个百分点)有力证明了 IVAF 通过精妙的交叉注意力机制,有效聚合多视角特征,增强了模型对复杂深度信息的理解和预测精度。随后,引入辅助对比学习策略(如 2.2.2 节)进一步优化了模型性能,MAE 达到 $20.8\mu m$, RMSE 为 $24.6\mu m$, Accuracy 提升至 90.57%。这表明对比学习通过增强特征判别性,使模型能更精准地区分不同电机位置所对应的细微离焦差异。最终,当所有核心组件——包括多视图输入、Swin Transformer 骨干网络、IVAF 模块和辅助对比学习策略——完整集成到 CFAN 模型中时,模型取得了本研究中的最佳性能:MAE 为 $20.6\mu m$, RMSE 为 $24.4\mu m$, $Accuracy@40\mu m$ 达到惊人的 91.51%。这一结果充分验证了 CFAN 整体架构的优越性及其各模块设计的协同增效性,共同构建了一个能够深度理解多视角视觉信息、精确预测焦面位置的智能对焦系统。

表 2 消融实验结果

Model	MAE	RMSE	Accuracy@ $40\mu m$
Swin-Tiny(single image)	23.0	28.4	81.87%
Swin-Tiny	22.0	26.9	85.10%
Swin-Tiny + IVAF	21.1	25.3	89.94%
Swin-Tiny+Contrastive Learning	20.8	24.6	90.57%
CFAN	20.6	24.4	91.51%

3.4 鲁棒性评估与增强

为了检验本文所提出的 CFAN 模型在模拟真实工业环境扰动下的性能表现,我们设计了一系列严格的鲁棒性测试。测试数据集通过对标准验证集施加四种不同类型的数字扰动生成,包括高斯噪声、椒盐噪声、亮度变换和对比度变换,每种扰动均设置了不同的强度等级,以全面评估模型的性能边界。初步测试结果(如表 3 所示)表明,尽管 CFAN 模型在无扰动的标准验证集上取得了高达 91.51%的预测精度($Accuracy@40\mu m$),表现出卓越的基准性能,但其在面对图像扰动时表现出明显的脆弱性。例如,在强度为 10 的高斯噪声下,其精度骤降至 27.10%;而在强度为 0.03 的椒盐噪声干扰下,精度更是断崖式下跌至仅 7.97%。

这表明基线模型 CFAN 对原始训练数据的分布存在一定程度的过拟合，泛化能力不足，难以在充满不确定性的实际工业环境中稳定工作。

为解决基线模型鲁棒性不足的问题，我们引入了一套综合性的在线数据增强（Online Data Augmentation）策略，旨在通过丰富训练数据的多样性，提升模型的泛化能力和对各类图像扰动的抵抗力。我们将经过此策略训练的模型称为 CFAN-R (Reinforced)。具体的增强方案在送入网络前被组合并随机应用，包括几何变换（随机水平翻转概率 $p=0.5$ ，随机旋转范围 -15° 至 $+15^{\circ}$ ）、光照与灰度变换（70% 概率调整亮度和对比度，因子范围 0.7 至 1.3）、噪声注入（20% 概率添加高斯噪声，标准差范围 1.0-5.0；20% 概率添加椒盐噪声，密度范围 0.001-0.005）以及模糊化处理（15% 概率应用高斯模糊， $\text{kernel_size}=3$ ）。所有增强操作之后，图像张量经过标准化处理后送入模型进行训练，其余训练配置与基线模型 CFAN 完全保持一致。

我们对 CFAN-R 模型在同一套标准验证集和鲁棒性测试集上进行了全面的评估，并与基线模型 CFAN 的性能进行了直接对比。详细的实验结果如表 3 所示， $\text{Accuracy@40}\mu\text{m}$ 的变化趋势如图 3 所示。




图 3 CFAN 与 CFAN-R 在鲁棒性测试下的 $\text{Accuracy@40}\mu\text{m}$ 变化

表 3 CFAN 与 CFAN-R 的鲁棒性测试

测试类别	扰动参数	MAE(μm) (CFAN/CFAN-R)	RMSE(μm) (CFAN/CFAN-R)	Accuracy@40 μm (CFAN/CFAN-R)
标准验证	-	20.6/19.4	24.4/24.0	91.51%/89.73%
高斯噪声	5	39.0/20.6	51.0/25.7	61.07%/87.23%
高斯噪声	10	118.1/24.1	161.8/30.7	27.10%/81.76%
高斯噪声	15	202.5/29.0	267.3/39.1	15.63%/74.99%
高斯噪声	20	295.3/36.3	377.4/58.6	10.42%/68.84%
椒盐噪声	0.005	112.2/19.8	165.4/24.2	26.94%/89.00%
椒盐噪声	0.01	212.4/20.2	274.1/24.8	18.34%/88.69%

椒盐噪声	0.02	336.0/ 21.4	414.8/ 26.7	10.47%/ 86.24%
椒盐噪声	0.03	386.9/ 25.3	473.2/ 34.6	7.97%/ 79.94%
亮度变化	0.5	42.3/ 21.1	69.5/ 26.8	63.78%/ 86.71%
亮度变化	0.7	47.0/ 21.4	77.6/ 27.4	59.41%/ 86.09%
亮度变化	1.3	58.1/ 25.8	102.7/ 39.8	56.28%/ 80.72%
亮度变化	1.5	61.0/ 25.7	104.4/ 38.4	50.91%/ 81.03%
对比度变化	0.5	36.3/ 23.1	54.6/ 31.5	67.33%/ 84.00%
对比度变化	0.7	42.8/ 22.7	73.4/ 31.9	62.95%/ 85.88%
对比度变化	1.3	61.3/ 24.4	110.4/ 31.7	51.59%/ 81.14%
对比度变化	1.5	61.4/ 25.8	108.4/ 39.7	51.22%/ 81.50%

3.5 特征可视化实验

为了更直观地揭示本文所提出的 CFAN（Contrastive Fusion Autofocus Network）模型如何有效处理和融合来自多视角的信息，并验证其关键模块（如 IVAF 和对比学习）的实际作用，本节设计了一系列可视化实验。我们旨在通过可视化模型的内部激活状态与注意力分布，揭示其在面对楔形滤光片这种特殊样本时，如精准地捕捉离焦特征并做出判断。我们采用梯度加权类激活映射（Grad-CAM^[19]）技术对模型进行了可视化分析，以理解不同模型变体在进行离焦距离预测时的关注区域。Grad-CAM 能够生成热力图，直观地展示模型在图像中的“注意力”焦点。如图所示，Swin-Tiny 基线模型（单张图像输入）的注意力主要集中在楔形滤光片的部分边缘区域，表明基础骨干网络能够识别边缘等局部清晰度变化，但其关注范围相对有限。在引入辅助对比学习后，模型对楔形滤光片边缘区域的关注面积显著增大，这验证了对比学习通过增强特征判别性，使模型能够更全面地捕捉与离焦差异相关的边缘信息。进一步集成 IVAF 模块后，模型不仅关注楔形滤光片的边缘，还扩展到边缘外部的高频特征区域，并捕捉到更多的边缘细节，这有力证明了 IVAF 通过精妙的交叉注意力机制，有效融合多视角信息，从而增强了模型对复杂深度信息（包括边缘及其周围的精细结构）的理解和利用能力。最终，作为完整模型的 CFAN，表现出对楔形滤光片近乎一半边缘特征的关注，并且其注意力分布在局部特征和全局特征之间取得了更为全面的平衡。这意味着 CFAN 模型能够同时兼顾图像的微观细节和宏观趋势，从而为精确预测离焦距离提供了更丰富、更鲁棒的视觉依据。综上，可视化结果有力地证明了 IVAF 模块和辅助对比学习策略在提升 CFAN 模型对楔形滤光片离焦特征捕捉能力方面的协同增效作用，共同构建了一个对焦性能卓越的智能系统。




图 4 grad-cam 热力图

4 结论

本研究针对楔形滤光片特有的倾斜表面结构及其在工业检测中引发的显微成像景深难题，成功设计并实现了一种基于多模态视觉注意力的鲁棒自动对焦方法。本文创新性地提出并构建了一个名为 **CFAN** 的深度学习网络。该模型巧妙地融合了三相机多视角输入、Swin Transformer 强大的特征提取能力、创新的视间注意力融合模块（IVAF）以及辅助对比学习策略，旨在从根本上解决传统方法在特殊样本上对焦速度慢、精度低且关联性弱的瓶颈问题。

详尽的对比实验结果充分证明了 **CFAN** 模型的卓越性能。在与多种主流深度学习模型的较量中，**CFAN** 在所有关键评估指标上均展现出压倒性优势，其平均绝对误差（MAE）和均方根误差（RMSE）分别低至 $20.6\mu\text{m}$ 和 $24.4\mu\text{m}$ ，并且在 $\pm 40\mu\text{m}$ 容忍度下的预测精度高达 **91.51%**，远超其他对比模型。这一结果有力地表明，本研究所提出的模型框架能够更精确地捕捉和理解由楔形滤光片倾斜表面造成的复杂离焦模式，为后续的高精度缺陷检测任务奠定了坚实的基础。

通过细致的消融实验与特征可视化分析，本研究进一步揭示了 **CFAN** 模型成功的内在机制。实验证明，三视角输入策略为模型提供了应对倾斜表面的丰富空间信息；而核心的 IVAF 模块通过高效的交叉注意力机制，显著提升了多视角特征的融合质量，使模型能够捕捉到更全面的边缘和高频细节。同时，辅助对比学习任务的引入，有效增强了模型对不同电机位置所对应离焦状态的特征判别能力。这些组件的协同作用，最终构建了一个能够深度理解全局与局部特征、实现精准聚焦的智能系统。

此外，本研究还充分考虑了工业应用中的实际挑战，对模型的鲁棒性进行了严格评估与增强。结果显示，通过引入一套综合的在线数据增强策略，强化后的 **CFAN-R** 模型在面对高斯噪声、椒盐噪声、亮度与对比度变化等各类强图像扰动时，依然能保持极高的预测精度，其鲁棒性相较于基线模型实现了质的飞跃。综上所述，本研究不仅为楔形滤光片的自动对焦问题提供了一个创新的、高性能的解决方案，也为其他具有相似复杂三维表面特征的精密光学元件的自动对焦任务提供了有价值的参考，展现了其在复杂工业场景中部署的巨大潜力与应用价值。

尽管 CFAN 模型性能卓越，但模型的架构复杂，依赖 Swin Transformer 和 IVAF 模块，并在高性能的 NVIDIA RTX 4090 上进行测试，这可能给工业边缘设备的实时推理带来挑战，因此未来的研究应聚焦于模型轻量化以满足高通量生产的需求。

参考文献

- [1] Zhang Y, Liu L, Gong W, et al. Autofocus System and Evaluation Methodologies: A Literature Review[J]. *Sensors & Materials*, 2018, 30.
- [2] Zhijie Hua, Xu Zhang, and Dawei Tu, "Autofocus methods based on laser illumination," *Opt. Express* 31, 29465-29479 (2023)
- [3] Chen Li, Adele Moatti, Xuying Zhang, H. Troy Ghashghaei, and Alon Greenbaum, "Deep learning-based autofocus method enhances image quality in light-sheet fluorescence microscopy," *Biomed. Opt. Express* 12, 5214-5226 (2021)
- [4] X. Wei et al., "Improve Deep Learning Autofocus with Depth Information Supervision and Current Focal Distance Cues," 2024 IEEE International Conference on Systems, Man, and Cybernetics (SMC), Kuching, Malaysia, 2024, pp. 1644-1651, doi: 10.1109/SMC54092.2024.10831553.
- [5] Liao J, Chen X, Ding G, et al. Deep learning-based single-shot autofocus method for digital microscopy[J]. *Biomedical Optics Express*, 2021, 13(1): 314-327.
- [6] Wang R, Liu T. Autofocus control using adaptive region selection and reinforcement learning applied in wafer micro-imaging[J]. *Optics Express*, 2025, 33(8): 17345-17354.
- [7] Pu W. SAE-Net: A deep neural network for SAR autofocus[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2022, 60: 1-14.
- [8] Liu Z, Yang S, Gao Q, et al. AFnet and PAFnet: Fast and accurate SAR autofocus based on deep learning[J]. *IEEE Transactions on Geoscience and Remote Sensing*, 2022, 60: 1-13.
- [9] Li C, Moatti A, Zhang X, et al. Deep learning-based autofocus method enhances image quality in light-sheet fluorescence microscopy[J]. *Biomedical Optics Express*, 2021, 12(8): 5214-5226.
- [10] Zhao W. Enhanced Autofocusing with a Compact and Swift ST-VGG Network[J]. 2024.
- [11] He L, Wang X, Wei J. FocusNet-CL: A deep learning approach for clarity assessment of laser direct writing blank samples[J]. *Optics Communications*, 2025: 132087.
- [12] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//*Proceedings of the IEEE/CVF international conference on computer vision*. 2021: 10012-10022.
- [13] Hu H, Wang X, Zhang Y, et al. A comprehensive survey on contrastive learning[J]. *Neurocomputing*, 2024: 128645.
- [14] Koonce B. MobileNetV3[M]//*Convolutional neural networks with swift for tensorflow: image recognition and dataset categorization*. Berkeley, CA: Apress, 2021: 125-144.
- [15] Koonce B. ResNet 50[M]//*Convolutional neural networks with swift for tensorflow: image recognition and dataset categorization*. Berkeley, CA: Apress, 2021: 63-72.
- [16] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. *arXiv preprint arXiv:2010.11929*, 2020.
- [17] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. *arXiv preprint arXiv:1409.1556*, 2014.

- [18] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//International conference on machine learning. PMLR, 2019: 6105-6114.
- [19] Selvaraju R R, Cogswell M, Das A, et al. Grad-cam: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE international conference on computer vision. 2017: 618-626.