

分类号 TP491

密级 公开

学校代码 10388

学号 2231801009



福建理工大学
FUJIAN UNIVERSITY OF TECHNOLOGY

学术型硕士研究生学位论文（毕业）论文

面向智能交通感知系统的楔形滤光片表面 缺陷智能检测技术研究

学 科 专 业： 交通运输工程

研 究 方 向： 智能交通检测

研 究 生 姓 名： 郭琛宇

指 导 教 师、职 称： 郑积仕副教授

所 在 学 院： 人工智能与交通工程学院

答辩委员会主席签名：

二〇二六年五月

一 遵守学术行为规范承诺

本人已熟知并愿意自觉遵守《福建理工大学研究生培养与学位授予工作中学术规范实施办法》的所有内容，承诺所提交的毕业和学位论文是终稿，不存在学术造假或学术不端行为，且论文的纸质版与电子版内容完全一致。

二 独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得福建理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

三 关于论文使用授权的说明

本学位论文作者完全了解 福建理工大学 有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权 福建理工大学 可以将学位论文的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

本学位论文属于（必须在以下相应方框内打“√”，否则一律按“公开论文”处理）：

1、保密论文：☐ 本学位论文属于保密，在_____年解密后适用本授权书。

2、限制级论文：☐ 本学位论文属于延迟公开，在_____年公开后适用本授权书。

3、公开论文：☒ 本学位论文不属于保密和延迟公开范围，适用本授权书。

研究生本人签名：_____ 签字日期：20____年____月____日

研究生导师签名：_____ 签字日期：20____年____月____日

面向智能交通感知系统的楔形滤光片表面缺陷智能检测技术研究

摘要

在智能交通系统全息感知与车路协同技术快速发展的背景下，路侧感知单元成像硬件的物理可靠性直接决定了交通数据的准确性与决策安全性。楔形滤光片作为交通感知系统的核心光学元器件，其表面微小缺陷会显著降低成像信噪比，而传统人工检测方式存在效率低与一致性差等痛点。同时，实现自动化检测面临着由楔形倾斜结构引发的非均匀离焦成像与复杂背景下弱信号缺陷特征难提取的双重技术瓶颈。针对上述挑战，本文以成像质量保障与智能感知检测协同优化为核心主线，开展了从检测装备研制、鲁棒自动对焦算法设计到智能缺陷识别模型构建的系统性研究。

首先，本文开发了集精密运动控制与多视角视觉采集于一体的自动化检测装备。实现了三轴运动平台与三相机成像单元的毫秒级时序协同，设计了分层模块化的软件调度体系，解决了多视角图像同步采集与高精度轴向位移补偿的问题，为算法验证提供了标准化的物理载体。

其次，为解决楔形滤光片倾斜表面导致的视场内非均匀离焦问题，提出了基于多模态视觉注意力的鲁棒自动对焦网络 CFAN。针对传统单视角清晰度评价方法在复杂倾斜表面场景下判定不稳定、易受噪声干扰的局限，构建了三视角协同输入的深度回归架构，将自动对焦建模为离焦距离估计问题。网络以 Swin Transformer 提取多视角图像的局部与全局特征，并通过视间注意力融合机制 IVAF 建模不同视场间的空间关联；同时引入辅助对比学习策略，增强模型对微小离焦差异的判别能力。实验表明，CFAN 实现了 $20.6\mu m$ 的平均绝对误差和 91.51% 的对焦成功率，并具有较好的鲁棒性。

再次，在获取高质量原始图像的基础上，针对暗场环境下划痕与麻点等缺陷对比度低且形态各异的识别困境，提出了融合物理感知引导与解耦注意力的轻量化检测算法 PGA-YOLO。该算法以 YOLO11n 为基准，通过设计深度解耦通道竞争注意力模块 DCCA 实现了特征空间中背景噪声的精准抑制与关键纹理提纯。同时构建了物理感知引导机制 PGM，将梯度与高光残差等确定性物理先验动态注入深度网络，有效弥补了纯数据驱动模型在模糊边界处的判别不确定性。实验验证该算法在保持 4.36ms 低延迟的同时将平均精度均值 mAP@0.5 提升至 0.509，优于主流检测模型。

关键词：智能交通感知，楔形滤光片，表面缺陷检测，自动对焦，深度学习

Research on Intelligent Surface Defect Detection Technology for Wedge Filters in Intelligent Transportation Perception Systems

Abstract

Against the backdrop of the rapid development of holographic perception and vehicle–infrastructure cooperation technologies in intelligent transportation systems, the physical reliability of imaging hardware in roadside sensing units directly determines the accuracy of traffic data and the safety of decision-making. As a core optical component of traffic perception systems, wedge filters are highly susceptible to surface micro-defects, which can significantly reduce the imaging signal-to-noise ratio. Traditional manual inspection methods suffer from low efficiency and poor consistency. Meanwhile, automated inspection faces two major technical bottlenecks: non-uniform defocus imaging caused by the wedge-shaped tilted structure, and the difficulty of extracting weak defect features under complex backgrounds. To address these challenges, this thesis takes the synergistic optimization of imaging quality assurance and intelligent perception-based inspection as its main line, and conducts systematic research ranging from the development of inspection equipment to the design of robust autofocus algorithms and intelligent defect detection models.

First, an automated inspection device integrating precision motion control and multi-view visual acquisition was developed. Based on EtherCAT, millisecond-level temporal coordination between a three-axis motion platform and a three-camera imaging unit was achieved. A hierarchical and modular software scheduling framework as well as a quality traceability database were designed, which solved the problems of synchronous multi-view image acquisition and high-precision axial displacement compensation, thereby providing a standardized physical carrier for algorithm validation.

Second, to address the problem of non-uniform in-field defocus caused by the tilted surface of wedge filters, a robust autofocus network based on multimodal visual attention, namely CFAN, was proposed. To overcome the limitations of traditional single-view sharpness evaluation methods, which are unstable and sensitive to noise in complex tilted-surface scenarios, a three-view collaborative deep regression architecture was constructed, and the autofocus task was formulated as a defocus distance estimation problem. The network employs a Swin Transformer to extract

local and global features from multi-view images, and uses an Inter-View Attention Fusion (IVAF) mechanism to model the spatial correlations among different views. In addition, an auxiliary contrastive learning strategy was introduced to enhance the model's discriminative ability for subtle defocus differences. Experimental results show that CFAN achieves a mean absolute error of 20.6 μm and an autofocus success rate of 91.51%, while maintaining strong robustness.

Third, on the basis of obtaining high-quality raw images, a lightweight defect detection algorithm named PGA-YOLO, which integrates physically guided perception and decoupled attention, was proposed to address the challenge of identifying low-contrast and morphologically diverse defects such as scratches and pits under dark-field conditions. Built upon YOLO11n, the proposed algorithm introduces a Deep Decoupled Channel Competition Attention (DCCA) module to precisely suppress background noise and refine critical texture features in the feature space. Meanwhile, a Physically Guided Mechanism (PGM) was constructed to dynamically inject deterministic physical priors, such as gradient and highlight residual features, into the deep network, thereby effectively compensating for the discriminative uncertainty of purely data-driven models at blurred boundaries. Experimental results demonstrate that the proposed algorithm improves the $\text{mAP}@0.5$ to 0.509 while maintaining a low latency of 4.36 ms, outperforming mainstream detection models.

Keywords: Intelligent Transportation Perception, Wedge Filter, Surface Defect Detection, Autofocus, Deep Learning

目录

摘要	I
Abstract	II
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 智能交通感知系统硬件可靠性研究	3
1.2.2 自动对焦与倾斜表面成像	4
1.2.3 精密光学元件表面缺陷检测	6
1.3 主要研究内容	8
1.4 论文组织结构	8
第二章 自动对焦与缺陷检测机理分析	11
2.1 楔形滤光片倾斜表面的成像机理	11
2.1.1 楔形结构的几何特性与视场高度变化	11
2.1.2 景深限制与非均匀离焦形成机理	12
2.1.3 离焦模糊对微小缺陷可见性的影响	14
2.2 自动对焦问题建模与机理分析	15
2.2.1 自动对焦问题的任务定义	15
2.2.2 基于图像回归的自动对焦原理	15
2.2.3 多视角聚焦建模原理	16
2.3 表面缺陷表征与检测机理分析	17
2.3.1 楔形滤光片表面缺陷类型及成像特征	17
2.3.2 微小缺陷检测的多尺度表征问题	18
2.3.3 目标检测基本原理及其适用性分析	18
2.4 本章小结	19
第三章 基于多模态视觉注意力的鲁棒自动对焦方法研究	20
3.1 自动对焦数据集构建与预处理	20
3.2 对比融合自动对焦网络 (CFAN) 总体架构设计	21
3.3 视间注意力融合机制 (IVAF) 的设计与实现	23
3.4 基于对比学习的特征判别增强策略	24
3.5 本章小结	25
第四章 融合物理感知引导与解耦注意力的缺陷检测	26
4.1 缺陷检测数据集构建与预处理	26
4.2 PGA-YOLO 网络总体架构设计	28

4.2.1 YOLO11n 基准算法简述	28
4.2.2 PGA-YOLO 改进策略概述	29
4.3 深度解耦通道竞争注意力模块 (DCCA)	30
4.3.1 空间-通道特征深度解耦	31
4.3.2 基于 Softmax 的通道竞争机制	32
4.4 物理感知引导机制 (PGM)	33
4.4.1 多维物理先验特征建模	33
4.4.2 物理感知检测头设计	33
4.5 本章小结	34
第五章 实验结果与分析	35
5.1 实验环境与评价指标	35
5.1.1 自动化检测设备与实验环境配置	35
5.1.2 评价指标定义	40
5.2 自动对焦算法性能验证与分析	42
5.2.1 离焦距离回归对比实验	42
5.2.2 视间注意力与对比学习消融实验	43
5.2.3 抗噪性与鲁棒性分析	43
5.2.4 可视化分析与机理解释	45
5.3 缺陷检测算法性能验证与分析	47
5.3.1 缺陷检测算法对比实验	47
5.3.2 改进模块有效性消融实验	48
5.3.3 算法鲁棒性与环境适应性测试	49
5.3.4 可视化分析与机理解释	50
5.4 面向交通感知的光学表面缺陷影响评估实验	53
5.4.1 实验目的与思路	53
5.4.2 表面缺陷建模方法	54
5.4.3 实验结果与分析	55
5.5 本章小结	57
总结与展望	59
参考文献	62
致谢	67
个人简历、在学期间的研究成果及发表的学术论文	68

第一章 绪论

1.1 研究背景与意义

在当前我国深入推进交通强国战略及智慧交通系统 (ITS) 快速发展的宏观背景下, 全息感知与车路协同技术已成为实现交通运输高效治理的关键手段^[1]。作为智慧交通系统的感官终端, 路侧感知单元、高精度监控摄像机及车载视觉传感器等硬件设备, 承担着全天候采集交通流量、识别车辆属性及监测交通冲突等核心任务。感知数据的准确性直接决定了上层交通调度决策的科学性与安全性, 而这种准确性高度依赖于底层精密的光学成像硬件。作为交通感知成像系统中的核心元器件, 楔形滤光片凭借其特殊的物理几何结构, 在抑制杂散光、消除成像鬼影及实现特定波段分光成像方面发挥着不可替代的作用^[2], 是保障交通感知系统在复杂光影环境下视觉感知稳定性的关键物理基础。

然而, 在楔形滤光片的加工制造与薄膜镀制过程中, 由于加工精度限制、工艺参数波动以及材料与环境因素的综合影响, 其表面不可避免地会产生划痕、麻点、崩边等缺陷。楔形滤光片表面缺陷对交通感知系统的影响并非简单的成像质量下降, 而是通过多重物理机制将影响传递至系统决策层。一方面, 楔形滤光片表面缺陷会引发入射光的非理想散射, 叠加的杂散光直接降低图像信噪比; 另一方面, 缺陷可能破坏楔形滤光片原有的鬼影抑制能力, 使强光源 (如夜间车辆大灯) 在像面产生鬼影干扰。这两种退化效应均会削弱后续交通决策系统 (如交通目标检测) 的特征提取能力。在车路协同场景下, 麻点等缺陷模拟的虚假特征可能诱发感知系统的误触发; 在复杂交通环境或极端工况条件下, 此类误触发甚至可能升级为自动驾驶与辅助驾驶算法的系统性误判, 对道路交通运行安全构成潜在威胁^[3]。因此, 楔形滤光片的质检问题, 本质上不是孤立的光学元件检测问题, 而是交通感知系统质量保障链中的关键前置节点。

目前, 针对楔形滤光片等精密光学元件的质量检测仍主要依赖传统的人工目检方式。如图 1-1 所示, 受限于元件尺寸微小及缺陷尺度细微, 检测人员需在高亮度照明条件下长时间进行高强度作业, 极易产生视觉疲劳, 从而导致误检率和漏检率居高不下, 且整体检测一致性与效率难以满足智慧交通基础设施规模化建设对高可靠性与高效率的要求。在此背景下, 研发高精度、高稳定性的自动化智能检测技术已成为保障交通感知硬件质量的必然趋势与紧迫需求。相比于传统人工模式, 自动化检测技术具有显著优势: 其不仅能显著提升检测通量, 满足智慧交通基础设施规模化建设的需求, 更能通过标准化的算法判定消除人为主观差异, 确保检测结果的高一致性与数字化可溯源性, 从而为交通感知系统提供标准化的

硬件质量标准。然而，在实现自动化检测的工程实践中，楔形滤光片特殊的物理几何特性与复杂的表面光学特征带来了双重技术挑战。



图 1-1 楔形滤光片人工缺陷检测

首先是高精度成像层面的聚焦难题。不同于普通平行平面元件，楔形滤光片的待测表面相对于相机成像光轴呈固定的倾斜角度，这使得在利用高倍率工业相机进行图像采集时，受限于光学系统的有限景深，样本表面往往无法全部落在清晰成像范围内。这种特殊的倾斜布局导致图像视野内呈现出非均匀的离焦模糊状态，极大地掩盖了表面微细缺陷的特征信息，使得常规的定焦检测系统难以获取全视野高质量的原始数据。

其次是复杂背景下的缺陷特征提取难题。即使在获取清晰图像的前提下，由于楔形滤光片表面通常具有多层光学镀膜，其缺陷特征往往表现出极低且非均匀的对比度，极易湮灭在复杂的光学背景干扰中。同时，滤光片表面缺陷呈现出极端的多尺度特性，从亚像素级的微小麻点、细长划痕到毫米级的崩边缺陷并存，这对检测模型的多尺度特征融合能力与微小目标捕捉精度提出了严苛要求。此外，为了适配智能交通感知系统对实时性与准确率的双重诉求，检测算法还需在处理复杂光学畸变的同时，保持较高的鲁棒性以降低虚警率。

综上所述，随着智能交通感知基础设施向高可靠与全天候方向演进^[4]，核心元器件楔形滤光片的质量保障已成为提升整体感知识别精度的物理前提。针对当前人工目检一致性差、效率低的痛点，研发高精度自动化检测技术势在必行；然而，受限于楔形结构倾斜表面引发的非均匀离焦模糊，以及复杂光学背景下多尺度、低对比度缺陷的识别困境，要构建一套兼顾鲁棒聚焦成像与智能特征提取的检测体系，不仅是突破精密光学元件自动化质检瓶颈的关键所在，更是从源头保障智慧交通数据可靠性、维护道路交通安全运行的重要技术支撑。

1.2 国内外研究现状

面向智能交通系统的感知技术正经历从单一算法优化向软硬件协同可靠性保障的深度转型^[5]。随着全息感知与车路协同技术的广泛应用，学术界与工业界已逐渐意识到，感知的精度不仅取决于后端深度学习算法的鲁棒性，更取决于前端成像硬件在复杂交通环境下的物理可靠性。楔形滤光片作为路侧感知单元中保障图像信噪比的核心光学组件，其表面缺陷检测已成为精密交通装备制造领域亟待攻克的关键技术。本节将从智能交通感知硬件可靠性、工业自动对焦技术以及表面缺陷检测算法三个维度，对国内外研究现状进行系统梳理与评述。

1.2.1 智能交通感知系统硬件可靠性研究

感知硬件的可靠性作为智能交通系统功能安全与运行效能的前置关键，其研究脉络在全球范围内呈现出既相互印证又各具侧重的显著特征。Kloeker 等人^[6]构建的智能路侧传感器质量评估框架颇具代表性，该框架通过将多模态传感器的精度与延迟置于统一度量体系，揭示了硬件性能波动对自动驾驶决策链路的潜在影响机制。Soltanirad 等^[7]基于对多种感知技术的定量对比分析，论证了多模态融合架构作为保障系统在极端环境下稳健运行的物理根基之必要性。Mohammed 等^[8]对全天候感知系统演进路径的系统性梳理，则着重强调了成像链路中物理退化特征对感知可靠性的根本性约束。Ibanez-Guzman 等^[9]从信息论视角剖析了激光雷达与摄像头的互补特性，指出成像模态的初始数据质量实质上构成了后续深度学习算法性能的上限。Ansariyar 等^[10]开展的实地实验定量刻画了不同能见度条件下交通摄像头的测量误差分布，实证了维持焦平面一致性对于高精度感知的重要价值。这些研究共同推动了可靠性评估范式从传统的故障统计向涵盖性能退化建模、环境适应性及多源协同效能分析的深度转变。前沿探索如 Zhang 等^[11]的工作，进一步将范畴扩展至应对传感器恶意攻击的鲁棒性理论建模，体现了该领域应对新型安全威胁的前瞻性思考。与此同时，面向复杂工程场景与规模化部署需求，相关标准与验证工作亦在同步推进。例如，全国通信标准化技术委员会发布的 GB/T 44417-2024 标准^[12]，从顶层设计上为智能路侧协同控制设备的技术要求与测试方法确立了强制性规范，标志着硬件可靠性已成为系统规模化落地的前置条件。

纵览全局，既有研究长于构建普适性理论框架、探索性能极限边界，也有研究胜在紧密结合实际工程场景推动标准落地与系统性验证，各方路径虽各有侧重，却共同深化了一个核心认知：感知硬件的可靠性是智能交通系统实现可信感知与安全决策的物理基石。任何底层元器件（如楔形滤光片）的微观缺陷，其引发的

成像质量退化都会直接影响后续视觉算法的特征提取,从而降低整个感知系统的决策可靠性。当前研究前沿正日益聚焦于为这些核心元器件建立兼具高精度、强鲁棒性与高效率的智能化质量检测与状态监控体系,旨在从物理源头筑牢智能交通发展的安全防线。

1.2.2 自动对焦与倾斜表面成像

在精密成像与工业检测不断向高分辨率、高可靠性演进的背景下,自动对焦技术已成为保障成像质量与系统稳定性的核心支撑。国内相关研究最初主要围绕基于图像清晰度评价与搜索策略优化的传统自动对焦方法展开。陈川等人^[13]针对显微成像中对焦速度与清晰度难以兼顾的问题,对经典爬山算法的反向搜索判据进行了改进,在不显著增加系统复杂度的前提下有效提升了对焦速度与成像清晰度。杨海等人^[14]则从聚焦与失焦图像特征出发,构建了加权 Tenengrad 清晰度评价函数,并引入模拟退火理论缓解搜索过程中的局部极值问题,进一步将研究拓展至动态图像场景,实现了显微镜在动态观测条件下的实时自动对焦。这类方法以图像评价函数为核心,结构直观、易于工程实现,但其性能高度依赖评价算子的稳定性,在复杂背景或低对比度场景中鲁棒性仍然受限。

随着应用场景的多样化,国内研究逐渐关注特定行业与复杂工况下的自动对焦需求。江阳等人^[15]面向多规格荧光 PCR 耗材成像过程中存在的高度微变与信号不稳定问题,设计了包含粗校准、细校准与水平校准的自动对焦流程,并在细对焦阶段结合二分查找与模拟退火算法实现高精度搜索,有效提升了系统在多规格条件下的适应能力。李才伟^[16]针对病理图像成像一致性要求高、对焦误差易累积的问题,引入固定光斑图案与图像互相关分析策略,实现了对焦位置的稳定判定。杨艳艳^[17]则将基于图像处理的自动调焦方法应用于航空相机,通过函数优化与搜索策略设计,论证了在高空环境扰动下进行焦平面校正的可行性。这些研究体现了国内自动对焦技术从通用显微系统向行业定制化方向的延伸,但整体仍以单视角成像与规则驱动策略为主。

在硬件协同层面,部分研究开始从光学结构与反馈机制入手提升对焦稳定性。张建宏等人^[18]提出了一种适用于荧光显微镜的自动对焦装置,通过监测荧光粒子成像半高宽并实时调节物镜位置,实现了无需改动显微镜内部结构的高灵敏度对焦控制。王小卓等人^[19]面向半导体晶圆表面检测需求,设计了基于分光反馈与压电调节件的实时自动对焦装置,使晶圆在扫描过程中始终保持焦面一致性,从系统层面提升了检测精度。这类方法通过引入额外光学通道或精密执行机构显著增强了对焦可靠性,但对系统成本与集成复杂度提出了更高要求。

在此基础上,国内自动对焦研究逐步引入机器学习与深度学习思想,实现从

经验驱动向数据驱动的转变。刘信良等人^[20]提出融合全局与局部信息的铁谱图像自动对焦方法,利用卷积神经网络与门控循环单元预测离焦距离,在粗对焦与精对焦阶段分别建模全局图像与关键磨粒特征,实现了较高的对焦精度与效率。郑博文等人^[21]进一步将自动对焦问题转化为离焦距离回归任务,构建了基于 ShuffleNetV2 与多层感知机的轻量化深度回归网络,仅需两帧图像即可完成对焦,大幅缩短了对焦耗时并提升了稳定性。这些研究表明,深度学习在减少搜索次数、规避局部极值方面展现出明显优势,但其训练过程依赖大量标注数据,且多针对平面或近似平面成像对象设计。

与国内研究路径相呼应,国外自动对焦技术的发展同样经历了从传统算法到深度学习方法的演进。早期研究主要关注通过图像序列或单幅图像估计焦平面位置,随着深度学习在计算机视觉领域的突破,其端到端特征学习能力被逐步引入自动对焦任务。Li 等人^[22]在光片荧光显微镜中提出基于深度学习的自动对焦方法,通过网络直接预测焦平面偏移量,在存在球差的厚组织成像条件下仍保持亚微米级精度。Liao 等人^[23]进一步提出基于改进 MobileNetV3 的单次拍摄自动对焦方法,仅依赖单幅离焦图像即可预测焦距误差,显著降低了成像与计算成本。为提升复杂场景下的适应性,Wei 等人^[24]引入深度信息监督与当前焦距线索,增强了模型对离焦程度变化的感知能力。

在高精度制造与遥感成像领域,深度学习自动对焦方法呈现出更为多样的技术形态。Wang 和 Liu^[25]将强化学习与自适应区域选择机制引入晶圆微成像自动对焦控制中,通过策略梯度算法实现跨区域个性化聚焦,有效缓解了传统方法泛化能力不足的问题。Pu^[26]提出的 SAE-Net 通过自监督方式同时实现合成孔径雷达成像与自动对焦,在运动误差补偿方面优于经典相位梯度算法。Liu 等人^[27]进一步提出 AFnet 与 PAFnet 框架,利用深度学习实现非迭代式相位误差校正,使 SAR 自动对焦速度较最小熵算法提升两个数量级。针对模型结构优化问题,Zhao 等人^[28]提出紧凑高效的 ST-VGG 网络,通过多尺度特征融合提升了对焦精度与训练效率。He 等人^[29]则从清晰度评价角度出发,构建 FocusNet-CL 模型,结合对比学习与全局—局部特征融合策略,在纳米级步长条件下实现了高精度清晰度评估。

综合现有研究可以看出,自动对焦技术虽在单视角成像条件下取得了较为成熟的发展,但在存在空间结构复杂性和显著离焦不均匀性的成像场景中,其性能仍受到根本性制约。对于具有倾斜或非平面特性的光学对象,单一视角下获取的图像信息往往难以完整刻画不同空间位置的聚焦状态,离焦特征在视场内呈现出显著的非一致分布特性。在此背景下,单视角对焦策略在特征判别能力和稳定性方面均面临天然瓶颈。

因此,从多视角建模的角度重新审视自动对焦问题,充分利用不同观测视角之间的几何互补性与聚焦差异信息,已成为提升复杂场景下对焦鲁棒性的重要研究方向。多视角信息不仅能够对焦平面估计提供额外的空间约束,还有助于缓解单视角成像中由噪声、纹理缺失或局部模糊引起的不确定性。同时,引入对比学习思想,通过显式刻画不同对焦状态之间的相对关系,引导模型学习具有判别性的离焦表征,有望进一步强化对焦特征在空间维度和对焦维度上的区分能力。通过将多视角建模与对比判别机制有机结合,自动对焦研究有望突破传统依赖单一视角与绝对清晰度评价的局限,为复杂光学成像条件下的稳定聚焦提供新的理论与方法支撑。

1.2.3 精密光学元件表面缺陷检测

在智能交通感知系统对成像可靠性要求不断提升的背景下,国内针对光学元件表面与亚表面缺陷检测的研究逐步形成了以光学物理机理为核心的技术体系,并在精密制造与高端装备领域取得了持续进展。邓燕等人^[30]围绕高阈值抗激光损伤光学元件的制造需求,系统研究了基于全内反射显微成像的亚表面缺陷检测方法,揭示了入射光偏振态与角度对不同深度缺陷可见性的调制规律,并通过精密调焦实现了缺陷深度位置的估计,为亚表面缺陷的定量表征提供了重要依据。戈畅等人^[31]则从散射光频谱调制机理出发,将显微拉曼光谱与共焦技术相结合,通过抑制非目标散射信号放大缺陷引起的拉曼峰强变化,实现了对光学元件微小表面缺陷的间接检测。面向更高精度需求,李佳慧等人^[32]对极紫外光学元件全频段面形误差与表面、亚表面缺陷检测技术进行了系统综述,从不同空间尺度误差的形成机理出发,对干涉、散射、电镜与探针等多种检测手段进行了对比分析,并指出检测技术正向智能化与多物理场耦合方向发展。这一阶段的研究充分体现了国内在光学成像机理建模与高精度检测方面的理论深度,但其系统复杂度较高,检测效率与工程适应性仍受到一定制约。

在此基础上,研究重心逐步转向利用成像增强与信号处理手段提升缺陷对比度与检测效率。陈晓辉等人^[33]基于光学元件微缺陷的偏振响应特性,构建了结合偏振成像与数字图像处理的检测流程,通过针对不同缺陷类型设计特征参数,实现了较高检出率与较短单幅处理时间。王鑫森等人^[34]进一步将偏振检测思想引入曲面光学元件检测场景,利用透射式偏振成像显著提升了球面与柱面元件微缺陷的成像对比度,从而改善了复杂曲面条件下的检测稳定性。针对透明光学元件在多光谱检测中面临的照明不均与细节掩盖问题,姜李哲等人^[35]提出了多光谱图像融合与自适应背景补偿相结合的缺陷检测方法,在不同环境条件下保持了较高的检测准确率。与此同时,张传博等人^[36]从多尺度信号分解角度出发,引入非下采

样剪切波变换与 L0 梯度最小化模型，实现了纹理背景与划痕缺陷的有效分离。这类方法在一定程度上降低了传统阈值与边缘算子对人工经验的依赖，但整体仍属于特征驱动范式，其鲁棒性在成像条件发生显著变化时仍存在局限。

随着深度学习技术在工业视觉领域的成熟应用，国内光学元件缺陷检测研究开始由规则驱动向数据驱动转变。马志程等人^[37]针对划痕缺陷细长、尺度差异大的特点，对 Mask R-CNN 模型进行了结构与损失函数层面的改进，通过引入 CSPRepResNet 骨干网络与注意力机制，在保证推理效率的同时显著提升了划痕检测精度。张静等人^[38]以划痕和麻点为典型缺陷，构建了基于改进 U2-Net 的分割模型，在准确率、交并比与召回率等指标上均取得了较优结果，验证了深度学习方法在复杂噪声背景下的特征表达能力。为适配新型显示与半导体制造等应用需求，洪惠敏和贺文俊^[39]从成像系统设计角度提出了宽光谱、大视场显微物镜方案，为获取高质量、多波段缺陷图像提供了硬件支撑。这些研究表明，深度学习已成为提升检测精度与自动化水平的重要手段，但现有工作多假设被测表面近似平行于成像平面，对倾斜结构引发的景深受限问题关注不足。

与国内研究演进路径相对应，国外相关研究同样经历了从传统图像处理到深度学习模型的技术更迭。早期研究普遍依赖阈值分割、边缘检测与形态学分析等方法，其特征表达能力受限于人工参数设定，在复杂工业背景下稳定性不足。随着卷积神经网络的发展，Wang 等人^[40]提出的轻量化 LDSN 系统在光伏缺陷检测中实现了边缘端实时应用，Karimi 等人^[41]通过融合 MobileNet 与 YOLO 架构完成了建筑瓷砖缺陷的自动判定。为刻画更长程的结构依赖关系，He 等人^[42]探索了线性复杂度 Mamba 架构在裂缝分割中的应用，进一步拓宽了工业检测模型的设计思路。在此基础上，Yuan 等人^[43]通过引入 HorNet 与混合注意力机制提升了 PCB 微小缺陷的定位精度，Chen 等人^[44]与 Li 等人^[45]分别针对 Micro-LED 与钢材表面缺陷设计了注意力残差模块与多尺度特征交互策略。面向精密晶圆检测场景，Mei 等人^[46]与 Qiao 等人^[47]将 Transformer 与残差注意力机制相结合，有效缓解了复杂背景对特征提取的干扰。

综合国内外研究可以发现，尽管基于深度学习的检测模型在多尺度特征表达与微小缺陷识别方面取得了显著进展，但现有方法大多建立在理想成像假设之上。对于楔形滤光片这类具有固定倾斜角度的光学元件，显微成像条件下有限景深必然导致视场内出现非均匀离焦模糊，这种由物理成像机制引发的特征退化难以通过单纯的注意力或多尺度结构完全弥补。由此可见，面向智能交通感知系统的楔形滤光片表面缺陷检测，有必要在深度学习框架中显式引入光学物理先验，将成像几何与聚焦机理纳入模型设计之中，以实现聚焦成像与智能检测的协同优化，这正构成了本文进一步研究的出发点。

1.3 主要研究内容

针对智能交通感知系统中楔形滤光片表面缺陷检测面临的非均匀离焦成像与复杂光学背景耦合退化问题,本文以成像质量保障与智能检测协同优化为主线,围绕实际工程检测场景中的关键技术瓶颈,系统开展了检测设备研制、自动对焦方法设计与缺陷检测算法研究,并进一步分析了表面缺陷对交通感知任务性能的影响。主要研究内容如下。

在检测设备研制方面,针对楔形滤光片倾斜表面引起的离焦问题,构建了一套集精密运动控制与视觉采集于一体的自动化检测设备,并建立了多视角同步采集、自动对焦驱动、缺陷检测调用及质量数据管理的整体流程,为复杂光学元件检测提供了标准化实验条件。

在自动对焦方面,针对显微成像中存在的非均匀离焦问题,将自动对焦建模为融合空间结构信息的离焦判别任务,提出了对比融合自动对焦网络 CFAN。该方法采用三视角协同输入架构,结合 Swin Transformer 与视间注意力融合模块 IVAF,实现了复杂倾斜表面下的鲁棒聚焦。

在缺陷检测方面,针对楔形滤光片表面缺陷尺寸小、对比度低且形态差异大的问题,提出了融合物理感知引导与注意力增强的轻量化检测模型 PGA-YOLO。该模型通过 DCCA 强化弱信号缺陷纹理表达,并利用 PGM 引入梯度、结构差分和高光残差等先验信息,提高了复杂背景下微小缺陷的识别精度与稳定性。

此外,围绕智能交通感知系统应用需求,本文还进一步分析了楔形滤光片表面缺陷对交通感知任务性能的影响。通过构建受控的图像退化场景,对划痕、麻点和崩边等典型缺陷引起的成像质量变化进行模拟,并评估其对目标检测结果的影响,揭示了前端光学元器件表面质量与后续感知决策可靠性之间的内在联系。该部分研究从应用层面说明了楔形滤光片表面缺陷检测的重要意义,也为智能交通感知硬件的质量保障提供了进一步依据。

本文围绕楔形滤光片质量保障问题,开展了从检测设备构建到自动对焦与缺陷检测算法设计的系统研究,并进一步分析了表面缺陷对交通感知任务性能的影响,为智能交通感知硬件的制造质量控制与成像可靠性保障提供了技术支撑。

1.4 论文组织结构

针对本文的研究目标与核心技术路线,各章节之间环环相扣,共同构建了从基础理论、系统设计到算法实现与验证的完整研究体系,技术路线图如图 1-2 所示。




图 1-2 技术路线图

全文共分为六章，各章节具体内容安排如下：

第一章为绪论。本章首先论述了在智慧交通战略背景下，楔形滤光片作为感知硬件核心元器件的研究意义，深入剖析了传统人工目检在效率与可靠性方面的局限性。随后，系统梳理了国内外在智能交通感知可靠性、自动对焦技术以及表面缺陷检测算法领域的研究现状，明确了现有技术在处理非均匀离焦与复杂光学背景时的瓶颈。在此基础上，阐述了本文的主要研究内容与技术架构。

第二章为自动对焦与缺陷检测理论基础。本章围绕楔形滤光片表面缺陷智能检测中的关键基础问题展开分析，重点阐述倾斜表面的成像机理、自动对焦问题建模及微小缺陷检测相关理论，为后续 CFAN 自动对焦方法和 PGA-YOLO 缺陷检测方法的提出提供理论支撑。

第三章为基于多模态视觉注意力的鲁棒自动对焦方法研究。针对楔形坡度结构导致的显微离焦难题，本章提出了一种对比融合自动对焦网络 CFAN。详细论述了以 Swin Transformer 为骨干网络的三视角同步输入架构，以及利用交叉注意力机制实现多源特征深度聚合的视间注意力融合模块 IVAF。同时，本章还阐述了辅助对比学习任务的设计原理，通过优化嵌入空间的特征分布提升模型对微小离焦差异的感知能力，并验证了其在模拟工况下的鲁棒性。

第四章为融合物理感知引导与解耦注意力的缺陷检测算法研究。在获得清晰图像的基础上，本章针对微小缺陷特征退化问题提出了 PGA-YOLO 检测模型。重点论述了深度解耦通道竞争注意力模块 DCCA 的设计机理，通过特征解耦与通道重标定抑制背景噪声。此外，本章详细构建了物理感知引导机制 PGM，通过将梯度、结构差分等物理先验动态注入检测头，利用物理几何引导弥补纯数据驱动特征的判定不确定性，实现了对划痕、崩边与麻点的高精度识别。

第五章为实验结果与分析。本章基于构建的工业实测数据集，对本文提出的自动对焦模型与缺陷检测模型开展了实证研究。针对 CFAN 自动对焦模型与 PGA-YOLO 缺陷检测模型，分别进行了消融实验、对比实验，验证了本文模型在精度、速度等关键评价指标上的优势。同时，通过鲁棒性实验探讨了模型在复杂工业环境干扰下的稳定性，并使用模型热力图可视化分析方法，直观揭示了 CFAN 与 PGA-YOLO 在特征表征层面的作用机理。在此基础上，进一步设计了面向交通感知的光学表面缺陷影响评估实验，通过构建受控的图像退化场景，定量分析楔形滤光片表面缺陷对目标检测性能的影响，揭示了光学元件质量与感知系统决策可靠性之间的内在关联。

第六章为总结与展望。本章概括了本文在楔形滤光片自动对焦与智能检测领域取得的主要研究成果与技术结论，客观评价了现有方案的优缺点。最后对未来的模型轻量化、罕见缺陷样本扩充及技术泛化应用等后续研究方向进行了展望。

第二章 自动对焦与缺陷检测机理分析

楔形滤光片表面缺陷自动化检测的核心难点，不仅在于缺陷本身尺度微小、对比度低且易受复杂背景干扰，更在于其特殊楔形结构导致显微成像过程中存在显著的非均匀离焦现象。前者决定了检测模型需要具备对弱信号缺陷的敏感表征能力，后者则决定了在缺陷识别之前必须首先解决清晰成像问题。因此，面向楔形滤光片的智能检测任务，本质上是一个聚焦成像与缺陷检测紧密耦合的协同优化问题。基于此，本章从楔形倾斜表面的成像机理出发，系统分析自动对焦与微小缺陷检测所涉及的基本理论，包括非均匀离焦的形成机制、自动对焦问题的建模思想、微小缺陷的表征特点以及物理先验引导下的智能检测原理，为第三章 CFAN 自动对焦方法和第四章 PGA-YOLO 缺陷检测方法的提出奠定理论基础。

2.1 楔形滤光片倾斜表面的成像机理

楔形滤光片作为一种具有特殊几何结构的精密光学元件，其待测表面并非与成像光轴严格平行，而是以固定倾角相对于成像系统光轴呈倾斜分布。该结构特征虽然使其在抑制杂散光、抑制鬼影以及实现特定光学路径调制方面具有独特优势，但也使其在显微检测过程中呈现出与普通平面光学元件显著不同的成像规律。对于面向微小表面缺陷的自动化检测任务而言，成像链路的物理状态直接决定了后续智能识别算法所能利用的特征上限。因此，有必要从几何结构、焦平面分布以及离焦退化三个层面分析楔形滤光片倾斜表面的成像机理，为后续自动对焦方法与缺陷检测模型的设计提供理论依据。

2.1.1 楔形结构的几何特性与视场高度变化

不同于普通平行平面光学元件，楔形滤光片在厚度方向上沿特定方向呈连续渐变，其表面相对于成像光轴存在固定的倾斜角度。当显微成像系统对该类元件进行表面观测时，视场中不同空间位置对应的样本表面到物镜前端的工作距离并不一致，而是随着横向坐标的变化呈连续变化趋势。楔形滤光片倾斜表面成像几何示意图如图 2-1 所示。这意味着，在同一幅图像中，不同局部区域所处的实际焦面位置并不相同。

为了便于分析，可将楔形滤光片待测表面的高度分布近似表示为：

$$z(x) = z_0 + x \tan \alpha \quad (2-1)$$

其中， z_0 表示参考位置处的表面高度， x 为沿楔形坡度方向的横向坐标， α 为表面相对于理想参考平面的倾斜角。当 $\alpha \neq 0$ 时，表面高度随空间位置变化而变化，导致不同区域的最佳聚焦位置不再重合。对于大视场低倍率成像系统而言，

这种高度差异可能仍可被系统景深部分容纳；但在高倍率显微检测条件下，景深显著减小，楔形结构引起的高度梯度将直接转化为明显的焦面失配现象。由此可见，楔形结构的几何特性是导致后续非均匀离焦问题的根本物理来源。




图 2-1 楔形滤光片倾斜表面成像几何示意图

2.1.2 景深限制与非均匀离焦形成机理

显微成像系统在提升放大倍率与空间分辨率的同时，其有效景深通常显著减小，这意味着系统仅能在有限轴向范围内保持目标区域的清晰成像^[48]。当待测表面起伏范围超过景深容限时，样本表面将无法整体落入同一清晰成像区间，从而造成视场内不同区域清晰度不一致的现象。对于楔形滤光片而言，这种问题尤为突出，因为其表面并非随机起伏，而是沿固定方向持续变化，因此离焦模糊往往表现为具有空间规律性的非均匀分布。有限景深条件下楔形表面非均匀离焦形成示意图如图 2-2 所示。

设显微成像系统当前设定焦面位置为，则视场内任意位置 x 处的离焦量可表示为：

$$\Delta z(x) = z(x) - z_f \quad (2-2)$$

当 $|\Delta z(x)|$ 小于系统允许的景深容限时，该区域可以近似视为清晰成像；当其

超过景深范围时，则会出现不同程度的欠焦或过焦模糊。由于 $z(x)$ 在楔形表面上是连续变化的，因此 $\Delta z(x)$ 同样呈现连续变化趋势，最终导致同一视场内同时存在清晰区、过渡区与模糊区。这种离焦并非传统平面样本中整体前移或整体后移的简单形式，而是空间分布显著不均匀的复杂离焦状态。

从成像本质上看，离焦会引起点扩散函数扩展，从而削弱局部边缘梯度、降低纹理对比度，并引发高频细节损失。对于楔形滤光片这类以微小划痕、麻点和崩边为主要检测目标的任务而言，局部离焦所带来的并不仅仅是视觉模糊，更会直接改变缺陷的可检测性。尤其当缺陷尺寸接近像素分辨率下限时，轻微离焦便可能使原本可区分的边界特征被背景纹理淹没，从而对后续特征提取与分类判定造成连锁影响。




图 2-2 有限景深条件下楔形表面非均匀离焦形成示意图

2.1.3 离焦模糊对微小缺陷可见性的影响

楔形滤光片表面缺陷通常具有尺度微小、对比度低以及形态差异显著等特点。在清晰成像条件下，划痕类缺陷主要表现为细长边缘结构，麻点类缺陷通常体现为局部亮度异常或微小斑状扰动，崩边类缺陷则多呈现不规则边界与明显几何突变。然而，一旦成像系统处于离焦状态，缺陷的这些关键判别特征将受到不同程度的压缩和弱化。清晰成像与离焦成像条件下典型缺陷可见性对比图如图 2-3 所示。




图 2-3 清晰成像与离焦成像条件下典型缺陷可见性对比图

从信号表征角度看，离焦模糊首先会降低缺陷区域与周围背景之间的局部对比度，使原本依赖灰度突变或边缘梯度识别的细节特征趋于平滑。其次，离焦会削弱划痕等细长缺陷的方向性纹理特征，导致其在卷积特征空间中的响应显著下降。再次，当暗场照明条件下存在镀膜纹理、高光残差或非均匀散射背景时，离焦往往会进一步加剧背景干扰，使弱信号缺陷更容易与非缺陷区域发生混淆。因此，离焦退化不仅降低图像主观清晰度，更会改变缺陷特征在统计分布和深度特征空间中的可分离性。

由此可见，在楔形滤光片自动化检测任务中，自动对焦并不是一个独立于缺陷检测之外的附属步骤，而是决定后续识别上限的前置环节。只有在复杂倾斜表面条件下获得尽可能一致且清晰的原始图像，后续缺陷检测模型才能充分利用微弱纹理、局部边缘与多尺度几何信息，实现稳定可靠的缺陷判别。这也说明了本

文后续将自动对焦与缺陷检测作为协同优化问题加以研究的必要性。

2.2 自动对焦问题建模与机理分析

在楔形滤光片表面缺陷自动化检测任务中，自动对焦的核心目标是根据当前成像状态快速确定最优焦面位置，从而为后续缺陷识别提供清晰、稳定且具有一致性的原始图像。对于普通平面样本，自动对焦通常可以近似看作寻找单一全局最优焦点的问题；然而对于楔形滤光片这类具有固定倾斜结构的复杂光学元件，由于视场内不同区域对应的最佳成像位置并不一致，焦面判定不再是简单的单峰搜索问题，而需要从整体成像状态出发，对复杂空间结构下的离焦分布进行综合分析。

2.2.1 自动对焦问题的任务定义

从任务本质上看，自动对焦是一个由图像观测反推焦面偏移量并完成位置补偿的闭环调节过程。其最终目标并非单纯提高主观视觉清晰度，而是在满足检测任务需求的前提下，使采集图像尽可能保留表面缺陷的细粒度纹理、局部边缘和灰度变化信息。对于楔形滤光片检测而言，自动对焦的意义在于克服倾斜表面引起的非均匀离焦退化，为后续缺陷检测模型提供稳定的输入基础。

为便于建立统一建模框架，本文将自动对焦问题抽象为离焦距离估计问题。设最优焦面位置为 z^* ，系统当前焦面位置为 z_t ，则当前状态下待补偿的离焦距离可表示为：

$$d = z^* - z_t \quad (2-3)$$

其中， d 表示待补偿的离焦距离。当 $d > 0$ 时，系统需要沿光轴正方向调整；当 $d < 0$ 时，则需要沿相反方向补偿；当 d 接近于0时，表明系统已到达或接近最佳聚焦状态。由此，自动对焦任务可转化为：根据输入图像直接预测离焦距离 d ，并以此作为后续控制补偿的依据。相较于将自动对焦视为离散搜索过程，上述建模方式能够将图像特征与焦面偏移量之间建立起直接映射关系，使系统从“评价函数驱动的逐步试探”转向“数据驱动的直接估计”。这不仅有利于减少对焦搜索次数，提高系统响应效率，也更适合处理楔形滤光片这类焦面分布复杂、局部清晰度响应不稳定的特殊成像对象。

2.2.2 基于图像回归的自动对焦原理

基于图像回归的自动对焦方法，其基本思想是利用数据驱动模型直接学习图像表征与离焦距离之间的映射关系，从而由输入图像直接输出当前成像状态相对于最佳焦面的偏移量。与传统依赖清晰度评价函数和迭代搜索策略的自动对焦方

式不同，图像回归方法不再显式构造某一人工定义的聚焦评价指标，而是通过网络从训练样本中自动提取能够表征离焦程度的特征，并通过端到端优化实现焦面偏移估计。

从特征学习角度分析，离焦图像与清晰图像之间的差异主要体现在边缘锐度、高频响应、纹理保真度以及局部对比度等方面。随着焦面偏移量变化，这些表征信息会呈现出连续而非离散的演变规律。

因此，离焦距离本质上是一个与图像特征连续相关的物理量，适合采用回归方式建模。设输入图像为 I ，回归模型记为 $f(\cdot)$ ，则自动对焦的图像回归过程可表示为：

$$\hat{d} = f(I) \quad (2-4)$$

其中， $\hat{d}$ 为模型预测的离焦距离。训练阶段通过最小化预测值与真实离焦标签之间的误差，使模型逐步学习不同离焦状态下图像特征的内在变化规律；测试阶段则根据模型输出的离焦距离直接指导 Z 轴补偿，从而实现快速自动对焦。

对于楔形滤光片检测任务而言，基于图像回归的自动对焦具有三方面优势。首先，该方法能够直接从图像整体特征中估计焦面偏移，而不依赖单一局部区域的清晰度变化，因此更适合处理视场内清晰度分布不均匀的复杂场景。其次，图像回归方法可避免传统搜索策略中多次采样、反复迭代所带来的时间开销与误差累积问题，从而提高系统对焦效率。再次，在深度学习框架下，模型可自动融合局部纹理与全局上下文信息，从而在存在噪声干扰、弱纹理区域或复杂背景散射的情况下仍保持较好的判别稳定性。

然而，图像回归虽然能够较好地描述离焦量与图像表征之间的连续映射关系，但当输入图像只来自单一视角时，其特征表达仍然可能受到局部纹理缺失、视场不均匀模糊以及噪声扰动的影响。特别是在楔形倾斜表面条件下，单视角图像往往只能反映局部区域的聚焦状态，难以完整刻画整个位姿下的全局焦面分布。因此，为进一步提升复杂场景下的对焦鲁棒性，还需要在回归建模的基础上引入多视角协同表征机制。

2.2.3 多视角聚焦建模原理

楔形滤光片表面的特殊几何结构决定了不同空间位置对应不同的离焦状态，因此单一观测视角通常只能描述局部区域的清晰程度，而难以完整反映整个样本表面的聚焦分布。当自动对焦任务仅依赖单幅图像进行判断时，模型容易受到局部纹理强弱、背景噪声或区域性模糊的影响，进而导致焦面偏移估计不稳定。

从几何约束角度分析，多视角成像通过在不同空间位置同步采集样本图像，

可以从多个观测维度共同反映同一楔形表面的焦面状态。由于这些视场分别对应样本表面的不同区域，它们之间并非彼此独立，而是共同受楔形坡度结构支配，因此不同视角中的清晰度变化具有内在关联。当某一视角下局部区域出现明显模糊时，其他视角中可能仍保留与其相关的几何线索与结构特征。通过对这些多源信息进行联合建模，可以有效缓解单视角条件下由局部不确定性带来的判断偏差，从而提高焦面估计的稳定性与准确性。

从特征表达角度分析，多视角输入不仅能够扩展模型对样本空间结构的感知范围，还可以使网络学习不同视场之间清晰变化的相对关系。这种相对关系对于判断焦面偏移方向与偏移幅度具有重要意义。尤其在楔形滤光片检测任务中，上、中、下三个视场具有固定空间布局，其成像状态共同反映了表面坡度与当前焦面之间的匹配关系。因此，多视角聚焦建模并不是简单地增加输入通道数量，而是通过引入空间互补信息，使模型从局部清晰判断提升为对整体聚焦结构的综合感知。

2.3 表面缺陷表征与检测机理分析

在楔形滤光片表面缺陷自动化检测任务中，缺陷识别并不是对普通工业目标的常规定位问题，而是一个兼具弱信号表征、多尺度识别与复杂背景抑制特征的精细视觉判别过程。楔形滤光片作为交通感知成像链路中的关键光学元件，其表面质量直接影响后续图像信噪比、鬼影抑制能力以及交通目标识别的稳定性。一旦划痕、麻点或崩边等缺陷未被及时识别并剔除，存在问题的元件进入实际感知系统后，可能进一步引发成像质量下降和目标检测性能退化。

2.3.1 楔形滤光片表面缺陷类型及成像特征

楔形滤光片在加工、镀膜与搬运过程中，表面容易产生划痕、麻点和崩边等典型缺陷。这些缺陷在几何形态、空间尺度以及成像表现上具有明显差异。划痕通常表现为长度较大、宽度较小的细长线性结构，具有明显方向性；麻点多表现为局部微小斑状异常，面积较小但数量较多；崩边则通常出现在元件边缘区域，表现为较大尺度的不规则缺口或边界破损。不同类型缺陷在图像中的灰度响应形式并不统一，有的表现为暗纹，有的表现为高亮残差，还有的以边缘突变方式出现，这使得统一建模的难度显著增加。

从成像特征角度看，楔形滤光片表面缺陷具有三个显著特点。其一，缺陷信号整体较弱，局部灰度变化幅度有限，在暗场成像条件下往往仅呈现细微纹理扰动；其二，缺陷与背景之间缺乏稳定、统一的对比关系，容易受到镀膜纹理、高光反射及散射噪声影响；其三，缺陷尺度跨度较大，从微小麻点到细长划痕再到

边缘崩损共同存在,使得单一尺度的特征提取方式难以同时兼顾细节敏感性与全局判别能力。对于深度学习模型而言,这意味着缺陷并不总是以高显著目标形式出现,而更接近于隐藏在复杂背景中的弱异常模式。

此外,楔形滤光片表面通常伴随多层光学镀膜,其表面纹理和局部反射特性会对缺陷成像产生干扰。一方面,镀膜纹理可能在空间频率上与划痕等细长结构相近,增加误检风险;另一方面,光照条件变化会改变局部高光残差与边缘响应,使同一类缺陷在不同样本中的表观分布呈现较大波动。因此,面向该类对象的缺陷检测不能仅依赖简单的亮度差异,而需要综合利用边缘、结构、纹理与上下文信息进行联合判别。

2.3.2 微小缺陷检测的多尺度表征问题

多尺度特征表达是楔形滤光片表面缺陷检测中的核心问题之一。对于微小麻点而言,其目标区域往往仅占图像极少部分,若经过多次下采样,极易造成关键信息丢失;对于划痕而言,虽然长度可能较大,但宽度极窄,属于典型的细长弱纹理目标;对于崩边而言,其整体尺度较大,但边缘形态复杂,需要同时关注局部轮廓与整体结构。由此可见,这一检测任务既要求模型能够保留高分辨率局部细节,又要求其具备一定的全局感受野,以避免因只关注局部噪声而产生误判。

在深度特征提取过程中,不同层级特征具有不同优势。浅层特征更适合描述边缘、纹理和局部灰度突变,对微小缺陷的初始响应更敏感;深层特征则包含更丰富的语义与上下文信息,更适合进行目标类别判别和背景抑制。对于楔形滤光片缺陷检测任务,若模型过度依赖深层特征,容易削弱对小尺度弱信号的感知能力;若只依赖浅层纹理,又容易将镀膜纹理和散射噪声误识别为真实缺陷。因此,需要在多尺度特征融合中同时兼顾局部敏感性和全局判别性。

2.3.3 目标检测基本原理及其适用性分析

从任务定义上看,楔形滤光片表面缺陷检测属于典型的目标检测问题,其基本目标是在输入图像中同时完成缺陷位置定位与缺陷类别判定。与单纯的图像分类任务相比,目标检测不仅需要判断图像中是否存在异常,还需要给出缺陷的空间位置、尺度范围以及类别属性;与语义分割任务相比,目标检测在保持较高识别能力的同时,通常具有更低的标注成本和更高的推理效率,因此更适用于工业质检场景中的快速部署需求。

当前主流目标检测方法大致可分为两阶段检测器与单阶段检测器两类。两阶段方法通常先生成候选区域,再进行分类与回归,具有较高定位精度,但模型复杂度和推理时延相对较大;单阶段方法则直接在特征图上完成目标类别与边界框

回归,具备更好的实时性和工程部署优势^[49]。面向楔形滤光片检测设备的实际应用场景,模型不仅需要具备较高识别精度,还需兼顾轻量化与低延迟,因此单阶段检测框架更符合实际需求。

然而,通用目标检测框架通常面向自然场景目标设计,对于楔形滤光片表面缺陷这类低对比度、小尺度、弱边界目标,仍然存在三方面局限。首先,通用检测器往往更擅长学习显著区域,对微小弱信号的响应不足;其次,在复杂光学背景下,模型容易受到纹理噪声、高光残差和散射伪影干扰,导致误检率升高;再次,纯数据驱动的特征方式虽然具有较强学习能力,但在缺陷边界模糊、样本数量有限时,特征分布容易出现不稳定现象。因此,若要将目标检测有效应用于楔形滤光片质检任务,必须针对其物理成像特点和缺陷视觉特征进行有针对性的结构增强。

2.4 本章小结

本章围绕楔形滤光片表面缺陷智能检测任务的理论基础展开分析,系统阐述了自动对焦与缺陷检测所涉及的关键物理机理与建模思想。首先,从楔形滤光片倾斜表面的几何特性出发,分析了显微成像条件下视场高度变化、有限景深约束以及非均匀离焦形成的内在原因,揭示了离焦模糊对微小缺陷边缘、纹理与局部对比度的削弱作用,说明了清晰成像是实现高精度缺陷识别的前提。其次,从任务建模角度出发,将自动对焦问题抽象为离焦距离估计问题,进一步论述了基于图像回归的自动对焦原理以及多视角聚焦建模的合理性,为后续构建面向复杂倾斜表面的鲁棒自动对焦方法奠定了理论基础。再次,针对楔形滤光片表面划痕、麻点和崩边等典型缺陷的视觉表现,分析了其弱信号、多尺度及复杂背景干扰下的表征特性,阐明了目标检测框架在该任务中的适用性,并从注意力增强与物理先验引导两个层面说明了提升微小缺陷检测稳定性和判别能力的必要性。综上,本章从成像物理、任务建模与特征表征三个层面建立了楔形滤光片自动对焦与缺陷检测的理论分析框架,为第三章 CFAN 自动对焦方法和第四章 PGA-YOLO 缺陷检测方法的提出提供了理论依据。

第三章 基于多模态视觉注意力的鲁棒自动对焦方法研究

楔形滤光片作为路侧感知单元的核心光学元器件,其表面缺陷检测精度直接制约着交通感知数据的源头质量。然而,该元件倾斜表面引发的非均匀离焦退化,是制约其检测精度的核心物理瓶颈。若无法获取清晰的显微图像,微小缺陷将被淹没于模糊背景中,最终可能导致存在缺陷的元件流入交通感知系统从而威胁交通运行安全。

由于楔形结构导致视场内焦深分布极不均匀,传统的基于梯度搜索的单视角对焦方法在面对非对称离焦特征时,往往表现出收敛速度慢、精度不足且易受环境扰动干扰的局限性。针对这一难题,本章提出了一种基于多模态视觉注意力的鲁棒自动对焦网络 (Contrastive Fusion Autofocus Network, CFAN)。该研究不再局限于单一视角的局部清晰度评估,而是通过多视角协同建模与对比学习机制,显式刻画倾斜表面的空间聚焦关联。本章将从数据集构建、网络架构设计、对比学习机制及视间注意力融合机制四个维度展开论述,旨在为精密光学元件的自动化对焦提供一套具备物理感知能力的深度学习解决方案。

3.1 自动对焦数据集构建与预处理

高质量的标注数据是训练稳健自动对焦模型的基础支撑。针对楔形滤光片特殊的几何属性,本研究依托第二章所述的硬件平台,设计了一套多视角联合成像的数据采集方案。该方案利用三台海康威视 MV-CS040-90UM 工业相机配合 4 倍显微物镜,通过分光光学系统将视场分别映射于楔形表面的上、中、下三个关键区域。这种多视角设计旨在利用不同焦深范围内图像纹理的差异性来弥补单视角深度感知的不足,从而为模型提供更具梯度的模糊模式信息,使系统能够从全局视角感知离焦状态的演变。

在具体的采样流程中,实验首先由专业光学工程师通过精密调试确定中心相机的最佳焦面作为基准坐标原点(0 位置)。随后,驱动 Z 轴伺服电机在 $-1000\mu\text{m}$ 至 $+1000\mu\text{m}$ 的轴向范围内执行步进采样。为了捕捉细微的离焦变化特征,采样步长设定为 $20\mu\text{m}$,每个独立位置均同步触发三台相机捕获当前位点的图像组,从而形成涵盖从严重离焦到精确聚焦完整过程的 101 个轴向采样点。为增强模型在复杂工业环境下的泛化能力,采集工作共覆盖 84 个独立的楔形滤光片采样组,总计生成了 25,452 张分辨率为 2048×2048 的高分辨率原始图像。并按照采样组将 84 组数据随机划分为训练集、验证集和测试集,划分比例为 7 : 1 : 1。数据集示例如图 3-1 所示。在数据组织形式上,每组输入样本由同一电机位置同步捕

获的三张不同视角图像堆叠而成,这种时空耦合的标注方式确保了模型能够学习到不同视角间离焦特征的内在关联规律。

数据预处理阶段对于提升深度学习网络的训练效率与收敛稳定性具有重要意义。考虑到原始图像分辨率过高会带来巨大的计算开销,所有原始图像在送入网络前均通过双线性插值算法统一缩放至 256×256 像素分辨率,并被归一化处理后堆叠为四维张量以适配多视角输入架构。此外,为了还原工业现场真实存在的成像扰动,研究在训练过程中引入了在线数据增强策略。该策略在模型训练迭代时,以一定概率随机注入高斯噪声、椒盐噪声以及动态调整图像的亮度与对比度。这种强化训练机制旨在模拟光照波动与传感器热噪声,引导模型摆脱对特定理想训练分布的过拟合,使其在面对低信噪比图像时,依然能够稳定提取对离焦状态具有判别性的边缘与纹理特征,从而为后续 CFAN 网络的特征融合与高精度距离回归奠定坚实的实证基础。




图 3-1 自动对焦数据集示例

3.2 对比融合自动对焦网络 (CFAN) 总体架构设计

为了构建一套能够深度适应楔形滤光片倾斜表面几何特征的鲁棒自动对焦系统,本研究提出了一种基于对比融合机制的端到端深度学习架构 CFAN。该网络的设计初衷是将自动对焦任务从传统的图像清晰度评价函数搜索问题,重构为基于空间结构感知的离焦距离回归问题。针对第二章所述的三相机协同成像系统,CFAN 构建了如图 3-2 所示的多支路并行网络架构,旨在通过深度挖掘多视角图

像间的时空关联，精确预测当前位置与理想焦面之间的微米级偏差。在输入端，模型接收来自同一电机位置同步捕获的三张图像，分别对应楔形滤光片的上部、中部及下部视场。这三张图像虽然在物理空间上处于同一时刻，但由于楔形表面的倾斜特性，它们各自呈现出不同的离焦程度与模糊模式，蕴含了关键的空间离焦梯度信息。为了完整保留这一物理约束，预处理后的图像被堆叠为一个维度为 $[B, 3, C, H, W]$ 的四维张量送入网络，从而实现了多视角数据的统一输入。




图 3-2 CFAN (Contrastive Fusion Autofocus Network) 网络整体架构图

数据进入网络后，首先通过参数共享的骨干网络进行独立的特征编码。本文选用 Swin Transformer^[50]作为特征提取骨干，主要因其特有的移动窗口机制能够高效地平衡局部特征与全局上下文信息的捕获能力。对于自动对焦任务而言，理解不同离焦程度下的纹理渐变等局部细节与整体结构信息至关重要。通过孪生架构设计，Swin Transformer 能够有效地从三张具有不同聚焦状态的图像中提取出处于同一语义空间的关键特征向量，将高维像素信息映射为包含丰富纹理细节的深层表征。

来自不同视角的特征向量不再是孤立处理，而是被送入视间注意力融合模块 (IVAF)。该模块利用交叉注意力机制在特征维度上建立三者之间的深层关联，通过混合与精炼，聚合出能够表征当前系统整体离焦状态的全局特征描述符。最终，融合后的特征被分流至两个功能不同的预测头：回归头负责直接输出当前位置与理想焦面之间的微米级偏差值，用于驱动 Z 轴电机执行闭环补偿；投影头则将特征映射至低维嵌入空间，用于计算辅助对比学习损失。这一设计旨在增强

模型对微小离焦差异的判别敏感度，使其能够区分极窄范围内的聚焦状态变化，从而实现从多视角原始图像到高精度电机控制指令的端到端映射。

3.3 视间注意力融合机制 (IVAF) 的设计与实现

在多视角图像分析任务中，如何有效地整合来自不同物理视域的特征信息是提升模型整体性能的关键。传统的特征融合方法通常采用简单的通道拼接或加权平均策略，这种浅层的聚合方式往往难以充分捕捉视角之间深层的语义关联与互补信息，导致关键的离焦梯度特征在传输过程中发生衰减或混淆。为了克服这一局限并构建更具鲁棒性的特征表征，本研究提出了视间注意力融合模块作为 CFAN 网络的核心组件。该模块旨在通过细粒度的注意力机制，促进三个同步相机捕获的特征在语义维度上进行深度交互。IVAF 接收三个独立的特征向量 v_1, v_2, v_3 作为输入，这些特征分别由骨干网络从上、中、下三个视角的图像中提取而来，且具有相同的特征维度 D 。

IVAF 模块的核心架构由三个并行的多头交叉注意力机制构成，其设计思想是让每一个视角都作为查询者，去主动检索并聚合其他视角中的互补信息。为了实现这一跨视角注意力交互，对于任意一个待增强的视角（例如 v_1 ），模块首先将其特征映射为查询向量 Q ，同时将剩余两个视角（例如 v_2 和 v_3 ）的特征在序列维度上进行堆叠，共同构建键向量 K 与值向量 V 。这种构造方式确保了每一个视角在进行特征更新时，都能充分利用其他视角的上下文信息与语义线索。随后，利用多头注意力算子并行地计算查询向量与键向量之间的相关性得分，并据此对值向量进行加权聚合。通过这种机制，模型能够自适应地关注那些对当前离焦状态判断最具贡献的视角特征，从而在特征子空间中捕获复杂的视间依赖关系。

为了进一步提升特征的表达能力并防止梯度消失，IVAF 在交叉注意力输出端引入了残差连接与层归一化结构。每一个经由注意力机制增强后的特征向量，首先与原始输入特征进行残差相加，保留了原始视角的固有信息，随后通过层归一化操作稳定特征分布，加速模型的收敛过程。经过上述处理，三个视角特征被更新为归一化且富含全局语义的向量 v'_1, v'_2, v'_3 。最后，这些特征在通道维度上被拼接为一个维度为 $3D$ 的融合向量 v_{pre} ，并送入一个由前馈神经网络 FFN 构成的非线性变换层。该 FFN 包含两个线性层与一个 GELU 激活函数，旨在进一步挖掘特征内部的高阶非线性关系。输出结果再次经过残差连接后，生成最终的全局融合特征 v_{fused} 。通过这一系列严密的交叉融合与精炼操作，IVAF 模块有效地解决了多视角数据中的信息冗余与互补性问题，为后续的离焦距离回归与对比学习任务提供了高质量的特征底座。

3.4 基于对比学习的特征判别增强策略

尽管回归头能够直接预测离焦距离,但在处理楔形滤光片这种具有连续变化特征的样本时,单纯的回归损失往往难以在特征空间中显式地拉开不同离焦状态之间的分布距离。为了进一步提升模型对微小离焦差异的判别敏感度,本研究引入了对比学习作为辅助任务。该策略通过显式优化样本在嵌入空间中的流形结构,强制模型学习近邻相似、远邻排斥的特征表示^[51],从而为回归任务提供更具判别力的特征底座。在 CFAN 网络的训练过程中,视间注意力融合模块 (IVAF) 输出的融合特征向量被同时送入回归头与投影头。投影头由两层多层感知机构成,旨在将高维语义特征映射至低维嵌入空间,以过滤掉与定位任务无关的冗余信息。设输入批次大小为 N ,对于第 i 个样本,其融合特征经投影与 L2 归一化处理后得到嵌入向量 p_i 。为了衡量样本间的特征相似性,本文采用余弦相似度作为度量标准。对于批次内的任意两个样本 i 和 j ,其相似度 s_{ij} 定义为:

$$s_{ij} = \frac{p_i \cdot p_j}{\|p_i\| \|p_j\|} \quad (3-1)$$

其中,分母项表示向量的 L2 范数乘积。该度量方式将特征约束在单位超球面上,使得模型专注于优化特征向量的方向差异而非模长,从而对光照变化等幅度干扰具有更好的鲁棒性。传统的对比学习通常针对大规模分类任务设计。传统 InfoNCE 损失函数^[52]通常将同一实例的不同增强视图视为正样本,将批次内其他样本视为负样本,并通过拉近正样本、推远负样本的方式优化特征空间。其基本形式可表示为:

其中, p_i 为锚点样本特征, p_j 为正样本特征, p_k 为负样本特征, s_{ij} 表示余弦相似度, τ 为温度系数。该损失函数适用于类别边界清晰的实例判别任务,但对于楔形滤光片自动对焦任务并不完全适用。原因在于,离焦距离是一个连续变量,轴向位置相近的样本在成像模糊程度、边缘锐度和纹理响应上通常具有较高相似性。若直接采用传统 InfoNCE,将这些相邻离焦位置的样本全部作为负样本处理,会使模型把本应相近的特征强行拉远,从而不利于学习连续离焦变化规律。

因此,本文在传统 InfoNCE 的基础上引入基于离焦距离的软标签权重,使样本之间的对比关系由“正/负二元划分”转变为“按离焦距离连续加权”。对于与锚点离焦距离接近的样本,赋予较高相似度权重;对于离焦距离差异较大的样本,则赋予较低权重。这样可以使模型在增强相近离焦状态判别能力的同时,保留离焦变化的连续性。

软标签 InfoNCE 损失函数引入了一个基于标签距离的连续权重因子。对于锚点样本 i ,样本 j 对其正向贡献的权重取决于两者真实离焦位置 y_i 和 y_j 的差异。损失函数的具体形式定义如下:

$$L_{CL} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\sum_{j \neq i} \exp(-\alpha|y_i - y_j|) \cdot \exp(s_{ij}/\tau)}{\sum_{k \neq i} \exp(s_{ik}/\tau)} \quad (3-2)$$

其中， N 为训练批次中的样本总数； τ 为温度系数，用于调节相似度分布的平滑程度，控制模型对困难样本的关注度； α 为软标签衰减因子，用于控制标签差异对权重的惩罚力度。 $|y_i - y_j|$ 表示两个样本真实物理位置的绝对差值。分子项并非仅包含单个正样本，而是包含了批次内所有其他样本 j 的加权和。权重项起到软正样本门控的作用：当两个样本的物理位置非常接近时，权重趋近于1，该样本对在损失函数中充当正样本，模型会最大化其相似度；当物理位置差异较大时，权重趋近于0，该样本对在分子中被抑制，仅在分母中作为负样本出现，模型会最小化其相似度。

3.5 本章小结

综上所述，本章针对智慧交通感知系统核心元器件楔形滤光片在自动化质检中面临的非均匀离焦与成像质量一致性难题，提出了一套基于多模态视觉注意力的鲁棒自动对焦解决方案。在方法层面，本章首先构建了面向交通光学元件的显微自动对焦数据集，通过轴向步进采样与在线数据增强，为模型训练提供了覆盖工业现场扰动的数据基础。同时提出了对比融合自动对焦网络 CFAN 架构，该网络以 Swin Transformer 为骨干，通过三视角输入策略保留倾斜表面的几何约束，并设计了视间注意力融合模块 IVAF，利用交叉注意力机制实现多视场特征的深层语义交互。为进一步提升模型对微小离焦差异的判别敏感度，本章引入了基于软标签 InfoNCE 损失函数的辅助对比学习策略，通过优化嵌入空间的特征流形结构，引导模型区分物理位置邻近但纹理存在细微差异的采样点。上述方法的有机结合，为克服复杂三维表面的对焦瓶颈提供了新的技术路径，并为后续章节开展微小缺陷的智能检测奠定了高质量的成像基础，从而从底层成像链路支撑智能交通感知系统的硬件可靠性与数据准确性。

第四章 融合物理感知引导与解耦注意力的缺陷检测

从交通感知系统质量保障的角度来看,楔形滤光片表面缺陷的错检、漏检可能直接导致问题元件流入交通感知系统,进而引发路侧单元成像信噪比下降、目标识别算法失效等连锁反应,造成一定的交通安全隐患。

尽管第三章通过构建 CFAN 网络有效解决了楔形滤光片倾斜表面导致的非均匀离焦成像难题,为后续检测提供了清晰的物理图谱,但在实际工业质检环节,微小缺陷往往呈现出极低的对比度与显著的多尺度差异,且极易湮灭在复杂的光学镀膜纹理与背景噪声中,导致常规数据驱动型算法难以提取有效的判别特征;针对这一在清晰成像基础上依然面临的弱信号识别瓶颈,本章提出了一种融合物理感知引导与解耦注意力的轻量化缺陷检测算法 PGA-YOLO,该算法在 YOLO11n 架构基础上,创新性地引入深度解耦通道竞争注意力模块 (DCCA) 以重标定特征通道并精准抑制背景干扰,同时构建物理感知引导机制 (PGM) 将图像梯度、结构差分等物理先验动态注入神经网络,旨在将光学物理先验与深度特征进行协同互补,提升模型在复杂背景下对微小弱信号缺陷的表征能力,从而满足高通量质检对高精度与实时性的要求。

4.1 缺陷检测数据集构建与预处理

构建高可信度且覆盖多形态缺陷的样本库是训练高精度检测模型的基础,依托前述章节构建的自动化检测平台与 CFAN 鲁棒对焦算法,本研究采集并构建了包含划痕、麻点与崩边三类典型缺陷的工业数据集。实验数据来源于第二章所述的楔形滤光片自动化检测产线,系统利用 EtherCAT 工业以太网协议驱动三轴运动平台,并控制 Z 轴电机进行精密对焦补偿,确保采集过程与运动坐标的毫秒级同步,最终通过海康威视工业相机捕获分辨率为 2048×2048 像素的原始图像。

根据 GB/T 1185-2006 光学零件表面疵病国家标准及企业质检规范,结合实际工业现场的失效模式,本研究重点关注三类具有显著弱信号与强干扰特性的典型缺陷。划痕通常由加工过程中的微小磨料划伤产生,在物理形态上表现为宽度极窄、长度跨度大且具有显著方向性的线性纹理。在暗场照明体系下,由于划痕深度极浅,其产生的散射光极其微弱,导致图像呈现出极低的对比度,且极易被楔形滤光片表面类似高频梯度的多层镀膜纹理所掩盖,产生严重的背景混叠效应,这使得深度学习网络在提取此类形态各向异性特征时极易发生断裂或漏检。崩边主要分布在元件的物理边界处,表现为滤光片边缘区域的不规则缺损,通常伴随有加工应力残留引发的微裂纹。此类缺陷的核心视觉特征是局部区域的梯度突变,

但在楔形结构厚度渐变特性的影响下，边缘区域往往处于景深范围的极限位置，导致缺陷轮廓因非均匀离焦模糊而被平滑化，算法难以利用梯度信息精确分割边界，极易造成定位偏差。麻点表现为孤立的点状凹坑、气泡或表面附着的微尘颗粒，其物理尺寸极其微小，直径通常小于 $20\mu m$ 。在暗场显微成像中，麻点虽然表现为局部高亮的散射光斑，但因目标尺寸过小，在卷积神经网络的多次下采样过程中极易丢失空间特征信息，且视场内不同位置的麻点受倾斜表面影响会呈现不同程度的弥散圆扩散，极易与高增益模式下传感器热噪声产生的孤立亮点混淆，从而导致高虚警率。数据集示例如图 4-1 所示。




图 4-1 缺陷检测数据集示例

如表 4-1 所示，本研究共采集并筛选出具有代表性的缺陷样本图像 480 张，累计标注缺陷实例 6026 个。统计分析表明数据集存在极度的类别不均衡现象，其中麻点类缺陷实例高达 4924 个，占比约 81.7%，而作为关键致命缺陷的划痕类仅有 362 个，占比不足 6%。这种显著的长尾分布特性会导致模型在训练过程中过度关注多数类样本，严重抑制对少数类关键缺陷特征的学习。此外，原始图像中微小缺陷的像素占比极低，直接输入网络容易导致特征在下采样过程中丢失，因此必须通过特定的预处理与增强策略来优化数据分布。

表 4-1 楔形滤光片缺陷数据集构成

缺陷类别	实例数量	图像总数 (具有该类缺陷即记入)	主要挑战指标
划痕	362	171	低对比度, 细长形几何
崩边	740	324	边缘干扰, 形态不规则
麻点	4924	460	微小, 模糊, 局部环境噪声
合计	6026	480	类别分布不均衡

针对上述数据集存在的样本量有限、类别分布极度不均以及微小缺陷特征不明显等问题, 本研究引入了在线数据增强与实例级混合增强相结合的预处理策略。在环境扰动模拟方面, 训练过程中引入了高斯模糊与色彩扰动, 通过模拟传感器热噪声与光照波动迫使模型学习更具鲁棒性的纹理特征。在几何与结构增强方面, 采用了概率为 1.0 的 Mosaic 马赛克增强, Mosaic 增强通过将四张图像随机缩放、裁剪并拼接为一张训练图像, 使同一批次中包含更多不同尺度、不同位置 and 不同背景条件下的缺陷目标, 有助于增强模型对微小缺陷和复杂背景的适应能力; 同时引入概率为 0.2 的 Mixup 与概率为 0.5 的 Copy-Paste 策略, Mixup 增强通过对两张图像及其标签进行线性混合, 能够平滑样本之间的类别边界, 降低模型对有限训练样本的过拟合风险。Copy-Paste 增强则将已标注的缺陷实例复制到其他背景图像中, 能够显式提高划痕、崩边等少数类缺陷在训练过程中的出现频率, 从而缓解类别不均衡导致的学习偏差。此外, 结合 RandAugment 自动增强技术与概率为 0.4 的随机擦除, 模拟工业现场可能的遮挡情况以提升模型对残缺特征的识别能力。为了确保模型能够精细化收敛, 在训练的最后 10 个 Epoch 自动关闭 Mosaic 增强, 使模型回归真实的数据分布, 避免过度扭曲的增强图像影响最终的检测精度。通过上述预处理流程, 原始的 480 张图像被动态扩充为具有高度多样性的训练流, 为 PGA-YOLO 算法的训练提供了高质量的数据基础。

4.2 PGA-YOLO 网络总体架构设计

4.2.1 YOLO11n 基准算法简述

为了满足智能交通感知硬件生产线对高通量质检的严苛要求, 检测算法必须在保障高精度的同时具备极低的推理延迟与计算资源占用率。为此, 本研究选取了 Ultralytics 公司发布的最新一代 YOLO11n 模型作为缺陷检测的基准架构。作为 YOLO 系列的最新迭代版本, YOLO11n 在继承了 CSPNet (Cross Stage Partial Network) ^[53]与 ELAN (Efficient Layer Aggregation Network) ^[54]高效特征聚合优势

的基础上,进一步优化了 C3k2 模块与 SPPF (Spatial Pyramid Pooling – Fast) 结构,使其在保持极低参数量的同时,依然具备强大的多尺度特征提取能力。该模型采用经典的单阶段检测范式,由负责特征提取的主干网络、负责多尺度特征融合的颈部网络以及执行最终分类与回归的检测头三部分构成。尽管 YOLO11n 在通用目标检测任务中表现优异,但在面对楔形滤光片这一特定场景时仍显不足。由于其本质上属于纯数据驱动的深度卷积神经网络,模型过度依赖纹理与边缘的统计规律。而在暗场显微成像下,微弱的划痕信号极易被复杂的背景纹理淹没,且非均匀离焦导致的边缘模糊使得模型难以仅凭卷积特征精确界定缺陷边界。因此,直接应用原始 YOLO11n 往往会导致对弱信号缺陷的漏检以及对背景噪声的虚警,难以满足精密光学元件的质检标准。

4.2.2 PGA-YOLO 改进策略概述

针对基准模型在处理低信噪比与非均匀离焦图像时的性能瓶颈,本研究提出了一种融合物理感知引导与解耦注意力的轻量化检测网络 PGA-YOLO (Physical Perception Guidance and Attention YOLO), 网络结构如图 4-2 所示。该网络的设计核心在于打破传统深度学习黑盒式特征提取的局限,通过显式注入光学物理先验知识,构建了数据驱动特征与物理机理特征协同互补的双流架构。PGA-YOLO 的整体架构在保留 YOLO11n 轻量化优势的基础上,实施了两个维度的核心重构。




图 4-2 PGA-YOLO 网络结构图

首先,在主干网络的深层特征编码阶段,本研究设计了深度解耦通道竞争注意力 (DCCA) 模块,用于替换原有的 C2PSA 结构。针对暗场环境下背景梯度波

动剧烈且缺陷信号微弱的特性 DCCA 模块摒弃了传统注意力机制仅关注空间或通道单一维度的做法,而是通过深度可分离卷积^[55]实现空间拓扑与通道语义的解耦建模,并引入基于 Softmax 的通道竞争机制。这一改进旨在从特征提取源头抑制与缺陷无关的背景噪声响应,强制网络在有限的能量分布中筛选出最具判别性的缺陷纹理特征,从而为后续处理提供纯净的高维语义表征。

其次,为了克服楔形结构导致的成像退化与离焦模糊,模型构建了独立的物理感知引导支路 (PGM Branch)。该支路不参与梯度的反向传播更新,而是作为确定性的物理先验来源,并行提取图像的梯度幅值、高光残差及线性结构分量等物理特征。这些物理特征经过多尺度映射后,被动态注入到检测头的分类分支中。这种设计利用了物理算子对边缘与突变的敏感性,弥补了深度网络在处理模糊目标时的不确定性,使得模型在难以区分是缺陷还是噪声的临界状态下,能够借助物理先验做出更准确的判断。

4.3 深度解耦通道竞争注意力模块 (DCCA)

在暗场显微成像的特殊物理环境下,楔形滤光片的表面检测面临着极大的挑战。由于暗场照明会对表面的微观起伏极度敏感,滤光片本身的复杂背景纹理与非均匀的光学散射噪声交织在一起,形成了一种高频且杂乱的干扰信号。在这种强噪声背景下,划痕与麻点等微弱缺陷的特征响应极易被淹没。传统的通道注意力机制,如经典的 SE 模块^[56],主要依赖全局平均池化来压缩空间信息,并利用全连接层配合 Sigmoid 激活函数对通道进行独立重标定。这种“各自为政”的权重分配方式在处理高信噪比图像时表现良好,但在工业暗场环境下,由于噪声的响应强度往往远高于微弱缺陷, Sigmoid 函数会不加区分地放大这些高响应的背景纹理,导致真实的缺陷特征反而受到抑制,严重影响了模型对低对比度目标的捕捉能力。

此外,传统注意力模块中全连接层的存在引入了大量的冗余参数,这与工业产线边缘端设备对实时性的严苛要求相悖。为了解决这一痛点,本研究提出了深度解耦通道竞争注意力模块 (Deep Decoupled Channel-Competition Attention, DCCA)。该模块的核心设计思想在于解耦与竞争。首先,通过将空间特征提取与通道相关性建模进行深度解耦, DCCA 利用轻量化的结构取代了繁琐的全连接层,在显著降低计算复杂度的同时,减少了模型在特征融合过程中的信息冗余,确保了检测网络在移动端或嵌入式平台上的高效运行。

在特征强化策略上, DCCA 引入了基于 Softmax 的通道竞争机制,这是对传统重标定方式的一次本质改进。不同于 Sigmoid 激活函数赋予每个通道独立的绝对权重, Softmax 函数在所有通道间建立了一种“零和博弈”的竞争关系。这种机

制强制网络在有限的能量分布中进行筛选,使得有限的注意力资源能够跨通道地向最具判别性的缺陷特征集中。通过这种全局能量的重新分配,高频背景噪声的响应在竞争中被相对削弱,而原本微弱的缺陷信号则在对比中脱颖而出。这种精准的抑制与增强过程,显著提升了模型在极端复杂成像条件下对弱目标的表征能力,为楔形滤光片的高精度缺陷检测提供了坚实的理论支撑。




图 4-3 深度解耦通道竞争注意力模块 (DCCA)

4.3.1 空间-通道特征深度解耦

为了解决传统卷积操作在提取特征时空信息与通道语义过度耦合导致的参数冗余问题, DCCA 模块首先引入了深度解耦设计思想。该结构并未直接对输入特征图进行通道压缩或全连接映射,而是利用深度可分离卷积将特征提取过程拆解为独立的空间滤波与通道组合两个步骤。设输入特征图为 $X \in R^{C \times H \times W}$, 其中 C 为通道数, H 与 W 分别为特征图的高度与宽度。模块首先利用 3×3 的深度卷积 DWConv 对每一个输入通道进行独立的空间拓扑建模, 该操作仅关注局部的空间纹理特征而不进行通道间的信息交互, 从而在保留高频边缘信息的同时大幅减少了参数量。随后, 利用 1×1 的逐点卷积 PWConv 将经过空间滤波的特征在

通道维度上进行线性组合与映射。为了丰富特征的语义多样性并为后续的特征筛选提供更大的搜索空间，本文在此阶段引入了通道扩展策略，将特征通道维度映射至高维隐藏空间 X' ，该过程可表示为：

$$X' = PWConv(DWConv(X)) \quad (4-1)$$

其中，隐藏空间的通道维度由增长因子 d 控制，即 $C' = d \cdot C$ 。这种先解耦后扩展的设计策略，不仅有效分离了空间背景噪声与核心语义特征，还通过增加特征的维度冗余度，为后续的通道竞争机制提供了更丰富的候选特征基，奠定了弱信号提纯的物理基础。

4.3.2 基于 Softmax 的通道竞争机制

经过深度解耦与维度扩展后，特征空间中虽然包含了丰富的语义信息，但也不可避免地混入了非均匀光场产生的背景干扰。为了从高维特征中精准剥离出与缺陷相关的关键通道，DCCA 模块摒弃了传统注意力机制中常用的 Sigmoid 独立门控策略，转而引入了基于通道维度的 Softmax 竞争机制。Sigmoid 函数倾向于独立地评估每个通道的重要性，容易导致多个背景通道同时被激活；而 Softmax 函数具有显著的归一化与排他特性，能够强制所有通道的权重之和为 1，从而在通道之间形成强烈的竞争关系。这意味着模型必须在众多候选通道中做出取舍，将有限的注意力权重集中分配给那些对缺陷判别贡献最大的极少数通道，从而实现冗余背景通道的显著抑制。具体而言，模块首先对高维特征 X' 执行全局平均池化^[57]以获取全局上下文描述符，随后通过多层感知机 MLP^[58]生成通道权重向量，并利用 Softmax 函数计算最终的竞争权重 W ：

$$W = Softmax\left(MLP\left(GAP(X')\right)\right) \quad (4-2)$$

获得竞争权重后，模块将其与高维特征 X' 进行逐通道加权相乘，完成特征重标定。为了进一步增强模型在非线性空间的表达能力并防止梯度消失，重标定后的特征通过 GELU 激活函数进行非线性变换。相比于 ReLU，GELU 的平滑特性能够更好地保留暗场下弱目标的梯度连续性。最后，利用第二个逐点卷积将特征维度恢复至原始通道数 C ，得到最终输出 Y ：

$$Y = PWConv\left(GELU(W \cdot X')\right) \quad (4-3)$$

通过这种深度解耦与通道竞争的协同作用，DCCA 模块成功实现了在复杂背景干扰下对微弱缺陷信号的特征提纯，为后续检测头提供了高信噪比的语义输入。

4.4 物理感知引导机制 (PGM)

在暗场显微成像条件下,楔形滤光片特有的坡度结构与显微镜头极小的景深范围产生耦合作用,导致视场内仅有局部区域处于清晰焦深范围内,图像不可避免地伴随严重的非均匀离焦模糊与局部对比度衰减。纯数据驱动的卷积神经网络在处理此类物理退化图像时,由于缺乏对成像物理过程的先验理解,其特征提取过程极易受到背景纹理与随机噪声的干扰,难以在模糊边界处建立明确的分割界限。为了突破这一局限,本研究构建了物理感知引导机制 PGM,旨在主干网络之外引入独立的先验旁路。该机制不参与深层语义的抽象,而是从梯度、光度学及几何结构四个维度对缺陷进行显式物理建模,将人工设计的确定性算子与深度学习的强拟合能力相结合,为网络提供具有物理可解释性的几何引导信息。

4.4.1 多维物理先验特征建模

为了全面捕捉不同类型缺陷在暗场下的光学散射特性,感知支路直接作用于原始输入图像,并通过四个并行设计的物理提取分支生成物理感知图。首先是梯度先验分量,考虑到崩边及麻点等缺陷在边缘处具有显著的灰度突变,而离焦模糊会平滑这些高频信息,模块利用 Sobel 算子分别提取图像在水平与垂直方向的梯度幅值,通过强化边缘响应来对抗模糊导致的特征弥散。其次是高光残差分量,针对暗场环境下缺陷表现为高亮散射点的光度学特性,该分支计算输入图像与其大尺度均值滤波结果的残差。这种处理方式能够有效抑制低频背景纹理,显著突出麻点等点状缺陷的散射核心区域,从而提升信噪比。第三是局部结构差分分量,借鉴差分高斯 DoG^[59]的思想,通过构建多尺度均值平滑算子的结构差分来描述局部对比度的微小突变,这对于识别那些隐藏在复杂镀膜纹理下的隐性缺陷提供了关键的补充信息。最后是线性定向结构分量,专门针对划痕缺陷显著的细长几何属性设计。由于划痕在暗场下往往呈现为断续的弱信号线条,常规卷积容易造成特征断裂。为此,本研究设计了包含非对称卷积与空洞卷积的 LinePrior 模块,通过聚合不同方向与感受野下的线性响应来恢复丝状目标的连续性,有效弥补了主干网络对细长几何目标提取能力的不足。上述四类先验特征在通道维度被拼接,并经由非线性映射提纯后,生成最终的物理感知图 P_{map} 。

4.4.2 物理感知检测头设计

提取物理先验特征仅是第一步,如何将其有效地转化为检测网络的实质增益是 PGM 机制的关键。为了实现物理特征与深度语义的深度融合,本研究对 YOLO11n 原本的检测头结构进行了改进,设计了物理感知检测头。该检测头接

收来自特征融合颈部的多尺度语义特征图与经过缩放的物理感知图 P_{map} ，并在分类分支中引入空间先验约束。具体而言，物理感知图被注入到分类预测层中，公式表达为：

$$Y_{cls} = Y_{cls} + \alpha \cdot \text{Resize}(P_{map}) \quad (4-4)$$

其中， α 为可学习的权重因子，用于动态调节物理先验对最终判别的贡献度。

值得注意的是，物理先验特征主要致力于为缺陷类别的判定及目标存在性提供确定性的物理依据，而针对目标边界的精确坐标回归则依然主要依赖于主干网络所提取的高维语义表征。考虑到不同尺度的特征层对缺陷物理属性的敏感度存在差异，例如微小的麻点与划痕主要保留在浅层高分辨率特征中，而深层特征更多包含语义信息。因此，本研究采用了非对称初始化策略来设定权重因子 α 。将浅层特征层（如 P2 层）的感知权重初始化为 0.5，而深层特征层的权重设为 0.1。这种物理启发式的引导策略确保了模型在处理细小且易受模糊影响的目标时，能够更多地参考物理边缘先验。

4.5 本章小结

本章针对楔形滤光片表面缺陷检测中存在的弱信号特征提取困难、类别分布不均衡以及复杂背景干扰等问题，在清晰成像基础上开展了缺陷检测方法研究。

首先，构建了包含划痕、崩边和麻点三类典型缺陷的工业检测数据集，并通过 Mosaic、Mixup 和 Copy-Paste 等增强策略缓解微小目标特征不足和类别长尾分布问题。其次，提出了融合物理感知引导与解耦注意力检测模型 PGA-YOLO。该模型以 YOLO11n 为基础，引入深度解耦通道竞争注意力模块 DCCA，以增强关键纹理表达并抑制复杂背景噪声；同时构建物理感知引导机制 PGM，将梯度、高光残差、结构差分 and 定向结构等先验信息动态注入检测头，以提升模型对微小缺陷和模糊边界的识别能力。

综上，本章所提方法为复杂光学背景下楔形滤光片表面微小缺陷的高精度检测提供了有效支撑，并为后续实验验证奠定了基础。

第五章 实验结果与分析

为客观评估本文所提方法在楔形滤光片表面缺陷检测中的实际性能，并验证其在保障交通感知硬件成像质量方面的应用潜力，本章依托本文研制的自动化检测设备与统一的模型训练测试环境，对 CFAN 自动对焦算法和 PGA-YOLO 缺陷检测算法开展系统实验研究。首先，构建统一的实验环境与量化评价指标体系，以保证实验结果的可复现性和对比分析的公平性。在此基础上，本章从三个层面展开论述：首先，通过对比实验、消融实验及鲁棒性测试，验证 CFAN 网络在复杂倾斜表面条件下的聚焦精度与抗干扰能力，为后续缺陷识别提供稳定的清晰成像基础；其次，基于自建工业缺陷数据集，系统评估 PGA-YOLO 在检测精度、推理效率与轻量化部署方面的综合表现，并结合 Grad-CAM 可视化分析其物理感知引导机制的作用机理；最后，围绕面向交通感知的应用场景，构建受控的图像退化实验，定性定量分析楔形滤光片表面缺陷所引发的成像质量下降如何进一步传递为交通目标检测性能劣化，从而揭示前端光学元件质量与后续感知决策可靠性之间的内在关联。

5.1 实验环境与评价指标

5.1.1 自动化检测设备与实验环境配置

为保证本文所提自动对焦方法与缺陷检测方法的实验结果具有客观性、可复现性与工程应用相关性，本文在实际研制的楔形滤光片表面缺陷自动化检测设备基础上，构建了统一的实验环境，对第三章提出的 CFAN 自动对焦模型和第四章提出的 PGA-YOLO 缺陷检测模型开展系统验证。该实验环境由实际检测设备与离线模型训练环境两部分构成：前者用于完成楔形滤光片样品的自动化检测与系统级验证，后者用于完成深度学习模型的训练、参数优化与推理分析。

本文搭建的楔形滤光片表面缺陷自动化检测设备以工业计算机为控制核心，集成了精密运动控制、多视角视觉采集、自动对焦、缺陷检测以及质量追溯等功能，能够完成样品扫描、焦面补偿、图像采集、缺陷识别与结果存储的全流程自动检测任务。整体设备采用分布式协同架构，通过运动控制单元、载物台执行机构、光学成像单元与软件调度模块之间的配合，实现了复杂倾斜表面条件下的稳定成像与高一致性检测。设备架构如图 5-1 所示，设备实物图如图 5-2 所示。




图 5-1 楔形滤光片表面缺陷检测系统硬件架构图




图 5-2 楔形滤光片表面缺陷检测设备实物图

在硬件组成方面，该检测设备采用工业计算机作为现场控制与任务调度中枢，负责检测流程控制、图像处理任务分发以及算法模型部署运行。运动执行部分配置三轴运动平台，其中 Z 轴采用高精度伺服电机驱动，用于执行自动对焦过程中的轴向微位移补偿，以适应楔形滤光片表面坡度变化带来的焦面起伏。载物台控制器通过串口通信与工业计算机建立实时双向连接，持续反馈样品空间位置信息，从而实现微米级行程控制与位置闭环校正，为后续图像采集与缺陷检测提供稳定的物理基础。

在视觉采集部分，设备集成了 3 台海康威视 MV-CS040-90UM 工业相机，并

统一配备 4 倍放大倍率的精密显微物镜。通过分光光学系统，三路视场分别对应楔形滤光片表面的上、中、下区域，从而构成面向倾斜表面的多视角协同成像机制。考虑到图像采集时序与空间位姿一致性直接影响自动对焦与缺陷检测的可靠性，系统采用硬触发方式实现三台相机同步曝光，即由载物台控制器在样品运动至指定位置后输出触发脉冲，直接驱动三台相机同步采集图像，并联动可控光源完成照明与曝光动作的同步控制。该设计有效降低了传统软件触发模式下存在的时序抖动与延迟误差，提高了原始图像采集的一致性与信噪比。

在软件实现层面，检测设备采用分层模块化架构设计，整体由人机交互层、业务逻辑层、算法推理层、硬件驱动层与物理设备层五个层级构成，如图 5-3 所示。其中文件底层的硬件驱动层负责封装工业相机 SDK、运动控制卡动态链接库以及串口通信驱动，用于完成异构设备的统一调度；算法推理层集成了图像预处理模块、CFAN 自动对焦推理引擎以及 PGA-YOLO 缺陷检测引擎，用于完成从清晰成像到缺陷识别的核心计算任务；业务逻辑层则负责检测流程管理、任务调度以及多线程协同控制；人机交互层主要实现检测状态显示、参数配置、结果查询与质量统计等功能。该分层架构既保证了系统在大批量检测任务下的稳定运行，也为算法后续迭代与设备功能扩展提供了良好的工程基础。




图 5-3 楔形滤光片表面缺陷检测系统软件架构图

在检测流程设计方面，系统以主进程为核心调度单元，将整体任务划分为硬件控制、图像采集与处理、用户界面显示三个子进程，并通过队列机制实现跨进程的指令传输与状态反馈，如图 5-4 所示。检测过程中，硬件控制子进程负责样品扫描、Z 轴调焦以及相机触发；图像采集与处理子进程在接收到原始图像后，首先调用 CFAN 完成离焦距离预测与焦面校正，随后依次执行图像配准、图像融合、去噪增强等预处理操作，最后由 PGA-YOLO 完成缺陷定位与类别判定；用户界面子进程则实时接收检测结果并进行可视化展示，同时将缺陷类别、位置信息及运行状态等关键数据写入数据库。该流程实现了从物理采样到智能判别再到结果追溯的完整闭环。




图 5-4 楔形滤光片表面缺陷检测系统软件功能流程图

为了提升检测过程的可追溯性与批量质量分析能力，本文还在设备软件中设计了质量追溯数据库，用于对样品信息、原始图像、检测结果、缺陷类别及位置信息进行结构化存储。数据库的引入使得该检测设备不仅能够完成单片楔形滤光片的自动判定，还能够支持批次产品的质量统计、异常样品回查与缺陷分布分析，从而为后续工艺优化与设备稳定性评估提供数据支撑。与此同时，系统人机界面能够实时显示样品检测状态、运行日志及结果统计信息，便于操作人员进行过程

监控与异常定位。系统界面如图 5-5 所示。



图 5-5 系统界面图

除实际检测设备外，本文所有深度学习模型的训练与离线推理实验均在统一的高性能计算环境中完成。本文的实验的计算环境部署于 featurizeAI 算力云服务平台，硬件层面搭载了 16 核 AMD EPYC 9354 高性能处理器，并配备了拥有 24GB 显存的 NVIDIA GeForce RTX 4090 独立显卡，系统内存容量为 60.1GB，能够满足多视角高分辨率图像数据的并行加载与大规模张量运算需求。软件环境基于 Linux 操作系统构建，采用 PyTorch 2.0.1 深度学习框架作为算法开发与部署的基础底座，并配置 CUDA 11.8 加速库与 CUDNN 8.7.0 深度神经网络库以优化 GPU 浮点运算效率。

针对具体训练策略，第三章提出的 CFAN 自动对焦网络旨在解决连续值回归问题，因此训练过程中将所有原始图像统一双线性插值缩放至 256×256 像素分辨率。优化器选用对 Transformer 架构收敛性更佳的 AdamW 算法，初始学习率设定为 0.0001，并配合线性学习率衰减策略。为了防止过拟合，设置权重衰减系数为 0.0001。训练过程中的批处理大小设定为 32，共迭代 100 个 Epoch。此外，参考对比学习在特征表征任务中的通用设置，本文选取温度系数 τ 为 0.07，旨在通

过较小的温度梯度增强模型对困难样本的判别能力,从而捕捉微弱的离焦特征差异。同时,考虑到楔形滤光片在焦平面附近的成像清晰度演变规律,本文设置软标签衰减因子为 α 为 5.0,以构建符合物理成像特性的监督信号,引导网络聚焦于高价值的近焦区域特征。并通过指数移动平均 EMA 策略动态平衡回归损失与对比损失的权重,动量系数 β 设为 0.9。而针对第四章提出的 PGA-YOLO 缺陷检测网络,为了适配工业缺陷检测的小样本特性,加载了官方 YOLO11n 的预训练权重作为初始化参数。优化器选用带有动量项的自适应随机梯度下降 SGD 算法,动量系数设为 0.937,权重衰减系数设为 0.0005。初始学习率设定为 0.01,并引入包含 3 个 Epoch 的 Warm-up 预热过程,随后采用余弦退火策略进行动态衰减。训练批处理大小设定为 16,总迭代轮数为 100 Epoch。在数据增强方面,采用了 Mosaic 概率 1.0、Mixup 概率 0.2 及 Copy-Paste 概率 0.5 组合策略,并为了确保模型精细化收敛,在训练的最后 10 个 Epoch 自动关闭 Mosaic 增强功能。

5.1.2 评价指标定义

鉴于本系统涵盖了清晰成像与缺陷识别两个紧密耦合但目标迥异的任务环节,本章分别定义了针对性的量化评价指标及相应的计算公式,以从不同维度综合评估系统的整体性能。

针对第三章 CFAN 自动对焦网络的回归性能评估,本研究主要关注预测焦面位置与真实物理位置之间的偏差程度。首先采用平均绝对误差 (Mean Absolute Error, MAE) ^[60]来衡量预测值的普遍偏离水平,该指标能直观反映模型在测试集上的平均预测精度。设 N 为测试样本总数, y_i 为第 i 个样本的真实离焦距离标签, $\hat{y}_i$ 为模型预测的离焦距离,则 MAE 的计算公式定义为:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (5-1)$$

其次,引入对大误差样本更为敏感的均方根误差 (Root Mean Squared Error, RMSE) ^[61]来衡量系统的稳定性,其计算公式如下:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (5-2)$$

此外,为了评估算法在实际工程应用中的可靠性,定义了特定容差下的对焦成功率 (Accuracy@ δ)。该指标统计了预测误差绝对值小于设定阈值 δ (本文依据景深特性取 $\delta = 40\mu m$)的样本占比,直接反映了系统满足清晰成像需求的概率,其公式表达为:

$$Accuracy@δ = \frac{1}{N} \sum_{i=1}^N M(|y_i - \hat{y}_i| \leq \delta) \times 100\% \quad (5-3)$$

其中, $M(\cdot)$ 为示性函数, 当括号内条件满足时取值为 1, 否则为 0。

针对第四章 PGA-YOLO 网络的缺陷检测性能评估, 本研究遵循通用目标检测标准, 选取平均精度均值 (Mean Average Precision, mAP) [62] 作为核心指标。在定义 mAP 之前, 需引入查准率 (Precision, P) 与查全率 (Recall, R)。查准率反映了模型预测为正样本的结果中真正正样本的比例, 衡量了模型对虚警的抑制能力; 查全率则衡量了所有真正正样本中被正确检出的比例, 直接关联漏检率。设 TP 为真正例, FP 为假正例, FN 为假负例, 两者的计算公式分别为:

$$P = \frac{TP}{TP + FP} \quad (5-4)$$

$$R = \frac{TP}{TP + FN} \quad (5-5)$$

基于 P-R 曲线, 平均精度 (Average Precision, AP) 被定义为查准率对查全率的积分, 即 P-R 曲线下的面积。对于包含 K 个缺陷类别的多分类任务, mAP 则为所有类别 AP 值的算术平均。本章重点考察 mAP@0.5 (IoU 阈值为 0.5 时的 mAP) 以及 mAP@0.5:0.95 (IoU 阈值从 0.5 到 0.95 步长为 0.05 的平均值), 其计算公式如下:

$$AP = \int_0^1 P(R) dR, \quad mAP = \frac{1}{K} \sum_{i=1}^K AP_i \quad (5-6)$$

考虑到智能交通硬件产线对高通量质检的刚性需求, 本章还将单图推理延迟 (Latency) 与模型参数量 (Parameters) 纳入评价体系, 以验证算法在边缘侧计算设备上的部署可行性与实时性表现。

此外, 在 5.4 节交通感知退化实验中, 为了进一步量化光学缺陷对目标检测结果的影响, 在缺乏精确标注的情况下, 本文引入检测结果统计指标作为补充评价手段, 包括检测目标数量 (Number of Detections) 与平均置信度 (Average Confidence)。

检测目标数量用于衡量模型在单幅图像或数据集上的检测响应强度, 其定义为:

$$N_d = \sum_{i=1}^M n_i \quad (5-7)$$

其中, M 表示图像总数, n_i 表示第 i 张图像的检测目标数量。

平均置信度用于衡量模型对检测结果的整体可信程度, 其定义为:

$$C_{avg} = \frac{1}{N_d} \sum_{j=1}^{N_d} c_j \quad (5-8)$$

其中， c_j 表示第 j 个检测框的置信度得分。

上述指标能够从检测响应强度和模型判别信心两个角度反映图像质量退化对感知性能的影响，适用于分析光学缺陷引起的性能下降趋势。

5.2 自动对焦算法性能验证与分析

5.2.1 离焦距离回归对比实验

为了客观评估 CFAN 网络在处理楔形滤光片非均匀离焦问题上的性能优势，本研究将其与 MobileNetV3-Large^[63]、ResNet50^[64]、ViT-Base-16^[65]、VGG16^[66]及 EfficientNetB1^[67]等当前主流的深度学习基准模型进行了严格的对比测试，实验结果如表 5-1 所示。考虑到这些通用模型原本仅设计用于单视角图像分类，为了保证对比的公平性，实验对所有对比模型进行了多视角适配改造，即采用特征后融合策略，实例化三个共享权重的骨干网络分别提取上、中、下视场特征，并在通道维度拼接后送入统一的回归头。所有模型均在相同的多视角数据集上采用一致的训练策略与超参数配置进行收敛。

表 5-1 CFAN 对比实验

模型	MAE(μm)	RMSE(μm)	Accuracy@40 μm
MobileNetV3-Large	44.7	58.8	55.76%
ResNet50	76.0	108.1	40.49%
ViT-Base-16	64.8	99.8	48.67%
VGG16	51.3	67.7	48.67%
EffecientNetB1	58.2	80.9	48.46%
CFAN	20.6	24.4	91.51%

实验结果表明，CFAN 网络在各项关键指标上均展现出显著的性能优势。具体而言，CFAN 在测试集上取得了最低的平均绝对误差 MAE，仅为 20.6 μm ，以及最低的均方根误差 RMSE，为 24.4 μm 。相比之下，表现最好的轻量化模型 MobileNetV3-Large 的 MAE 高达 44.7 μm ，而参数量巨大的 ViT-Base-16 与 ResNet50 的 MAE 更是分别达到了 64.8 μm 与 76.0 μm 。这表明，缺乏针对性设计的通用特征提取器难以有效捕捉倾斜表面导致的非对称离焦规律，容易被复杂的背景纹理误导。在工程应用最为关注的对焦成功率指标 Accuracy@40 μm 上，CFAN 达到了 91.51%，意味着绝大多数预测结果均落在了 $\pm 40\mu\text{m}$ 的许用焦深范围

内。而对比模型的最高准确率仅为 55.76%，难以满足工业现场对高一致性成像的要求。上述数据有力证明了 CFAN 架构中多视角输入策略与定制化特征融合机制的有效性。

5.2.2 视间注意力与对比学习消融实验

为了进一步探究 CFAN 网络内部各核心组件对最终对焦性能的贡献度，本节设计了逐步累加的消融实验，实验结果如表 5-2 所示。实验以处理单张中心视角图像的 Swin-Tiny 网络作为基准模型 (Baseline)，该基准模型的 MAE 为 $23.0\mu m$ ，准确率为 81.87%。首先，引入多视角输入策略，将上、下视场图像与中心视场进行简单的通道堆叠，模型的 MAE 降低至 $22.0\mu m$ ，准确率提升至 85.10%，证明了边缘视场的离焦信息能够为中心对焦提供有效的空间几何约束。

在此基础上，引入视间注意力融合模块 IVAF 替换简单的特征拼接。实验数据显示，模型的 MAE 显著下降至 $21.1\mu m$ ，RMSE 降至 $25.3\mu m$ ，准确率大幅跃升至 89.94%。这一显著增益（准确率提升约 4.8 个百分点）充分验证了 IVAF 模块的设计初衷：通过交叉注意力机制，模型能够显式地建模不同视角间非对称的离焦关联，从而从全局维度理解楔形表面的倾斜状态，而非孤立地处理局部特征。最后，在回归任务之外引入辅助对比学习损失，构成完整的 CFAN 框架。结果显示，最终模型的 MAE 进一步优化至 $20.6\mu m$ ，准确率达到峰值 91.51%。这表明软标签对比学习策略有效地优化了特征在嵌入空间的流形分布，增强了模型对微小离焦差异的判别敏感度，使其在连续的回归空间中具备了更强的细粒度区分能力。

表 5-2 CFAN 消融实验

模型	MAE(μm)	RMSE(μm)	Accuracy@ $40\mu m$
Swin-Tiny (single image)	23.0	28.4	81.87%
Swin-Tiny	22.0	26.9	85.10%
Swin-Tiny + IVAF	21.1	25.3	89.94%
Swin-Tiny + Contrastive Learning	20.8	24.6	90.57%
CFAN	20.6	24.4	91.51%

5.2.3 抗噪性与鲁棒性分析

在实际的智能交通硬件制造现场，成像系统往往面临电磁干扰、光源波动及

传感器热噪声等不可控的环境扰动。为了验证算法的工程适用性,本研究构建了包含高斯噪声、椒盐噪声、亮度变化及对比度波动等四类扰动的鲁棒性测试集。初始测试结果显示,仅在纯净数据集上训练的基准 CFAN 模型表现出明显的脆弱性。例如,当施加标准差为 10 的高斯噪声时,其预测准确率从 91.51%骤降至 27.10%;在密度为 0.03 的椒盐噪声干扰下,准确率更是跌至 7.97%,完全丧失了作业能力。这表明基准模型存在对理想纹理特征的过拟合倾向。

针对这一鲁棒性短板,本研究引入了包含几何变换、光度畸变及噪声注入的在线数据增强策略,训练了增强版模型 CFAN-R。如表 5-3 与图 5-6 所示,CFAN-R 在面对各级扰动时展现出了较强的稳定性。在相同的高斯噪声(强度 10)干扰下,CFAN-R 的准确率能够维持在 81.76%;面对极端的椒盐噪声(密度 0.03),其准确率仍保持在 79.94%,远超基准模型的表现。此外,在亮度与对比度发生 $\pm 50\%$ 的剧烈波动时,CFAN-R 的性能衰减均控制在可接受范围内。这一结果证实,通过引入环境模拟增强策略,模型成功学习到了对焦状态的本质结构特征而非表面纹理,具备了在复杂工业环境下全天候稳定运行的抗干扰能力。

表 5-3 CFAN 与 CFAN-R 在各类图像扰动下的鲁棒性测试结果对比表

测试类别	扰动参数	MAE(μm) (CFAN/CFAN-R)	RMSE(μm) (CFAN/CFAN-R)	Accuracy@40 μm (CFAN/CFAN-R)
标准验证	-	20.6/19.4	24.4/24.0	91.51%/89.73%
高斯噪声	5	39.0/20.6	51.0/25.7	61.07%/87.23%
高斯噪声	10	118.1/24.1	161.8/30.7	27.10%/81.76%
高斯噪声	15	202.5/29.0	267.3/39.1	15.63%/74.99%
高斯噪声	20	295.3/36.3	377.4/58.6	10.42%/68.84%
椒盐噪声	0.005	112.2/19.8	165.4/24.2	26.94%/89.00%
椒盐噪声	0.01	212.4/20.2	274.1/24.8	18.34%/88.69%
椒盐噪声	0.02	336.0/21.4	414.8/26.7	10.47%/86.24%
椒盐噪声	0.03	386.9/25.3	473.2/34.6	7.97%/79.94%
亮度变化	0.5	42.3/21.1	69.5/26.8	63.78%/86.71%
亮度变化	0.7	47.0/21.4	77.6/27.4	59.41%/86.09%
亮度变化	1.3	58.1/25.8	102.7/39.8	56.28%/80.72%
亮度变化	1.5	61.0/25.7	104.4/38.4	50.91%/81.03%
对比度变化	0.5	36.3/23.1	54.6/31.5	67.33%/84.00%
对比度变化	0.7	42.8/22.7	73.4/31.9	62.95%/85.88%
对比度变化	1.3	61.3/24.4	110.4/31.7	51.59%/81.14%
对比度变化	1.5	61.4/25.8	108.4/39.7	51.22%/81.50%




图 5-6 CFAN 与 CFAN-R 的鲁棒性能对比图

5.2.4 可视化分析与机理解释

为了直观揭示 CFAN 网络特征提取与多视角信息融合的内在机理,验证视间注意力融合模块 (IVAF) 与辅助对比学习策略在捕捉非均匀离焦特征方面的实际效能,本节引入梯度加权类激活映射 (Grad-CAM)^[68] 技术,我们针对不同模型变体在处理相同楔形滤光片样本时的注意力分布进行了热力图可视化分析。




图 5-7 CFAN 不同模型变体的 Grad-CAM 可视化热力图

如图 5-7 所示,热力图中的颜色深浅直观地反映了神经网络在执行离焦距离回归任务时贡献度最高的空间区域,其中红色高亮部分代表了模型提取深度特征时所赋予的关键权重关注点。

观察基准 Swin-Tiny 模型的热力图可以发现,其激活区域主要局限在楔形滤光片的部分边缘轮廓上。这表明基础骨干网络虽然能够识别出图像中的高频边缘信息作为对焦依据,但其感受野与特征捕获能力相对单一,难以从全局角度建立离焦状态与空间位置的稳健映射。在引入辅助对比学习策略后,热力图显示激活信号沿滤光片轮廓进行了有效延伸。这一变化证实了对比学习通过优化特征在嵌入空间的流形分布,增强了模型对微小离焦差异的判别敏感度,迫使网络挖掘更丰富的边缘纹理线索以区分相近的聚焦状态。进一步引入视间注意力融合模块 (IVAF) 后,模型不仅强化了对边缘轮廓的关注,更将注意力敏锐地扩展至边缘以外的高频纹理区域及细微结构特征上。这种关注点的空间扩散有力地证明了 IVAF 模块通过交叉注意力机制,成功实现了多视角信息的深度交互与互补,使得模型能够突破单视角信息的物理局限,捕捉到隐含在复杂倾斜表面中的精细离焦模式。最终集成了所有模块的 CFAN 完整模型则展现出了最为全面且均衡的注意力分布,实现了局部细节与全局结构信息的有机统一。

为了进一步直观验证 CFAN 模型在回归预测任务中的实际表现,本文将测试集中的所有样本按照位移真实值进行升序排列,并据此绘制了预测值与真实值的对比曲线及残差分布情况,如图 5-8 所示。




图 5-8 CFAN 模型在测试集上的回归性能分析对比图

从回归性能分析图中可以观察到，在 $-1000\mu\text{m}$ 至 $+1000\mu\text{m}$ 的全量程对焦行程内，预测值紧密围绕基准线分布，未出现明显的非线性畸变或由于离焦程度加深而产生的预测失效现象。计算得到的确定系数 R^2 达到了 0.9982，这充分证明了模型能够精准地捕捉楔形滤光片图像中复杂的离焦特征，并建立起深度映射关系。

同时可以看到，绝大部分样本的绝对误差被严格且均匀地控制在 $40\mu\text{m}$ 的预设精度阈值范围内，残差分布在零误差基准线上下表现出良好的统计特性，并未随样本索引的移动而出现明显的波动增强。这种稳定的误差控制能力表明，CFAN 模型通过其特有的多视角注意力融合机制，有效克服了楔形滤光片表面坡度引起的非均匀离焦干扰。可视化结果有力地支撑了本文所提算法的有效性，证明其能够为后续高分辨率的表面缺陷检测提供稳定且可靠的焦平面位置参考。

5.3 缺陷检测算法性能验证与分析

5.3.1 缺陷检测算法对比实验

为了全面客观地评估 PGA-YOLO 算法在楔形滤光片表面缺陷检测任务中的综合优势，本研究在同一构建的工业数据集上，将其与当前主流的目标检测模型进行了对比实验。对比基准涵盖了经典的单阶段检测器 YOLOv8n、YOLOv8s、YOLO11s、面向实时检测优化的 RTMDet^[69]系列，以及基于 Transformer 架构的大型检测网络 DINO-r50^[70]以评估性能边界。所有模型均在统一的实验环境下采用默认超参数进行训练与推理，详细的性能对比数据如表 5-4 所示。

表 5-4 PGA-YOLO 对比实验结果

模型	参数量/M	推理延迟/ms	准确率	召回率	mAP50	mAP50:95
基线模型 (YOLO11n)	2.62	1.93	0.556	0.470	0.471	0.243
YOLO11s	9.45	3.33	0.516	0.461	0.477	0.253
YOLOv8n	3.16	2.44	0.507	0.458	0.453	0.242
YOLOv8s	11.17	3.66	0.547	0.464	0.474	0.253
RTMDet-s	8.89	6.82	0.498	0.461	0.440	0.225
RTMDet-tiny	4.87	5.03	0.512	0.419	0.417	0.208
DINO-r50	47.54	48.8	0.515	0.476	0.462	0.210
PGA-YOLO	2.82	4.36	0.596	0.477	0.509	0.253

实验结果表明，PGA-YOLO 在检测精度与模型轻量化之间取得了最优的平衡。在关键精度指标上，PGA-YOLO 的 mAP@0.5 达到 0.509，相比基准模型

YOLO11n 提升了约 8.1%，且显著优于体量更大的 YOLOv8s 与 YOLO11s，后者的 mAP@0.5 分别为 0.474 与 0.477。值得注意的是，尽管 DINO-r50 拥有高达 47.54M 的参数量，是本算法的 16 倍以上，但其 mAP@0.5 仅为 0.462。这一反直觉的现象表明，在处理具有非均匀离焦模糊与低信噪比的工业图像时，单纯增加网络深度或引入通用的自注意力机制并不能有效提取微弱的缺陷特征，反而可能因过拟合复杂的镀膜背景噪声而导致性能下降。在计算效率方面，PGA-YOLO 的参数量仅为 2.82M，单图推理延迟控制在 4.36ms，虽然相比最轻量的 YOLO11n 略有增加，但仍远低于 RTMDet-s 的 6.82ms 与 DINO-r50 的 48.8ms。这证实了本研究提出的物理感知引导策略，能够以极小的计算代价换取显著的精度增益，具备在边缘计算设备上执行高通量质检的工程潜力。

5.3.2 改进模块有效性消融实验

为了验证 PGA-YOLO 架构中深度解耦通道竞争注意力 DCCA 模块与物理感知引导机制 PGM 的独立贡献及协同效应，本研究设计了逐步累加的消融实验，结果如表 5-5 所示。在基线 YOLO11n 模型中单独引入 DCCA 模块后，虽然模型参数量仅从 2.62M 微增至 2.67M，但反映高精度定位能力的 mAP@0.5:0.95 指标由 0.243 提升至 0.259，涨幅达 6.6%。这表明 DCCA 通过深度可分离卷积与通道竞争机制，有效地实现了特征解耦与背景噪声抑制。当单独加载 PGM 支路时，模型的 mAP@0.5 从 0.471 显著提升至 0.498。这一结果有力证明了显式注入的梯度与高光残差先验，对于克服离焦模糊、提升点状微小目标的检出率具有积极作用。

表 5-5 各模块对模型性能影响的消融实验结果

模型	参数量/M	推理延迟/ms	准确率	召回率	mAP50	mAP50:95
基线模型 (YOLO11n)	2.62	1.93	0.556	0.470	0.471	0.243
YOLO11n + DCCA	2.67	4.25	0.571	0.473	0.476	0.259
YOLO11n + PGM	2.67	4.27	0.572	0.463	0.498	0.248
PGA-YOLO	2.82	4.36	0.596	0.477	0.509	0.253

进一步如表 5-6 所示的类别级分析显示，PGM 机制虽然提升了麻点与崩边的识别能力，但在处理低对比度划痕时，由于引入了高频物理梯度，导致划痕的 AP 值一度从 0.219 下滑至 0.160。然而，在最终的 PGA-YOLO 模型中结合 DCCA 模块后，划痕的检测精度成功回升至 0.219 并保持稳定。这一先抑后扬的性能曲线深刻揭示了两个模块在特征表征层面的互补机理：PGM 模块的核心价值在于

提供确定性增益，它利用物理成像规律提升了显著目标的召回率，确立了模型检测的基准性能。而 DCCA 模块则在深层特征空间内发挥了精准的智能滤波作用，通过跨通道的注意力关联与权重重塑，有效识别并抑制了物理支路引入的非目标纹理干扰。这种协同作用模式构成了模型内部的自适应平衡。DCCA 模块精准地从噪声背景中剥离并保护了弱信号划痕的特征完整性，防止了因特征冲突导致的性能坍塌。

表 5-6 不同模块在各缺陷类别上的精度表现 (mAP50)

模型配置	崩边	麻点	划痕	现象分析
基线模型 (YOLO11n)	0.739	0.454	0.219	基础水平
YOLO11n + DCCA	0.746	0.454	0.227	划痕微涨，麻点持平
YOLO11n + PGM	0.768	0.566	0.160	麻点大幅提升，划痕下降
PGA-YOLO (Ours)	0.733	0.576	0.219	综合最优，短板修复

5.3.3 算法鲁棒性与环境适应性测试

为了验证所提 PGA-YOLO 算法在复杂工业现场环境下的可靠性与泛化能力，本研究构建了包含光照波动、机械离焦模糊以及对比度衰减的鲁棒性测试实验。考虑到实际产线中可能存在的非受控照明、传送带微震动等导致的成像质量退化，本节在推理阶段对验证集图像注入不同强度的物理扰动，并引入 YOLO11n 进行同等条件下的对比测试。实验重点考察模型在图像信噪比降低与特征纹理退化情况下的性能保持率，三组典型扰动下的定量对比结果如图 5-9 所示。




图 5-9 算法鲁棒性与环境适应性测试折线图

针对楔形滤光片微小缺陷检测中最为棘手的弱信号提取难题，对比实验结果

揭示了 PGA-YOLO 在低对比度工况下具有显著的性能优势。如图 5-4(c)所示, 随着对比度系数从标准状态衰减至 0.4 的极限灰度环境, 基线 YOLO11n 模型的检测精度 $mAP@0.5$ 从 0.4706 断崖式下跌至 0.4301, 显示出纯数据驱动模型在纹理特征变弱时的判别乏力。相比之下, PGA-YOLO 展现出了较好的特征锁定能力, 即便在对比度仅为 0.4 的极端工况下, 其 $mAP@0.5$ 依然维持在 0.4806, 这一数值甚至超越了基线模型在无扰动高质量成像下的最佳性能。该表现证明了物理感知引导机制 PGM 在像素灰度差异大幅降低的背景下, 显式提取的梯度拓扑结构依然稳固, 能够引导网络精准勾勒出深埋于背景中的微弱缺陷边界。

在非受控照明环境的适应性测试中, PGA-YOLO 同样表现出优于基线的稳定性。如图 5-4(b)所示, 当亮度系数在 0.6 至 1.2 的范围内波动时, PGA-YOLO 的性能曲线始终位于基线模型上方且保持平稳。特别是在亮度系数降低至 0.6 以模拟光源老化或极暗环境时, 基线模型的性能出现明显波动, 而 PGA-YOLO 检测精度仍稳定在 0.5069, 显著高于基线的 0.4625。这表明改进后的模型不再过度依赖图像的绝对灰度值进行特征判别, 而是得益于深度解耦通道竞争注意力 DCCA 模块的作用。该模块通过通道间的竞争机制, 成功学会了抑制受光照影响较大的低频背景通道, 专注于提取对光照变化不敏感的本征纹理特征。

关于机械震动引发的离焦影响, 实验呈现出明显的物理边界特性。如图 5-4(a)所示, 在轻微离焦工况下, PGA-YOLO 凭借 0.4665 的平均精度依然领先于基线模型, 证明了算法对产线常规微震动具有良好的容忍度。然而, 随着模糊核大小增加至 9 的严重失焦状态, PGA-YOLO 的性能衰减幅度开始大于基线模型。这一现象恰恰符合物理可解释性, 因为基线模型主要依赖深层语义特征进行团块识别, 对边缘清晰度不敏感, 而 PGA-YOLO 引入物理梯度引导旨在追求像素级的边缘精准度, 当严重失焦导致物理边缘彻底消失时, 梯度引导失效从而导致性能下降。这一物理特性反向印证了本文第三章 CFAN 自动对焦系统的必要性, 即只有通过精密硬件保障基础成像在一定清晰度范围内, PGA-YOLO 的精密检测优势才能得到释放。

综上所述, 对比实验表明 PGA-YOLO 不仅在标准工况下精度领先, 更在低对比度与光照波动等恶劣环境下展现出较高鲁棒性。其通过物理先验与深度特征的有效融合, 成功解决了弱信号缺陷在复杂成像条件下的漏检难题, 满足智能交通感知硬件产线全天候且高可靠的质检需求。

5.3.4 可视化分析与机理解释

为了打破深度学习模型的黑盒特性并深入探究 PGA-YOLO 算法在特征提取与目标定位过程中的内在关注逻辑, 本研究采用梯度加权类激活映射 Grad-CAM

技术对不同模型变体在处理典型缺陷样本时的类激活热力图进行了可视化对比分析，结果如图 5-10 所示。图中红色高亮区域代表模型在进行决策时赋予高权重的特征响应区，直观反映了网络的视觉注意力焦点。




图 5-10 PGA-YOLO 不同模型变体的 Grad-CAM 可视化热力图

观察基准 YOLO11n 模型的热力图响应可以发现其注意力分布呈现出显著的发散性。热力图的大量高响应值错误地溢出至背景区域，对表面的纹理边缘、灰尘干扰及暗场成像中的随机噪声表现出了明显的无效激活。这种注意力弥散现象表明纯数据驱动的基准网络难以在低信噪比环境下有效区分缺陷特征与背景杂波，这直接解释了基准模型在定量实验中虚警率较高的原因。

在引入深度解耦通道竞争注意力 DCCA 模块后，特征图的热力分布发生了质的变化。可视化结果显示原本弥散在背景区域的杂乱热点被大幅抑制，背景颜色趋于冷色调，而高响应区域开始显著向缺陷主体收缩与凝聚。这有力地证明了 DCCA 模块内部的通道竞争机制发挥了关键的滤波作用，通过抑制冗余的背景通道响应并增强关键特征通道的权重，成功实现了特征层面的噪声净化与语义聚焦。

进一步引入物理感知引导机制 PGM 后，模型对缺陷几何形态的感知能力得到了显著增强。热力图显示在崩边与麻点等具有显著梯度变化的区域激活强度大幅提升，且热力图的轮廓边缘与缺陷真实的物理几何边界呈现出高度的吻合性。这表明 PGM 机制通过注入梯度与结构差分等物理先验，成功引导网络突破了模

糊成像的限制,使其能够敏锐地捕捉到缺陷的边缘拓扑结构,而非仅仅关注局部像素的强度差异。

最终集成了双重改进策略的 PGA-YOLO 模型在热力图上展现出了背景纯净且目标锐利的理想特征响应模式。其热力图不仅精准覆盖了微小的麻点与极低对比度的细长划痕,且边界清晰度远超各对比模型,背景区域几乎无无效激活。这种从发散模糊到精准聚焦的特征响应演变,从可解释性角度深刻印证了物理感知引导与深度特征解耦策略的协同有效性,即 DCCA 负责去噪以降低虚警而 PGM 负责增强以提升召回,两者共同赋予了模型在复杂背景下精准检测微小缺陷的科学机理与鲁棒能力。基于上述特征提取层面的机理优势,PGA-YOLO 在最终的检测输出端展现出了较好的实用性能,检测结果示例如图 5-11 所示。




图 5-11 楔形滤光片缺陷检测结果示例 (splash: 麻点; chipping: 崩边; scratch: 划痕)

针对滤光片边缘高频出现的微小崩边以及表面极易被忽略的细微划痕,模型生成的预测框与缺陷几何边界高度贴合,且置信度评分始终保持在较高水平。这有力地证明了模型在处理形态各异的复杂缺陷时,能够精准还原缺陷的物理真实属性。即便在背景噪声干扰严重或缺陷对比度极低的难检测区域,算法仍能凭借对梯度拓扑结构的深度解析,滤出微弱目标信号,从一定程度上解决了精密光学质检中因光照不均或成像退化导致的漏检难题。

实验结果表明,该方案在提升检测效能的同时,一定程度上降低了系统对高质量成像环境的依赖,为楔形滤光片的高可靠性自动化质检提供了具备科学解释性的技术支撑。

5.4 面向交通感知的光学表面缺陷影响评估实验

5.4.1 实验目的与思路

为评估楔形滤光片表面缺陷对智能交通感知系统决策性能的影响,本节以交通目标检测任务为典型应用场景开展验证实验。作为交通感知系统的关键光学元件,楔形滤光片的表面质量直接决定了成像结果的信噪比水平及结构特征的完整性。其表面存在的划痕、麻点及崩边等物理缺陷,往往会引发光线散射、局部模糊及对比度下降等退化效应,从而对后续视觉感知算法产生级联影响。因此,本实验的核心目的在于定性定量分析上述物理缺陷如何由光学层面的成像退化,传递并映射至算法推理层面的感知性能下降。

在具体实现上,实验通过构建受控的图像退化场景,重点考察图像质量劣化后目标检测模型在识别车辆、行人等关键交通参与者时的性能变化,包括检测置信度的波动及漏检错检现象的发生情况。

首先,在性能基准阶段,选取 Kitty 交通数据集中的验证集作为原始数据集,共计 1496 张交通图像,并利用预训练的 YOLO11m 模型在理想成像条件下进行推理,统计其检测目标数量及平均置信度,作为后续对比分析的基准参考。随后,在缺陷建模阶段,结合滤光片实际损伤机理,基于数字图像处理方法构建划痕、麻点与崩边等典型缺陷的退化模型,并按照轻微、中等与严重三个强度等级对原始图像进行扰动,生成多组具有不同退化程度的受损样本数据。

在获得受损样本后,实验通过保持检测模型参数及推理配置一致,对比分析模型在原始图像与各类退化图像上的检测表现差异。重点从目标边缘结构保持能力及局部语义特征表达能力两个方面,分析光学缺陷对模型特征提取过程的影响机制,进一步探讨其引发漏检或误检的潜在原因。最后,通过汇总各实验组的统计结果,结合第 5.1 节中定义的平均置信度及检测数量等评价指标,对缺陷强度

与感知性能衰减之间的关系进行定量刻画。

通过将典型失效案例分析与统计指标变化相结合,本节实验能够直观揭示楔形滤光片表面质量缺陷对交通感知系统性能的负面影响。

5.4.2 表面缺陷建模方法

为真实反映楔形滤光片表面缺陷对成像质量的影响,本研究在交通场景原始图像的基础上,构建具有物理意义的缺陷退化模型,对划痕、麻点及崩边三类典型缺陷进行模拟。本实验充分考虑了光学成像过程中由表面缺陷引起的散射、模糊及对比度压缩等效应,从而使生成的退化图像在视觉表现及统计特性上更接近真实受损情况。

针对划痕缺陷,采用具有随机方向的线性结构对图像进行局部扰动。具体而言,在图像中随机生成若干具有一定长度和方向的线段区域,并基于方向相关的卷积核对该区域进行模糊处理,以模拟划痕对光线传播路径的干扰作用。在此基础上,通过对划痕区域像素进行亮度压缩与对比度降低,进一步刻画划痕导致的局部能量损失及细节退化现象。随着缺陷强度的增加,划痕的数量、宽度以及模糊程度同步提升,从而形成由轻微到严重的连续退化效果。

针对麻点缺陷,采用局部块状区域随机生成的方式构建退化模型。在图像中随机选取多个不同尺度的区域块,对其像素进行均值回归处理以压缩对比度,并叠加高斯噪声模拟微小坑蚀对光学成像产生的散射干扰。同时,根据缺陷强度对局部区域施加不同程度的模糊操作,使得麻点区域呈现出细节缺失与纹理紊乱的特征。为增强整体退化一致性,还在全图范围内引入弱噪声扰动,从而更真实地反映实际光学系统中多点缺陷的叠加效应。

针对崩边缺陷,主要模拟滤光片边缘损伤对成像质量的影响。该类缺陷通常表现为图像边界区域的模糊与亮度衰减,因此在建模过程中选取图像的边缘区域,通过逐行或逐列递增模糊核尺寸的方式构建渐进式退化效果,使边缘区域从清晰逐渐过渡至严重模糊。同时对该区域施加亮度衰减因子,以模拟边缘破损引起的光能衰减与散射现象。不同强度下,崩边区域的影响范围与退化程度逐步扩大,从而对整体图像结构产生更显著的干扰。

在实际实验中,为更全面地反映复杂工况下的光学退化情况,三类缺陷可按照设定强度进行组合叠加,形成多类型混合缺陷场景。通过设定轻微、中等及严重三个强度等级,对原始图像进行逐级扰动,最终构建出具有不同退化程度的测试数据集。该建模方法不仅能够在视觉上再现真实缺陷特征,还能够为后续交通感知性能分析提供稳定且可控的数据基础。

5.4.3 实验结果与分析

在完成缺陷建模与数据集构建后,本文基于统一配置的 YOLO11m 目标检测模型,对原始图像与不同强度下的退化图像进行对比实验分析。实验过程中严格保持模型权重及推理参数一致,确保性能波动仅由成像质量退化引起,以此客观反映楔形滤光片表面缺陷对交通感知系统的影响。

如图 5-12 所示,随着混合缺陷模拟强度的增加,图像的综合视觉特征退化趋势显著。在原始基准图像中,成像质量清晰,模型能够精准识别视场内的各类交通目标,检测框贴合度高且分类属性明确。在轻微缺陷(强度 0.3)条件下,由划痕散射、麻点噪声与边缘照度畸变共同组成的复合干扰开始显现,图像局部对比度出现下降,导致部分远端小尺寸目标的边缘轮廓变得模糊,但在该强度下,模型仍能依靠残存的结构特征维持大部分目标的检出。



图 5-12 混合缺陷模拟交通检测结果图

随着混合缺陷强度提升至 0.5,多类缺陷的协同干扰效应加剧,图像信噪比显著降低。此时,划痕对边缘梯度的破坏与麻点对纹理特征的掩盖相互交织,使

得算法对车辆关键语义特征的提取受到明显干扰，部分处于背景复杂区域的目标开始出现检测框漂移或置信度大幅波动的现象。在严重缺陷（强度 0.7）条件下，高强度的复合缺陷导致图像整体结构信息遭到大幅度削弱，严重的非均匀照度畸变与密集的随机噪声使得原始场景中原本清晰可见的车辆目标特征趋于湮灭，进而诱发了大面积的漏检现象。可视化结果直观地表明，楔形滤光片表面多类缺陷的混合叠加，通过削弱图像中的有效结构信息，直接破坏了模型对关键特征的鲁棒提取能力，且这种干扰程度随强度的增加呈现出明显的非线性扩展。

从定量统计结果来看，实验数据进一步验证了上述定性观察。根据图 5-13 显示，检测目标总数随缺陷强度增加呈现明显的阶梯式下降，从原始状态下的 10662 个目标跌落至严重缺陷状态下的 8354 个，漏检率显著上升。与此同时，图 5-14 反映出平均置信度从 0.616 持续下滑至 0.598。这种数量与质量指标的同步衰减，说明图像退化不仅导致了检测的完整性缺失，更削弱了感知系统对残存目标的判别信心。深入分析不同缺陷的作用机理可知，划痕缺陷主要通过破坏目标梯度信息影响定位精度，麻点缺陷通过引入高频噪声干扰纹理表达，而崩边缺陷则对图像边缘区域造成严重的感知盲区。多类型缺陷叠加时，这些负面效应相互耦合，导致系统整体感知性能呈现出非线性的快速劣化趋势。




图 5-13 不同缺陷模拟强度检测数量统计图




图 5-14 不同缺陷模拟强度下的检测置信度趋势折线图

综合上述分析可知，楔形滤光片表面缺陷对交通感知系统决策性能具有显著的负面影响，其核心机制表现为光学退化导致特征表达能力下降，进而诱发检测性能劣化。这一结论从应用层面印证了前端光学元件质量对智能交通系统稳定运行的决定性作用，充分证明了开展高精度楔形滤光片表面缺陷智能检测研究的必要性。为本文所提出的缺陷检测算法在实际交通工程中的应用价值提供了坚实的理论与实验支撑。

5.5 本章小结

本章在统一实验环境与评价指标体系下，从自动对焦、缺陷检测及交通感知影响评估三个层面对本文方法进行了系统验证。

在自动对焦实验中，CFAN 通过三视角协同输入和视间注意力融合机制，有效提升了复杂倾斜表面条件下的离焦距离预测精度与对焦成功率；辅助对比学习策略进一步增强了模型在噪声干扰和光照波动条件下的鲁棒性，为后续缺陷检测提供了稳定的清晰成像基础。

在缺陷检测实验中，PGA-YOLO 在保持轻量化和低时延的同时，实现了较优的检测精度。实验结果表明，DCCA 模块能够有效抑制复杂背景干扰、增强关键纹理表达，PGM 机制通过引入物理先验提升了模型对微小缺陷的识别能力和环境适应性。

此外，本章还开展了面向交通感知的光学表面缺陷影响评估实验。结果表明，

随着缺陷强度增加，交通目标检测数量和平均置信度均呈下降趋势，揭示了光学元器件表面缺陷对后续感知任务性能的影响。

综上，本章实验结果验证了本文所提自动对焦与缺陷检测方法在精度、效率和鲁棒性方面的有效性，并说明了其在交通感知硬件质量保障中的实际应用价值。

总结与展望

1 全文工作总结

本文立足智能交通感知系统对前端成像硬件物理可靠性的根本依赖，以核心光学元器件楔形滤光片为切入点，明确其表面缺陷通过成像质量退化逐级传递至系统决策层的链式风险。针对楔形结构引发的非均匀离焦成像与复杂背景下弱信号特征难提取的技术瓶颈，系统开展了从精密检测装备研制、鲁棒自动对焦算法设计到智能缺陷识别模型构建的研究工作，旨在从物理源头筑牢交通感知硬件的质量保障防线。

首先面向工业现场的高通量质检标准，搭建了集精密运动控制、多视角同步采集与分布式软件调度于一体的自动化检测实验平台。通过 EtherCAT 工业总线实现了三轴运动平台与视觉采集单元的毫秒级时序协同，并设计了基于数据库的质量追溯体系，为后续算法的验证与工程化部署提供了标准化的物理载体与数据基础。

其次，针对楔形滤光片倾斜表面在显微成像视场内产生的非均匀离焦现象，提出了基于多模态视觉注意力的鲁棒自动对焦网络 CFAN。该方法突破了传统单视角清晰度评价的局限，创新性地构建了三视角协同输入的深度回归架构，利用 Swin Transformer 骨干网络强大的全局上下文捕捉能力提取空间离焦特征。在此基础上，设计了视间注意力融合机制 IVAF 以显式建模不同视场间的几何关联，并引入辅助对比学习策略增强模型对微小离焦差异的判别敏感度。实验表明该方法在复杂工业环境下实现了 $20.6\mu\text{m}$ 的平均绝对误差与 91.51% 的对焦成功率，有效解决了倾斜表面的全视场清晰成像难题。

再次，在获取高质量原始图像的基础上，针对镀膜纹理背景下划痕、麻点等微小缺陷对比度低且形态各异的识别困境，提出了融合物理感知引导与解耦注意力的轻量化检测算法 PGA-YOLO。该算法以 YOLO11n 为基准，通过设计深度解耦通道竞争注意力模块 DCCA，实现了特征空间中背景噪声的精准抑制与关键纹理的提纯。同时构建了物理感知引导机制 PGM，将梯度、高光残差等确定性物理先验动态注入深度网络，有效弥补了纯数据驱动模型在模糊边界处的判别不确定性。实验验证了该算法在保持极低参数量与推理延迟的同时，显著提升了对弱信号缺陷的检测精度，实现了精度与速度的较好平衡。

最后，基于统一的软硬件实验平台与量化评价体系，对所提技术方案进行了全流程的综合验证。结果表明，本文构建的自动对焦与缺陷检测协同体系有效解决了楔形滤光片特殊光学结构带来的成像与检测难题，具备适应复杂工业现场环境的鲁棒性与稳定性。在此基础上，面向交通感知的应用验证实验进一步揭示了

表面缺陷通过成像质量退化对目标检测性能产生的级联影响,从应用层面实证了前端光学元件质量对感知系统决策可靠性的关键作用。该研究成果为智能交通感知硬件的制造质量提供了可靠的技术保障,对于保障交通感知系统的安全性具有重要的理论意义与工程应用价值。

2 研究不足分析

尽管本文在楔形滤光片自动化检测系统的构建、鲁棒自动对焦方法及微小缺陷智能识别算法等方面取得了具有理论意义与工程价值的研究成果,但受限于实验条件、数据规模及时间成本,现有研究工作在以下几个方面仍存在一定的局限性与改进空间。

首先是深度学习模型在边缘侧设备的部署效能仍面临算力瓶颈。虽然本文提出的 PGA-YOLO 检测算法在轻量化设计上取得了显著进展,将单图推理延迟控制在毫秒级,但整个检测链路中还包含了基于 Swin Transformer 架构的 CFAN 自动对焦网络。Transformer 架构虽然在提取全局空间离焦特征方面优势明显,但其计算复杂度与显存占用率相对较高。尽管本文提出的 PGA-YOLO 在现有实验平台上表现出较低推理延迟和较小模型规模,但本文尚未完成实际嵌入式设备移植和长周期在线运行验证。因此,现阶段的轻量化结果主要说明模型具有部署潜力,仍不能完全代表其在产线边缘端设备上的实际运行效果。后续研究将进一步围绕模型剪枝、参数量化、ONNX/TensorRT 推理加速以及工控机端稳定性测试开展工作,以验证模型在连续检测场景下的实时性、稳定性和资源占用情况。

其次是缺陷数据集的覆盖范围与样本多样性尚显不足。本文构建的工业缺陷数据集虽然涵盖了划痕、麻点与崩边这三类最典型的失效模式,且通过 Mixup 与 Copy-Paste 等增强策略缓解了类别不均衡问题,但实际的光学元件生产过程中可能出现的缺陷形态远不止于此。例如镀膜层脱落、水纹印渍以及油污污染等长尾罕见缺陷,此类罕见缺陷在暗场下往往表现为缺乏高频边界的极低对比度渐变信号。由于缺乏显著的物理几何突变,其微弱特征极易在网络背景抑制过程中被当作低频光场噪声过滤,暴露出当前模型对非几何突变类异常的感知局限。由于这些罕见缺陷由于发生频率低、样本采集难度大,尚未形成足够规模的数据集。该问题限制了模型对长尾异常缺陷的覆盖能力。后续研究将结合企业实际生产数据持续扩充罕见缺陷样本,并探索小样本学习、生成式数据增强和开放集异常检测方法,以提升模型对未知缺陷和低频缺陷的识别能力。

最后是系统在极端复杂环境下的长期稳定性验证尚不够充分。尽管本文在实验环节引入了高斯噪声、椒盐噪声及光照波动等模拟扰动来测试算法的鲁棒性,并证明了模型具备一定的抗干扰能力,但这些数学模拟生成的噪声与真实的工业现场环境相比仍存在差异。智能交通感知硬件的生产车间往往伴随着高频机械振

动、电磁干扰以及温湿度的剧烈变化, 这些物理因素可能导致成像系统的光轴发生微小偏移或传感器信噪比随时间发生非线性退化。目前的研究主要基于短期的离线数据集进行验证, 缺乏在实际生产线上进行数月乃至更长周期的在线运行测试, 因此系统在应对设备老化与环境长期漂移时的自适应调整能力还有待进一步的工程实证与优化。

3 未来研究展望

针对当前研究在边缘侧部署算力适配、罕见缺陷样本扩充及技术泛化应用方面存在的不足, 后续工作将重点围绕以下三个技术维度展开深化研究。

首先是面向边缘计算终端的模型极致轻量化与硬件加速技术研究。为了解决 Swin Transformer 架构在嵌入式工控机上推理延迟较高的问题, 未来将深入探索基于知识蒸馏^[71]的跨架构模型压缩技术, 尝试利用高精度的 CFAN 教师网络指导轻量化卷积神经网络学生模型的训练, 以期在大幅降低计算复杂度与显存占用的同时保留对全局空间离焦特征的捕获能力。同时将研究网络剪枝与参数量化技术, 开发适配 TensorRT 或 FPGA 硬件加速器的专用推理引擎, 通过算子融合与混合精度计算优化, 实现自动对焦与缺陷检测算法在低功耗边缘设备上的毫秒级实时响应, 推动检测系统向小型化与便携化方向发展。

其次是基于生成式人工智能的小样本与无监督缺陷检测方法研究。针对工业现场长尾罕见缺陷难以获取足量训练样本的瓶颈, 未来计划引入生成对抗网络 GAN^[72]或扩散模型 Diffusion Model^[73]等前沿生成式技术, 通过学习已知缺陷的物理纹理特征生成高逼真的虚拟缺陷样本, 以实现训练数据集的定向扩充。此外还将探索基于良品重构的无监督异常检测范式, 利用自编码器或归一化流模型学习正常楔形滤光片的分布规律, 通过度量重构误差来识别包括未知缺陷在内的所有异常区域, 从而彻底摆脱对海量标注数据的依赖, 提升系统在面对开放集缺陷时的泛化与自适应能力。

最后是探索将本文提出的核心技术推广应用于智能交通系统中其他异形光学元件的质量检测。虽然 CFAN 自动对焦与 PGA-YOLO 检测算法是针对楔形滤光片这一特定对象设计的, 但其蕴含的多视角视间注意力融合机制与物理感知引导思想对于处理具有复杂曲面或非连续表面的光学组件同样具有普适性价值。未来研究将致力于挖掘该技术架构的泛化潜力, 尝试将其迁移至车载非球面镜头、激光雷达视窗及异形交通信号透镜等精密元件的自动化质检场景中。通过构建通用的异形表面成像与缺陷识别理论框架, 进一步拓宽智能视觉检测技术的应用边界, 为构建全方位且高可靠的智能交通感知硬件生态体系提供更广阔的技术支撑。

参考文献

- [1] 潘晓炜. 车路协同技术在城市交通出行应用探讨[J]. 时代汽车, 2025, (19): 180-182.
- [2] 俞侃, 黄德修, 尹娟娟, 等. 倾斜入射楔形薄膜滤光片的透射光谱研究[J]. 光谱学与光谱分析, 2013, 33(08): 2290-2293.
- [3] 蓝章礼, 文鸿, 张洪, 等. CoCo-SEAM: 融合颜色相关图与自集成多尺度注意力的被遮挡交通标志检测算法[J/OL]. 电子测量技术, 1-15[2026-03-31]. <https://link.cnki.net/urlid/11.2175.TN.20260305.0918.004>.
- [4] 吴洪洋, 高倍力, 杨海平. 智能交通先导应用试点建设进展、关键技术与发展趋势[J]. 交通运输研究, 2025, 11(04): 11-24.
- [5] 李道飞, 刘鹏博, 黎嘉, 等. 高速公路多视角轻量化感知系统设计和应用研究[J]. 西部交通科技, 2025, (06): 178-180.
- [6] Kloeker C, Liu C, Wei C, et al. Framework for Quality Evaluation of Smart Roadside Infrastructure Sensors for Automated Driving Applications[C]. Piscataway, NJ: IEEE, 2023: 1-7.
- [7] Soltanirad M, Ma H, Bagheri M, et al. A Comparative Quantitative Analysis of LiDAR, Radar, and Camera for Robust Environmental Perception in All-Weather Conditions [C]. Piscataway, NJ: IEEE, 2023: 1334-1341.
- [8] Mohammed A, Hussein M. Evolution of All-Weather Perception and Recognition Systems for Autonomous Vehicles: A Systematic Review[J]. Sensors, 2023, 23(17): 7556.
- [9] Ibanez-Guzman J, Lefaudeux B. Complementary Properties of LiDAR and Camera for 3D Object Detection in Autonomous Driving: An Information-Theoretic Perspective[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 3740-3747.
- [10] Ansariyar A, Al-Zahrani M. Experimental Evaluation of Traffic Camera Measurement Errors under Varying Visibility Conditions at Signalized Intersections[J]. Transportation Research Part C: Emerging Technologies, 2023, 152: 104164.
- [11] Zhang L, Wang Y. Measuring Robustness of Cyber-Physical Systems Against Sensor Attacks: A Conformal Prediction Approach[J]. IEEE Transactions on Dependable and Secure Computing, 2024, 21(1): 123-137.
- [12] 全国通信标准化技术委员会. GB/T 44417-2024 车路协同系统智能路侧协同控制设备技术要求和测试方法. 北京: 中国标准出版社, 2024.
- [13] 陈川, 张旻, 仇浩, 等. 基于改进爬山算法的显微自动对焦系统[J]. 江苏理工学院学报, 2023, 29(4): 45-50.
- [14] 杨海, 冯选璋, 刘家屹, 等. 基于图像评价的显微镜自动对焦方法[J]. 激光与光电子学进展, 2023, 60(10): 1011001.
- [15] 江阳, 胡飞, 龚大江, 等. 荧光 PCR 多规格耗材自动对焦算法及装置研究[J]. 中国激光, 2025, 52(3): 0317001.
- [16] 李才伟. 基于固定光斑图案和图像互相关的病理图像自动对焦方法[D]. 海口: 海南大学, 2024.

- [17] 杨艳艳. 基于图像处理的航空红外相机自动调焦技术研究[D]. 中国科学院研究生院(上海技术物理研究所), 2016.
- [18] 张建宏, 杜晋, 朱亚东, 等. 一种适用于荧光显微镜的自动对焦装置: CN202211269881.8[P]. 2023-01-31.
- [19] 王小卓, 孙炜钰, 陶佳清, 等. 用于半导体表面检测的实时对焦装置及自动对焦方法: CN202211296699.1[P]. 2023-02-14.
- [20] 刘信良, 张龙泉, 冷晟, 等. 融合全局和局部信息的铁谱图像自动对焦算法[J]. 中国光学, 2024, 17(02): 356-366.
- [21] 郑博文, 刘绍锦, 沈铨武, 等. 视觉测量系统中基于深度学习的自动对焦方法[J]. 激光与光电子学进展, 2024, 61(05): 0511002.
- [22] Chen L, Adele M, Xuying Z, et al. Deep learning-based autofocus method enhances image quality in light-sheet fluorescence microscopy[J]. Biomedical Optics Express, 2021, 12(8): 5214-5226.
- [23] Jun L, Xu C, Ge D, et al. Deep learning-based single-shot autofocus method for digital microscopy[J]. Biomedical Optics Express, 2022, 13(01): 314-327.
- [24] Wei X, Yang R, Wu X, et al. Improve Deep Learning Autofocus with Depth Information Supervision and Current Focal Distance Cues[C]//2024 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2024: 1644-1651.
- [25] Wang R, Liu T. Autofocus control using adaptive region selection and reinforcement learning applied in wafer micro-imaging[J]. Optics Express, 2025, 33(08): 17345-17354.
- [26] Pu W. SAE-Net: A Deep Neural Network for SAR Autofocus[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-14.
- [27] Liu Z, Yang S, Gao Q, et al. AFnet and PAFnet: Fast and Accurate SAR Autofocus Based on Deep Learning[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-13.
- [28] Zhao W. Enhanced Autofocusing with a Compact and Swift ST-VGG Network[J]. 2024.
- [29] He L, Wang X, Wei J. FocusNet-CL: A Deep Learning Approach for Clarity Assessment of Laser Direct Writing Blank Samples[J]. Optics Communications, 2025: 132087.
- [30] 邓燕, 许乔, 柴立群, 等. 光学元件亚表面缺陷的全内反射显微检测[J]. 强激光与粒子束, 2009, 21(11): 1641-1644.
- [31] 戈畅, 韩军, 吴飞斌. 基于显微拉曼的光学元件缺陷检测方法研究[J]. 激光杂志, 2022, 43(08): 45-50.
- [32] 李佳慧, 匡翠方, 徐月暑, 等. 极紫外光学元件全频段面形误差检测与缺陷探测技术研究进展[J]. 光学精密工程, 2025, 33(02): 180-195.
- [33] 陈晓辉, 王鑫森, 段亚凡. 光学元件微缺陷偏振检测的图像处理方法研究[J]. 光学仪器, 2024, 46(03): 10-16.
- [34] 王鑫森, 陈晓辉, 段亚凡, 等. 曲面光学元件表面微缺陷透射式偏振检测[J]. 光学技术, 2023, 49(05): 520-526.
- [35] 姜李哲, 刘骥, 林嘉俊, 等. 基于图像处理的多光谱透明光学元件疵病检测[J]. 激光杂

- 志, 2025, 46(01): 66-72.
- [36] 张传博, 李林福, 陈建军, 等. 基于剪切波变换的光学元件表面缺陷检测方法[J]. 传感器与微系统, 2023, 42(04): 150-153.
- [37] 马志程, 李丹, 张宝龙. 基于改进 Mask R-CNN 的光学元件划痕缺陷检测研究[J]. 电子测量与仪器学报, 2023, 37(12): 200-208.
- [38] 张静, 刘思莹, 王甜, 等. 基于深度学习的光学元件表面缺陷检测方法[J]. 光学与光电技术, 2025, 23(01): 88-95.
- [39] 洪惠敏, 贺文俊. Micro-LED 晶圆缺陷检测的宽光谱大视场显微物镜设计[J]. 光子学报, 2025, 54(03): 0322001.
- [40] Wang C, Chen H, Zhao S, et al. A Low-Cost Defect Segmentation System Based on IoT for Large-Scale Photovoltaic Manufacturing[J]. IEEE Internet of Things Journal, 2024, 11(09): 16928-16940.
- [41] Karimi N, Mishra M, Lourenço P B. Deep Learning-Based Automated Tile Defect Detection System for Portuguese Cultural Heritage Buildings[J]. Journal of Cultural Heritage, 2024, 68: 86-98.
- [42] He Z, Wang Y H. Mamba meets crack segmentation[J]. arXiv preprint arXiv: 2407.15714, 2024.
- [43] Yuan M, Zhou Y, Ren X, et al. YOLO-HMC: An Improved Method for PCB Surface Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 2001611.
- [44] Chen M, Chen J, Li C, et al. Defect Detection of MicroLED With Low Distinction Based on Deep Learning[J]. Optics and Lasers in Engineering, 2024, 173: 107924.
- [45] Li Z, Wei X, Hassaballah M, et al. A Deep Learning Model for Steel Surface Defect Detection[J]. Complex & Intelligent Systems, 2024, 10: 885-897.
- [46] Mei Z, Luo Y, Qiao Y, et al. A Novel Joint Segmentation Approach for Wafer Surface Defect Classification Based on Blended Network Structure[J]. Journal of Intelligent Manufacturing, 2025, 36: 1907-1921.
- [47] Qiao Y, Chen Y, Liu F, et al. RA-UNet: A New Deep Learning Segmentation Method for Semiconductor Wafer Defect Analysis on Fine-Grained Scanning Electron Microscope (SEM) Images[J]. IEEE Transactions on Semiconductor Manufacturing, 2025.
- [48] Fan C L, Cao M, Hung C C, et al. Optical Model-Driven Sharpness Mapping for Autofocus in Small Depth-of-Field and Severe Defocus Scenarios[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2025: 6426-6435.
- [49] Pagire V, Chavali M, Kale A. A comprehensive review of object detection with traditional and deep learning methods[J]. Signal Processing, 2025, 237: 110075.
- [50] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30: 5998-6008.
- [51] 张重生, 陈杰, 李岐龙, 等. 深度对比学习综述[J]. 自动化学报, 2023, 49(01): 15-39.
- [52] Oord A, Li Y, Vinyals O. Representation learning with contrastive predictive coding[J]. arXiv preprint arXiv: 1807.03748, 2018.
- [53] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A new backbone that can enhance

- e learning capability of CNN[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops. 2020: 390-391.
- [54] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 7464-7475.
- [55] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv: 1704.04861, 2017.
- [56] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [57] Lin M, Chen Q, Yan S. Network in network[J]. arXiv preprint arXiv: 1312.4400, 2013.
- [58] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(6088): 533-536.
- [59] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(02): 91-110.
- [60] Willmott C J, Matsuura K. Advantages of the mean absolute error over the root mean square error in model performance assessments[J]. Climate Research, 2005, 30(01): 79-82.
- [61] Chai T, Draxler R R. Root mean square error (RMSE) or mean absolute error (MAE)?—Arguments against avoiding RMSE in the literature[J]. Geoscientific Model Development, 2014, 7(03): 1247-1250.
- [62] Lin T Y, Maire M, Belongie S, et al. Microsoft coco: Common objects in context[C]//European Conference on Computer Vision (ECCV). 2014: 740-755.
- [63] Koonce B. MobileNetV3[M]//Convolutional Neural Networks with Swift for TensorFlow. Berkeley, CA: Apress, 2021: 125-144.
- [64] Koonce B. ResNet 50[M]//Convolutional Neural Networks with Swift for TensorFlow. Berkeley, CA: Apress, 2021: 63-72.
- [65] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv: 2010.11929, 2020.
- [66] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv: 1409.1556, 2014.
- [67] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//Proceedings of the International Conference on Machine Learning (ICML). PMLR, 2019: 6105-6114.
- [68] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017: 618-626.
- [69] Lyu C, Zhang W, Huang H, et al. RtmDET: An empirical study of designing real-time object detectors[J]. arXiv preprint arXiv: 2212.07784, 2022.
- [70] Zhang H, Li F, Liu S, et al. Dino: DETR with improved denoising anchor boxes for end-to-end object detection[J]. arXiv preprint arXiv: 2203.03605, 2022.

- [71] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv: 1503.02531, 2015.
- [72] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems (NeurIPS). 2014, 27: 2672-2680.
- [73] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020, 33: 6840-6851.

致谢

春去秋来，寒窗数载，硕士研究生的求学生涯已接近尾声。回首这段时光，既有深夜攻克算法难题的焦虑，亦有实验成功后的喜悦。本论文的顺利完成，离不开导师、家人、同窗及友人的鼎力支持与悉心关怀。

本论文的研究工作是在我的导师郑积仕老师和易定容老师的悉心指导下完成的。在研究生期间，郑老师严谨的治学态度、扎实的专业素养和敏锐的科研洞察力使我深受启发；从课题的选题构思、技术路线制定到论文的修改定稿，郑老师始终给予我耐心细致的指导与支持。易老师在论文研究过程中同样给予了我许多宝贵帮助，在研究思路凝练、论文结构完善和学术表达提升等方面提出了重要指导意见，使我受益匪浅。在此，谨向郑老师和易老师致以最诚挚的感谢和崇高的敬意。

特别感谢合作企业福建福特科光电股份有限公司对本研究的大力支持。感谢企业提供的研发项目平台及大量关键实验样本，为本课题的深度学习模型训练与算法验证提供了真实、可靠的数据支撑。在项目推进过程中，企业工程技术人员在硬件集成与工业场景需求方面给予了诸多实用建议，使本研究能够紧贴工业检测的实际应用。企业提供的良好实验条件为论文成果的顺利落地奠定了坚实基础。感谢实验室师兄、师姐在科研起步阶段提供的经验分享与技术支持。同时，感谢实验室师弟、师妹在实验开展、数据采集与标注过程中给予的协助。良好的学术讨论氛围为本研究的顺利推进提供了保障。

感谢所有在我的研究生学习与科研成果产出过程中提供过支持与帮助的老师、同学和朋友。感谢参与论文评审与答辩的各位专家教授，感谢你们在百忙之中审阅本论文并提出宝贵的修改建议。

最后，向我的父母及家人致以最深切的谢意。感谢你们多年来在学业与生活上给予的理解、包容与支持，你们的默默付出是我能够坚持前行并顺利完成学业的重要基石。

值此论文完成之际，谨向所有关心、帮助和支持过我的老师、同学、家人及亲友表示衷心的感谢。

个人简历、在学期间的研究成果及发表的学术论文

一、 个人简历

郭琛宇，山西大同人。

2019.09 - 2023.06 就读于杭州电子科技大学自动化学院（人工智能学院），测控技术与仪器专业，本科，获得工学学士学位。

2023.09 - 2026.06 就读于福建理工大学人工智能与交通工程学院，交通运输工程专业，在读研究生。

二、 攻读硕士学位期间发表的论文

- [1] Zheng J, **Guo C**, Wang Y, et al. An automatic focusing method for wedge filters based on multi-view visual attention[J]. Optics and Lasers in Engineering, 2026, 204: 109870. （中科院二区）
- [2] 郑积仕, 郭琛宇, 马鹏飞, 等. 融合物理感知引导与解耦注意力的楔形滤光片轻量化缺陷检测[J]. 武汉理工大学学报. （已录用）

三、 攻读硕士学位期间参与的科研课题

福州市科技局揭榜挂帅项目：《光学零部件（包含楔形）表面瑕疵及三维形貌检测装备研发和产业化》（Y31-KY310562）。

福建省科技厅项目：《科技特派团服务龙岩市武平县新型显示产业链专项》（2025N0057）。

四、 攻读硕士学位期间获得的奖励

2024 年获得学业奖学金三等奖。

2025 年获得第十五届海峡两岸信息服务创新大赛暨福建省第十九届计算机软件设计大赛一等奖。